



2025



Dylan Haazelager
HvA
23-5-2025

Inhoud

1	Images and code snippets:	4
1.1	walkforward validation	4
1.2	Google Search Volume:	5
1.3	Bijtelling percentage per year	7
1.4	Gas prices:	8
2	D1 Feedback.....	9
2.1.1	20 May – Meeting with Kees	9
2.1.2	14 May – Meeting with Marcio	9
2.1.3	13 May – Written feedback from Marcio	9
2.1.4	12 May – Feedback from Daphne	10
2.1.5	07 May – Go/No-Go Check.....	10
2.1.6	06 May – Meeting with Prof. Van Montfort.....	10
2.1.7	17 April – Planning & Topic Shift	10
2.1.8	change list	11
3	Email and keywords:.....	13
4	Prompt used for translating the Key words from Dutch to English:	18
4.1	Python script for google trends url	20
5	Dataset documentation.....	20
5.1	Consumer Confidence, Economic Climate, and Willingness to Buy (CBS, 2007–2025) 20	
5.2	Fuel Pump Prices per Day 2007-2025	23
5.3	Registrations by Fuel Type and Vehicle Category – Netherlands (2007–2025)	24
	NOS News Articles – Netherlands (2015–2025) (Not used)	25
6	Model Selection Rationale	25
7	Daily brain dump	27
7.1	23/05 70%	27
7.2	22/05.....	27
7.3	21/05.....	27
7.4	20/05.....	27
7.4.1	Todolist:.....	27
	Meeting with Kees	27
7.5	19/05.....	29
7.6	Zo18/05.....	29
7.7	Za 17/05	29
7.8	16/05 70% Inleveren.....	33

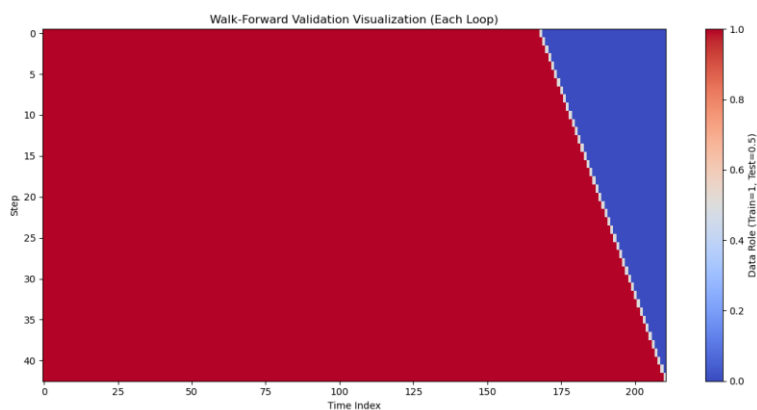
7.9	15/05.....	34
7.10	14/05.....	41
7.10.2	Results new keywords:	49
7.11	13/05.....	49
7.12	12/05.....	58
7.12.1	Oplossing keyword search?	59
7.13	11/05.....	63
Samenvattingen Kernpaper		64
7.14	10/05.....	75
7.14.1.4	Internetgebruik en online activiteiten (CBS-tabel, 2024)	78
7.15	09/05.....	79
7.16	08/05.....	80
7.16.1	Literatuuronderzoek:	80
7.17	07/05 Onderzoekplan herzien	84
7.17.1	Meeting met Marcio	89
7.17.2	Belangrijkste feedbackpunten	89
7.18	06/05.....	91
7.18.2	Gesprek met labbegeleider Kees.....	96
7.19	05/05.....	97
7.19.1	Verkenning en filtering van nieuwsartikelen m.b.v. keywords en embedding	97
7.19.2	Aanbevelingen voor verdere verbetering van het model en de sentimentanalyse 103	
7.20	2/05.....	114
7.20.1	Idee generatie: waarde propositie:	115
7.21	01/05 To do list.....	116
7.22	30/04: (Leave one out toepassen, Nos Sentiment maken met keyword search, evt train/test split maken)	118
7.23	28/04 (Dataset gemerged, code naar stefan gestuurd)	119
7.24	21/04.....	126
7.24.1	TO Do list:	126
8	Meeting Marcio 17/04	131
8.2	Update last feedback moment:	134
Algemeen / Overkoepelend		134
Introductie		134
Probleemstelling en Onderzoeksdoel		135
Onderzoeksvragen.....		135

Literatuurstudie	135
Methodologie	135
Reflectie en Discussie	136
8.3 15/04:	138
8.4 14/04:	142
8.5 03/04:	143
8.6 29/03:	144
8.7 26/03:	145
Feedback thesis	145
8.8 13/03:	148
8.8.1 12/03 feedback daphne op concept:	148
9 Jip en janeke taal:	150
9.1 Feedback Dinsdag 25 februari:	155

1 Images and code snippets:

1.1 walkforward validation

[xgboost.ipynb](#)



Code:

Code snippet:

```
# Walk-forward split: start with 80% as initial train, then identify test points

drop_cols = ['Periode', 'Totaal_verkochte_wegvoertuigen']
target_col = 'Totaal_verkochte_wegvoertuigen'
feature_cols = [col for col in df_lagged.columns if col not in drop_cols]

initial_train_size = int(len(df_lagged) * 0.8)
walkforward_train_sizes = []
walkforward_test_points = []

X = df_lagged[feature_cols].values
y = df_lagged[target_col].values

for i in range(initial_train_size, len(df_lagged)):
    X_train, y_train = X[:i], y[:i]
    X_test, y_test = X[i], y[i]

    walkforward_train_sizes.append(len(X_train))
    walkforward_test_points.append(y_test) # Optional: you can skip storing this

print(f"Total walk-forward steps: {len(walkforward_test_points)}")

# Visualize each walk-forward loop as a matrix (like a CV split matrix)
n_samples = len(df_lagged)
```

```

n_steps = len(walkforward_test_points)
visual_matrix = np.zeros((n_steps, n_samples))


for i in range(n_steps):
    train_end = walkforward_train_sizes[i]
    visual_matrix[i, :train_end] = 1 # Train = 1
    visual_matrix[i, train_end] = 0.5 # Test point = 0.5

plt.figure(figsize=(12, 6))
plt.imshow(visual_matrix, aspect='auto', cmap='coolwarm',
interpolation='nearest')
plt.title("Walk-Forward Validation Visualization (Each Loop)")
plt.xlabel("Time Index")
plt.ylabel("Step")
plt.colorbar(label="Data Role (Train=1, Test=0.5)")
plt.tight_layout()
plt.show()

```

1.2 Google Search Volume:

[Preprocessing.ipynb](#)



Code snippet:

```

# Extract year from 'Periode'
df_consumenten_merged['Year'] = df_consumenten_merged['Periode'].str[:4]

# Group by year and calculate the mean for each indicator
df_yearly = df_consumenten_merged.groupby('Year')[['Consumentenvertrouwen',
'Economisch klimaat', 'Koopbereidheid', 'Grote
aankopen']].mean().reset_index()

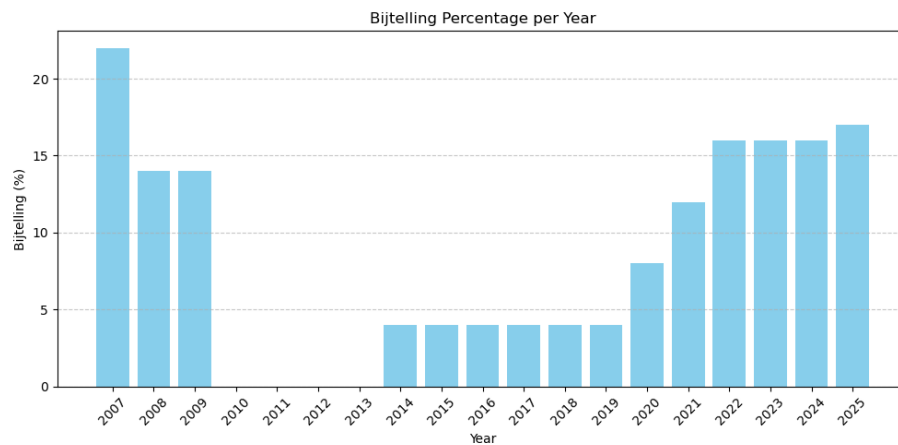
plt.figure(figsize=(14, 6))

```

```
plt.plot(df_yearly['Year'], df_yearly['Consumentenvertrouwen'],
label='Consumer confidence')
plt.plot(df_yearly['Year'], df_yearly['Economisch klimaat'], label='Economic
climate')
plt.plot(df_yearly['Year'], df_yearly['Koopbereidheid'], label='Willingness to
buy')
plt.plot(df_yearly['Year'], df_yearly['Grote aankopen'], label='Favorable time
for large purchases')
plt.xlabel('Year')
plt.ylabel('Index value')
plt.title('Consumer confidence, Economic climate, Willingness to buy, and
Favorable time for large purchases (2007-2025)')
plt.xticks(rotation=45)
plt.legend()
plt.tight_layout()
plt.show()
```

1.3 Bijtelling percentage per year

[Preprocessing.ipynb](#)




Code snippet:

```
colors = ['red' if pct == 0 else 'skyblue' for pct in
yearly_bijtelling['Bijtelling (%)']]

plt.figure(figsize=(10, 5))
plt.bar(yearly_bijtelling['Year'], yearly_bijtelling['Bijtelling (%)'],
color=colors)
plt.xlabel('Year')
plt.ylabel('Bijtelling (%)')
plt.title('Bijtelling Percentage per Year')
plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.xticks(yearly_bijtelling['Year'], rotation=45)
plt.tight_layout()
plt.show()
```


1.4 Gas prices:

[Preprocessing.ipynb](#)



Code snippet:

```
df_pompprijzen_aggregatie['Year'] =  
df_pompprijzen_aggregatie['Periode'].str[:4].astype(int)  
df_yearly = df_pompprijzen_aggregatie.groupby('Year')[['BenzineEuro95_1_mean',  
'Diesel_2_mean']].mean().reset_index()  
  
plt.figure(figsize=(10, 5))  
plt.plot(df_yearly['Year'], df_yearly['BenzineEuro95_1_mean'], marker='o',  
label='BenzineEuro95 (mean)')  
plt.plot(df_yearly['Year'], df_yearly['Diesel_2_mean'], marker='o',  
label='Diesel (mean)')  
plt.xlabel('Year')  
plt.ylabel('Average price (€)')  
plt.title('Yearly average fuel prices (Gasoline & Diesel)')  
plt.xticks(df_yearly['Year'], rotation=45)  
plt.legend()  
plt.tight_layout()  
plt.show()
```

2 D1 Feedback

Generally, I addressed feedback by documenting meeting notes immediately after each session. Based on these notes, I created a to-do list with specific items to add or revise in the report. I also left comments directly in my thesis draft, linking feedback points to the relevant sections.

For the final version, I plan to include a table summarizing all feedback points, whether they were implemented (yes/no), and any relevant remarks.

2.1.1 20 May – Meeting with Kees

Theme: Scope, Methods, and Interpretation

- Clarify what changed in your research and what sets it apart.
- Sharpen your core problem statement and the research gap.
- Add a graph to explain peaks/dips in EV sales using common-sense reasoning.
- Implement Leave-One-Feature-Out (LOFO) analysis.
- Add SHAP values for model interpretability.
- Review requirements critically—are they measurable, justified?
- Test different lag structures for EV sales (e.g., 1–6 months).

2.1.2 14 May – Meeting with Marcio

Theme: Features, Model Justification, Data Handling

- Address multicollinearity in features; use smarter feature selection.
- Justify model choice: why XGBoost and CNN, and not alternatives like LSTM?
- Provide clear descriptions for all features in the dataset.
- Use proper time-series split to avoid data leakage.
- Improve the quality of literature sources (source 8 is strong—use it more).

2.1.3 13 May – Written feedback from Marcio

Theme: Structure, Claims, Literature, Framing

- Refine title – current version is unclear and too narrow.
- Back all strong claims with references.
- Avoid overreliance on Google Trends in framing; keep question broad.
- AIDA model is inconsistently used—consider removing it.
- Improve clarity in research gap and problem statement: who is it for, and why does it matter?
- Consolidate repetitive content in gap sections.
- Make requirements specific and tailored to your target audience.

- Add exploratory data analysis (EDA) on Google Trends and macro variables.
- Improve methodology clarity: how features are selected, why XGBoost, etc.
- Reconsider use of TF-IDF/YAKE—may be outdated.

2.1.4 12 May – Feedback from Daphne

Theme: AIDA, Model Explainability, Relevance

- AIDA model may not match your data and scope—remove it.
- XGBoost isn't truly interpretable—rephrase your claims.
- Avoid repeating gap/problem discussions—streamline.
- Clarify why you didn't collect richer attention/desire signals (e.g., social media, subsidies).

2.1.5 07 May – Go/No-Go Check

Theme: Thesis Scope, Learning Outcomes

- Scope is too broad; problem definition is unclear.
- Refocus on one stakeholder group (e.g., municipalities).
- Make A1–A5 explicit in the thesis.
- Prototype is out of scope? Then clearly state that.
- Keyword selection (NOS) lacks rigor—consider semantic clustering.
- Model fails in certain months (e.g., Feb/Jul); address time variable issues.
- Add monthly dummies instead of time index.
- Hypothesis (NOS sentiment) is likely falsified—pivot to Google Trends.
- Provide rationale for Google Trends: reproducibility, fewer noise issues.

2.1.6 06 May – Meeting with Prof. Van Montfort

Theme: Model Bias, Time as Variable

- Predictions are consistently lower—suggests bias.
- Don't normalize for seasonality at this stage.
- Include time as explanatory variable (e.g., month dummies or month count).
- Avoid redundant aggregations (min, max, avg fuel prices)—choose one.
- OK to proceed without external client—just explain it briefly in your report.

2.1.7 17 April – Planning & Topic Shift

Theme: Tools, Metrics, Planning

- Use semantic tools like Jina Embeddings instead of RobBERT.

- Improve article clustering via cosine similarity and thresholding.
- Clearly justify article selection and filters.
- Define model performance goals (precision, interpretability).
- Track historical policy context and explain patterns in the data.

In the week of May 19, I provided Marcio with a detailed change list showing his feedback and the corresponding adjustments I made.

2.1.8 change list

Legend:

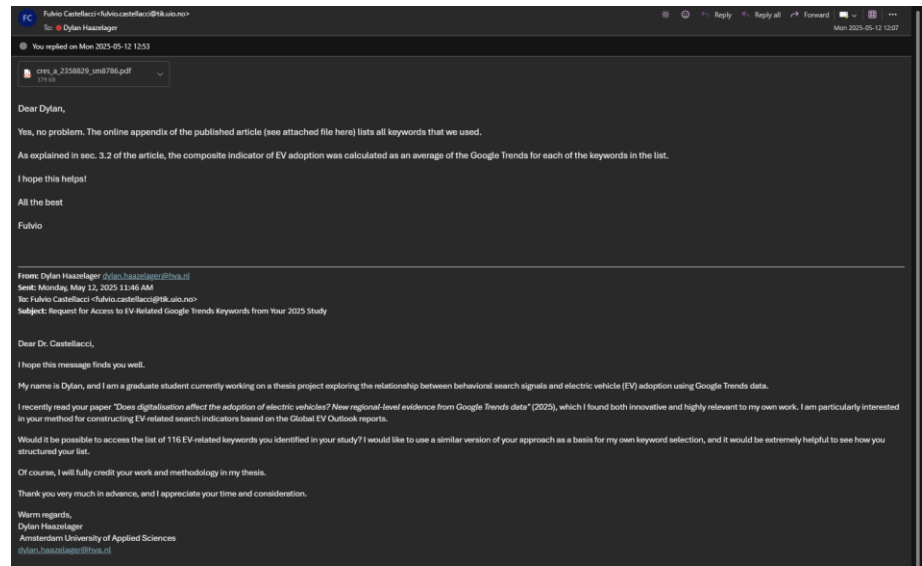
Not changed yet
Changed but still work to do
Changed and happy

Feedback Area	Changed?	Follow-up
Title & Scope • The title was vague and overemphasized “grouped feature importance.”• It needed to better reflect the study’s aim.	✓ Changed from “ <i>Uncovering the Drivers of Car Sales...</i> ” to “ <i>Identifying Data-Driven Predictors of Electric Vehicle Sales in the Netherlands.</i> ”	The title now better reflects the main research question. I may refine it further in the final version for full alignment with the objective.
References & Citation Quality • Missing DOIs and incomplete references.• Literature quality was weak.• Source 8 should be used more effectively.	✓ Used source 8 (Gallagher & Muehlegger) to reinforce the problem statement.△ Some DOIs still missing.	I plan to update all references this week, categorize peer-reviewed vs grey literature, and revise source 5 as needed.
Claims Without Evidence • Some claims lacked sources or statistical backing.• Avoid premature causal language.	△ Still present in parts of the paper.	I will refine unsubstantiated claims and add citations where necessary in the next revision.
AIDA Methodology • Introduced but not followed through.• Unclear	✓ AIDA was removed.	I originally included it based on prior literature but replaced it with

relevance.		better-grounded reasoning on behavioral data.
Problem Statement • Lacked specificity and alignment with Learning Outcome A. • Needed clarity on stakeholders, relevance, and consequences.	✓ Stakeholders added (“policymakers, NGOs, public institutions”).⚠ Still missing clear articulation of consequences of poor forecasting.⚠ LO-A alignment moved under ‘Scope of Research’.	I will integrate LO-A explicitly into the problem statement and add consequences such as infrastructure mismatch and subsidy inefficiency.
Research Question & Subquestions • Too narrow, too focused on one data source.	✓ Broadened to include macroeconomic, digital, and policy signals.✓ Added subquestions.	I will update the final subquestion to more specifically address model performance across feature types.
Requirements • Vague and audience not defined. • Needed to be measurable and referenced in the discussion.	Based on intuition	I will revisit and refine requirements based on hypothetical stakeholder perspective and ensure they are linked back in the discussion section.
Data Description & Preprocessing • No EDA; TF-IDF/YAKE outdated; unclear feature handling.	✓ Added EDA and removed YAKE.✓ Switched to using top correlated keywords.✓ Described macroeconomic data more clearly.✓ Moved keyword selection to Methodology.	No major follow-up needed here; only continue refining EDA plots and documenting variable construction in the appendix or logbook.
Methodology • No clear justification for model choices. • Poor explanation of feature transformations. • Spatial/temporal context lacking.	✓ Justified XGBoost .✓ Tried 5 models and selected XGBoost based on performance. ✓ Temporal structure clarified using lag features and walk-forward validation.	Will finalize and document SHAP/LOFO analysis to reinforce model transparency.
Model Evaluation • MAE alone is insufficient; missing rationale. • Needed comparison to traditional regressors.	✓ Added MAE, RMSE, MAPE, R^2 , and MAPA.⚠ Traditional regressors referenced but not fully described.	I will explicitly name and briefly compare traditional methods (e.g., ARIMA, Linear Regression) in the evaluation or discussion section.
Interpretability vs Accuracy • Why is	✓ Clarified that the audience includes public sector	I will add one sentence explicitly connecting

interpretability important?• Who is the audience?	stakeholders.✓ XGBoost selected for interpretability; SHAP/LOFO planned.	interpretability to policymaker usability in the discussion section.
Qualitative Analysis• Is this included? Will you reflect on why certain features matter?	△ Partially addressed. Mentioned in results section planning.	I plan to add a brief qualitative reflection in the discussion on the policy implications of top predictive features.
Structure, Clarity & Redundancy• Redundancies and vague sentences need improvement.	△ Still in progress.	I will revise for conciseness, remove repeated references to car brand keywords, and improve clarity sentence-by-sentence this week.

3 Email and keywords:



Online appendices

Appendix A: List of keywords used for the Google Trends indicators.

Electric vehicles

Accessible chargers, accessible charging, accessible fast chargers, alternative fuels, alternative fuels infrastructure, battery electric vehicle, battery electric vehicles, battery electric vehicles and plug-in hybrid electric vehicles, battery swapping, cell electric vehicles, charging infrastructure, charging network, charging point, charging points., charging stations, demand for electric vehicles, deployment of electric cars, deployment of electric vehicles, electric bus electric buses, electric car, electric car market, electric car models, electric car purchase price, electric car sales, electric car stock, electric cars, electric cars subsidies, electric driving,, electric light duty, electric light-commercial vehicle, electric light-duty vehicle, electric lightduty vehicles, electric mobility, electric truck, electric trucks, electric two wheelers, electric vehicle, electric vehicle , electric vehicle adoption, electric vehicle batteries, electric vehicle battery, electric vehicle charging, electric vehicle charging infrastructure, electric vehicle deployment, electric vehicle fleet, electric vehicle initiative, electric vehicle initiative countries, electric vehicle market, electric vehicle markets, electric vehicle models, electric vehicle outlook, electric vehicle purchase price, electric vehicle sales, electric vehicle sales shares, electric vehicle supply, electric vehicle supply equipment, electric vehicle supply, equipment deployment, electric vehicle supply equipment outlets, electric vehicle uptake, electric vehicle volumes, electric vehicles, electric vehicles data, electric vehicles initiative, electric vehicles subsidies, emission vehicles, financial incentives electric cars, financial incentives electric vehicles, fuel cell electric car, fuel cell electric vehicle, , global electric vehicle, global electric vehicle fleet, global electric vehicles data, home charging, hybrid electric, hybrid electric vehicles, internal combustion engine cars, internal combustion engine vehicle, internal combustion engine vehicles, light-duty vehicle chargers, light-duty vehicle sales, new energy vehicles, number of electric cars, number of electric vehicles, plug in hybrid, plug-in hybrid electric vehicle, plug-in hybrid electric vehicle , plug-in hybrid electric vehicles, private chargers, private charging, public chargers, public charging, publicly accessible chargers, publicly accessible charging, purchase incentives electric cars, purchase incentives electric vehicles, purchase of electric cars, purchase of electric vehicles, purchase price electric car, purchase price of electric vehicle, purchase subsidies electric cars, purchase subsidies electric vehicles, sales share of electric cars, sales share of electric vehicles, share of electric cars, share of electric vehicles, smart charging, stock of electric cars, stock of electric vehicles, transition to electric, uptake of electric cars, uptake of electric vehicles, vehicle charging, vehicle electrification, zero emission vehicle, zero emission vehicles.

Digitalization

Smart Manufacturing

3D printing, Additive Manufacturing, Computer Numerical Control, Layered Manufacturing,

Additive Fabrication, Rapid Prototyping, Direct Digital Manufacturing, Advanced Manufacturing, Collaborative Robotics, Robot Automation, Cobot, Cyber-Physical System, Augmented Reality, Computer Vision, Artificial Reality, Application Architecture, Application Programming Interface, Artificial Intelligence, Asset Administration shell, Batch Size, Big Data Analytics, Blockchain, Bluetooth Low Energy, Cloud Computing, Cloud Robotics, Cyber-Physical System, Cyber-Physical Production Systems, Data Analyst, Data Architecture, Deep Learning, Descriptive Analytics, Digital Enterprise, Digital Supply Chain, Digital Twin, Edge Computing and Gateway, Enterprise Resource Planning, ERP system, ERP software, Customer relationship management, CRM, Extensible Markup Language, Flexible Manufacturing, Fog Computing, Apache Hadoop, SAP HANA, Human-Machine Interface, Industrial Internet Consortium, Industrial Internet of Things, Industrial Internet Reference Architecture, Industry 4.0, Machine to Machine Communication, Machine Learning, Manufacturing Execution System, Open System Interconnection Model, OPC Unified Architecture, Operational Technology, Predictive Maintenance, Production analytics software, Programmable Logic Controller, RAMI 4.0, Risk-based Planning & Scheduling, Remote Maintenance, SCADA, Supervisory Control and Data Acquisition, Social Mobile Analytics Cloud, Smart Factory, Virtual Reality, ZigBee, Fideltronik, Semeq, SMARTECH, WorkClout,

Bosch Rexroth AG, DXC Technology, Honeywell Industry, Honeywell Manufacturing,

Parsable, Rockwell Automation, SICK AG, Siemens PLMc, Autodesk, Autocad, Industry 4.0 Solutions SAP, Industrial Internet of Things SAP, Dassault Systemes, Epicor, Fishbowl Inventory, Infor, Thrive software, NetSuite.

Smart city

Autonomous vehicles, real time traffic data, smart traffic management, smart traffic control, smart traffic system, real time pollution data, real time energy data, City-as-a-Service, Hyperlocal data, Smart waste, smart street lighting, smart bins, smart drains, smart grid, Smart infrastructure, smart parking, Traffic adaptive lighting, Ubiquitous city, smart city applications, Urban data platform, smart buildings, Gunshot Detection Technology, City Transit Applications.

Smart Appliances

Smart plug, Amazon Alexa, Samsung Smart Home, Samsung SmartThings, SmartRules, Google Home, Apple Home, Danalock, MyQ, Ecobee, Honeywell Home, Honeywell Total

Connect, Philips Hue, Wemo, Yale Connect, Insteon, Senti all in one, Wink Hub, Alarm.com.

Communication

Skype, Microsoft Teams, Zoom, WhatsApp, whatsapp messenger, facebook messenger, msn messenger, facetime, instant messaging, messaging app, delete message, unsend, gmail, Hotmail.

Social Media

Myspace, friendster, facebook, instagram, tumblr, pinterest, tweeter, snapchat, friending, unfriend, share photo, share post, posted, user profile, untag, tweet, posting, hashtag, instagram like, likes, shares, follower, followers, unfollow, profile pic, cover pic.

Appendix B: Comparing Google Trends data with Eurostat data on the diffusion of EVs in European countries.

Figure B1: Google Trends indicator of EVs adoption (left-axis) and Eurostat indicator on the share of EVs in each country (right-axis).

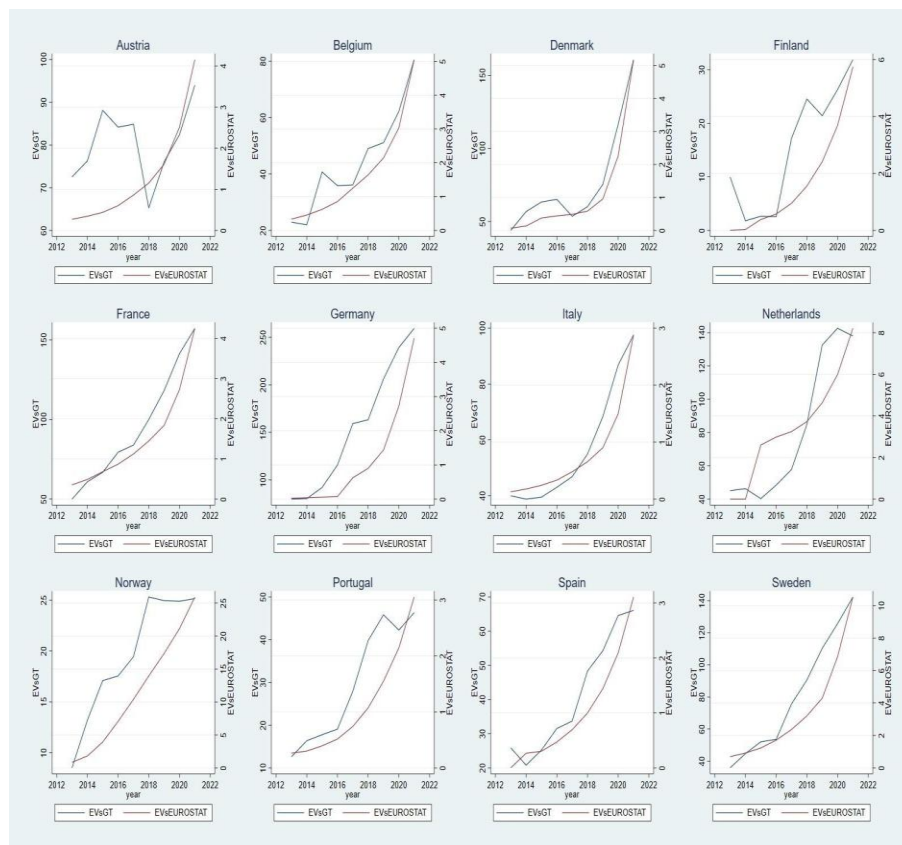



Figure B2: Google Trends indicator of EVs adoption and Eurostat indicator on the share of EVs in each country (Y-axis), both standardized using the same method.



4 Prompt used for translating the Key words from Dutch to English:

translate this to dutch: Accessible chargers, accessible charging, accessible fast chargers, alternative fuels, alternative fuels infrastructure, battery electric vehicle, battery electric vehicles, battery electric vehicles and plug-in hybrid electric vehicles, battery swapping, cell electric vehicles, charging infrastructure, charging network, charging point, charging points., charging stations, demand for electric vehicles, deployment of electric cars, deployment of electric vehicles, electric bus electric buses, electric car, electric car market, electric car models, electric car purchase price, electric car sales, electric car stock, electric cars, electric cars subsidies, electric driving,, electric light duty, electric light-commercial vehicle, electric light-duty vehicle, electric light duty vehicles, electric mobility, electric truck, electric trucks, electric two wheelers, electric vehicle, electric vehicle , electric vehicle adoption, electric vehicle batteries, electric vehicle battery, electric vehicle charging, electric vehicle charging infrastructure, electric vehicle deployment, electric vehicle fleet, electric vehicle initiative, electric vehicle initiative countries, electric vehicle market, electric vehicle markets, electric vehicle models, electric vehicle outlook, electric vehicle purchase price, electric vehicle sales, electric vehicle sales shares, electric vehicle supply, electric vehicle supply equipment, electric vehicle supply, equipment deployment, electric vehicle supply equipment outlets, electric vehicle uptake, electric vehicle volumes, electric vehicles, electric vehicles data, electric vehicles initiative, electric vehicles subsidies, emission vehicles, financial incentives electric cars, financial incentives electric vehicles, fuel cell electric car, fuel cell electric vehicle, , global electric vehicle, global electric vehicle fleet, global electric vehicles data, home charging, hybrid electric, hybrid electric vehicles, internal combustion engine cars, internal combustion engine vehicle, internal combustion engine vehicles, light-duty vehicle chargers, light-duty vehicle sales, new energy vehicles, number of electric cars, number of electric vehicles, plug in hybrid, plug-in hybrid electric vehicle, plug-in hybrid electric vehicle , plug-in hybrid electric vehicles, private chargers, private charging, public chargers, public charging, publicly accessible chargers, publicly accessible charging, purchase incentives electric cars, purchase incentives electric vehicles, purchase of electric cars, purchase of electric vehicles, purchase price electric car, purchase price of electric vehicle, purchase subsidies electric cars, purchase subsidies electric vehicles, sales share of electric cars, sales share of electric vehicles, share of electric cars, share of electric vehicles, smart charging, stock of electric cars, stock of electric vehicles, transition to electric, uptake of electric cars, uptake of electric vehicles, vehicle charging, vehicle electrification, zero emission vehicle, zero emission vehicles.

ChatGPT zei:

Here is the Dutch translation of your list:

Toegankelijke laders, toegankelijk laden, toegankelijke snelladers, alternatieve brandstoffen, infrastructuur voor alternatieve brandstoffen, batterij-elektrisch voertuig, batterij-elektrische voertuigen, batterij-elektrische voertuigen en plug-in hybride elektrische voertuigen,

batterijwisselsystemen, elektrische voertuigen op celbasis, laadinfrastructuur, laadnetwerk, laadpunt, laadpunten, laadstations, vraag naar elektrische voertuigen, uitrol van elektrische auto's, uitrol van elektrische voertuigen, elektrische bus, elektrische bussen, elektrische auto, markt voor elektrische auto's, modellen van elektrische auto's, aankoopprijs van elektrische auto's, verkoop van elektrische auto's, voorraad van elektrische auto's, elektrische auto's, subsidies voor elektrische auto's, elektrisch rijden, elektrische lichte bedrijfsvoertuigen, elektrische lichte bedrijfswagens, elektrische lichte voertuigen, elektrische mobiliteit, elektrische vrachtwagen, elektrische vrachtwagens, elektrische tweewielers, elektrisch voertuig, elektrisch voertuig, adoptie van elektrische voertuigen, batterijen voor elektrische voertuigen, batterij voor elektrisch voertuig, opladen van elektrische voertuigen, laadinfrastructuur voor elektrische voertuigen, uitrol van elektrische voertuigen, wagenpark van elektrische voertuigen, initiatief voor elektrische voertuigen, landen binnen het initiatief voor elektrische voertuigen, markt voor elektrische voertuigen, markten voor elektrische voertuigen, modellen van elektrische voertuigen, vooruitzichten voor elektrische voertuigen, aankoopprijs van elektrisch voertuig, verkoop van elektrische voertuigen, marktaandeel van elektrische voertuigen, aanbod van elektrische voertuigen, laadapparatuur voor elektrische voertuigen, uitrol van laadapparatuur voor elektrische voertuigen, laadpunten van laadapparatuur voor elektrische voertuigen, groei van elektrische voertuigen, aantallen elektrische voertuigen, elektrische voertuigen, data over elektrische voertuigen, initiatief voor elektrische voertuigen, subsidies voor elektrische voertuigen, voertuigen met uitstoot, financiële prikkels voor elektrische auto's, financiële prikkels voor elektrische voertuigen, waterstofcel-elektrische auto, waterstofcel-elektrisch voertuig, wereldwijde elektrische voertuigen, wereldwijd wagenpark van elektrische voertuigen, wereldwijde data over elektrische voertuigen, thuis opladen, hybride elektrisch, hybride elektrische voertuigen, auto's met verbrandingsmotor, voertuig met verbrandingsmotor, voertuigen met verbrandingsmotor, laders voor lichte voertuigen, verkoop van lichte voertuigen, nieuwe energievoertuigen, aantal elektrische auto's, aantal elektrische voertuigen, plug-in hybride, plug-in hybride elektrisch voertuig, plug-in hybride elektrisch voertuig, plug-in hybride elektrische voertuigen, privé laders, privé laden, publieke laders, publiek laden, publiek toegankelijke laders, publiek toegankelijke laadmogelijkheden, aankoopstimulansen voor elektrische auto's, aankoopstimulansen voor elektrische voertuigen, aankoop van elektrische auto's, aankoop van elektrische voertuigen, aankoopprijs elektrische auto, aankoopprijs van elektrisch voertuig, aankoopsubsidies voor elektrische auto's, aankoopsubsidies voor elektrische voertuigen, verkoopaandeel van elektrische auto's, verkoopaandeel van elektrische voertuigen, aandeel elektrische auto's, aandeel elektrische voertuigen, slim laden, voorraad van elektrische auto's, voorraad van elektrische voertuigen, transitie naar elektrisch, acceptatie van elektrische auto's, acceptatie van elektrische voertuigen, opladen van voertuigen, elektrificatie van voertuigen, nul-emissie voertuig, nul-emissie voertuigen.

4.1 Python script for google trends url

```
base_url = "https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q="
urls = [base_url + quote(k) for k in keywords]

# Combine all URLs into a single JavaScript array for pasting in browser
# console or bookmarklet
js_array = "const urls = [\n" + ",\n".join([f'"{url}"' for url in urls]) +
"\n];"
js_array = js_array + "\nurls.forEach((url, i) => setTimeout(() =>
window.open(url, '_blank'), i * 1000));"

# Output JS-ready array of URLs
js_array[:1000] # display only the first 1000 characters for brevity here

for url in urls:
    webbrowser.open_new_tab(url)
```

5 Dataset documentation

5.1 Consumer Confidence, Economic Climate, and Willingness to Buy (CBS, 2007–2025)

[Source: Statistics Netherlands \(Centraal Bureau voor de Statistiek – CBS\)](#)

Consumer Confidence, Economic Climate, and Willingness to Buy (CBS, 2015–2025)

Dataset code: 83693NED

Coverage period: April 1986 – Present

Source: Statistics Netherlands (Centraal Bureau voor de Statistiek – CBS)

Content and Scope

This dataset contains monthly, seasonally adjusted indicators of consumer sentiment in the Netherlands, collected through the *Consumenten Conjunctuuronderzoek* (Consumer Confidence Survey), continuously conducted since 1972 by CBS and co-financed by the European Commission.

The dataset includes four main indicators:

- **Consumer Confidence**– A composite index reflecting consumer perceptions of both the national economy and their own financial situation.
- **Economic Climate**– A perception index focused on the past and expected economic situation in the Netherlands.
- **Willingness to Buy** – A seasonally adjusted index measuring consumers' inclination to make major purchases.

- **Koopbereidheid** – The original, unadjusted series reflecting the same underlying sentiment.

Koopbereidheid Indicator (Explanation)

The **Koopbereidheid** indicator reflects consumer attitudes toward their own financial situation and major spending decisions. It is particularly relevant for understanding short-term fluctuations in household consumption, especially in durable goods purchases. It is calculated as the average of three balances (positive minus negative responses) to questions about:

1. Financial situation over the past 12 months
2. Expected financial situation over the next 12 months
3. Whether it is a good time to make large purchases

The indicator ranges from **-100** (all respondents negative) to **+100** (all positive), with **0** indicating a neutral stance (equal pessimists and optimists). Both the adjusted (*Koopbereidheid_3*) and raw (*Koopbereidheid*) series are available in the dataset.

Method of Data Collection

Data is obtained from monthly surveys of a geographically stratified, demographically representative sample of Dutch residents, selected from the *Basisregistratie Personen* (BRP). Survey questions cover economic expectations, personal financial conditions, and attitudes toward large purchases.

All series are seasonally adjusted using full-series time series models. CBS applies standard statistical correction procedures; no additional post-processing is performed. Figures are provisional upon initial publication and finalized after annual revisions. The survey is EU-harmonized to support cross-country comparisons and policy use.

Data Availability and Status

- **Period covered:** January 2007 – January 2025
- **Frequency:** Monthly (updated around the 22nd of each month)
- **Final data:** Up to December 2023
- **Provisional data:** 2024–2025
- **Included variables:** Date, Consumentenvertrouwen_1, Koopbereidheid_3 (adjusted), EconomischKlimaat_2, Koopbereidheid (raw)

Values range from -100 (all respondents negative) to +100 (all positive), with 0 indicating a neutral stance. All series are seasonally adjusted using full-series time series models.

Method of Data Collection

The data is obtained from monthly surveys of randomly selected Dutch residents, drawn from the *Basisregistratie Personen* (BRP). Questions cover economic expectations, financial health, and willingness to make large purchases. The sample is geographically stratified and

demographically representative. All data are statistically corrected for sampling variability and seasonally adjusted.

No additional post-processing is applied beyond CBS's standard correction procedures. Provisional figures are later finalized after annual revisions. The survey is harmonized across the EU to allow cross-country comparisons, and the results are used by both CBS and the European Commission for economic monitoring (CBS, n.d.).

Data Availability and Status

- Period covered: January 2007 – January 2025
- Monthly frequency, updated around the 22nd of each month
- Final data available up to December 2023; 2024–2025 figures are provisional
- Includes: Date, Consumentenvertrouwen_1, Koopbereidheid_3, EconomischKlimaat_2
Koopbereidheid

5.2 Fuel Pump Prices per Day 2007-2025

Dataset code: 80416NED

Source: [Statistics Netherlands \(Centraal Bureau voor de Statistiek – CBS\)](#)

Coverage period: January 1, 2006 – April 7, 2025

Update frequency: Weekly

Content and Scope

This dataset contains daily pump prices for motor fuels in the Netherlands. The data includes weighted average daily prices (including VAT and excise duties) for:

- Euro95 Petrol
- Diesel
- LPG

Although the dataset records daily values, these prices are published once per week.

Data Availability

- Available from January 1, 2006 – present
- The dataset includes 7037 rows and 4 columns as of the most recent update.

Data Status

- All published prices are final upon release.
- No provisional figures are used.

Update Schedule

Daily fuel prices (up to and including Monday) are typically published on the following Thursday. If publication on Thursday is delayed due to holidays or other circumstances, the data is released on the next working day.

Method of Data Collection

The statistics are based on daily transaction-level data from approximately 3,800 fuel stations and a substantial portion of electric charging stations across the Netherlands. This data is provided to CBS by Travelcard BV, a commercial provider of fuel payment services. Each transaction reflects actual consumer purchases and includes timestamped price data.

The dataset uses a stratified weighting system to compute average prices. Fuel stations are categorized by fuel type and electric charging form, with each group assigned a fixed annual weight reflecting consumer fueling behavior. The weights are updated annually using external data sources.

CBS performs internal quality controls by checking for completeness, plausibility, and consistency. Missing or suspect data points are addressed through follow-up verification or imputation, ensuring that price estimates reflect realistic market conditions (CBS, 2023).

5.3 Registrations by Fuel Type and Vehicle Category – Netherlands (2007–2025)

Dataset code: 71107NED

Source: [Statistics Netherlands \(Centraal Bureau voor de Statistiek – CBS\)](#)

Coverage period: 2007 – present

Content and Scope

This dataset contains quarterly and monthly counts of newly registered and second-hand vehicles in the Netherlands, broken down by vehicle category and fuel type. Vehicle categories include passenger cars, vans, trucks, buses, tractors, motorcycles, mopeds, and special vehicles. Data on trailers and semi-trailers is excluded.

This research focuses exclusively on fully electric passenger cars (Battery Electric Vehicles – BEVs). These vehicles are powered solely by an electric motor and a large battery pack, with no internal combustion engine.

Data is available from 2007 onward and includes both new and used vehicle registrations. Registrations are classified by:

- Vehicle type (e.g., passenger car, van, motorcycle)
- Fuel type (e.g., petrol, diesel, LPG, hybrid, electric)

Method of Data Collection

The data originates from monthly reports by **RDC** (RDC Nederland BV), which collects and validates vehicle registration information based on the official Dutch vehicle registry. The dataset distinguishes between new and second-hand vehicle registrations and applies corrections based on improvements in RDC's data sources (notably from 2007 onward).

CBS processes and publishes these figures quarterly, with new figures typically released within three months after the end of each quarter. Data prior to 2022 is final; more recent figures are provisional and subject to revision.

Vehicles are categorized using standardized definitions, such as:

- **Passenger Car:** Road motor vehicle with up to nine seats
- **Full Electric (BEV):** Battery-powered electric vehicle with no combustion engine

No post-sampling adjustments are applied beyond RDC's and CBS's regular consistency and classification checks.

NOS News Articles – Netherlands (2015–2025) (Not used)

Dataset code: NOS-NEWS-2015-2025-FEATHER

Source: [Kaggle \(uploaded by John Boulard\)](#)

Content and Scope

This dataset contains news articles published on the Dutch national broadcaster’s website, NOS.nl, between **January 1, 2015**, and **March 31, 2025**. It includes full-text content along with metadata such as publication time, article type, and topical section. The dataset is designed to support research in **media analysis, sentiment tracking, topic modeling, and temporal analysis of Dutch news**.

The full text of each article is stored with preserved HTML structure, allowing for structural parsing and feature extraction (e.g., headlines, quotes, embedded tweets, and article sections).

Method of Data Collection

The articles were scraped directly from the NOS.nl website using automated extraction tools. Only minimal post-processing was applied: unnecessary HTML elements were removed, and embedded tweets were reformatted to support easier identification. The dataset is unannotated and retains some inconsistencies or missing fields, reflecting the natural variability of the source website.

The dataset is stored in **Feather format (.feather)**, which enables fast reading and writing in data processing environments such as Python and R.

Data Availability and Status

- **Coverage period:** January 1, 2015 – March 31, 2025
- **Format:** Feather (.feather)
- **Data status:** Raw scraped text with minor cleaning; no annotations applied
- **Download location:** [Kaggle – NOS News Articles Dataset](#)

6 Model Selection Rationale

Featured in github here: [Modelvergelijking.ipynb](#)

Model	RMSE	MAE	R ²	MAPE	Opmerking
Prophet	11522.58	9279.27	-4.6566	27.28%	Slecht op alle metrics
Holt-Winters	1427.03	1140.87	-4.8417	20.63%	Verrassend stabiel
SARIMAX	4776.29	4161.23	-1.5153	18.37%	Redelijk, maar traag
SARIMA	4589.61	3732.98	-2.1472	16.11%	Beste klassieke model
XGBoost	6109.53	5328.81	-4.4232	20.61%	Niet goed ondanks tuning
LightGBM	4285.06	3235.11	-1.5048	38.51%	Matig, hoge MAPE

LSTM	5262.84	4533.36	-4.9191	18.29%	Matige resultaten
TFT	8099.60	7017.87	-1.7950	20.87%	Niet indrukwekkend
GRU					Werkt niet

7 Daily brain dump

7.1 23/05 70%

Feedback verwerking, evaluatie invullen

7.2 22/05

bijtelling is not a subsidy in the traditional sense. It is a tax incentive

7.3 21/05

Feedback verwerking

7.4 20/05

Feedback verwerking

7.4.1 Todolist:

- Requirements baseren op field research
- Verschilwe
- Add sources to formulas

Meeting with Kees

Attendees: Dylan Haazelager, Kees

Duration: approx. 45 minutes

Next meeting: Friday 09:00

Discussion Summary:

1. Research Changes

- We started by discussing the recent changes I made to my research, as outlined in earlier emails. The most notable change is the shift from news sentiment analysis to using Google Trends data as an indicator of consumer interest in electric vehicles (EVs).
- Kees immediately asked what exactly had changed as a result, and how my research differs from previous studies. I proposed that we go through the paper together.

2. Problem Definition and Scope

- Kees asked what the core problem of my research was. I admitted I struggled a bit to articulate it clearly, but explained it as follows:

NGOs and governmental organizations currently lack reliable forecasting models for predicting EV sales. Since electric vehicles are key to achieving zero-emission targets in the transport

sector, having accurate forecasts is critical. My study explores whether open data sources like Google Trends can improve forecast accuracy beyond traditional historical sales data.

3. Research Gap Compared to Existing Studies

- Kees then asked about the research gap: what am I doing that hasn't been done before? I explained that my work is distinct in several ways:
 1. I focus specifically on the Dutch car market, which has been understudied.
 2. I use general EV-related keywords, whereas many studies focus on brand- or model-specific terms.
 3. My dataset spans a long time period (2007–2025), while others often cover a limited window.
 4. I include microeconomic indicators and other public data sources that are often overlooked.

4. Feedback on Results and Analysis

- We went through the results section together. Kees suggested adding a graph where I use 'common sense reasoning' to explain peaks and dips in EV sales.
- He also recommended running the model on each individual feature (Leave-One-Feature-Out analysis) and including those results in the report. Additionally, he advised integrating SHAP values to provide interpretability of the model's decisions.

5. Additional Suggestions

- Kees mentioned that the list of requirements seemed well-founded and intuitive but encouraged me to review them again critically to ensure they are sharp and well-supported.
- Finally, he pointed out that EV purchases typically respond with a delay to external factors. He advised adding a lag structure to the EV sales data to explore how many months of lag produce the best results.

Action Points:

- Add a graph to explain peaks/dips in sales using common sense reasoning.
- Run the model with Leave-One-Feature-Out and include it in the report.
- Integrate SHAP value analysis.
- Review the requirements critically for clarity and justification.
- Add lagged EV sales variables and test different lag lengths.
- Await written feedback from Kees after he reads the full paper later today.

7.5 19/05

Rest day

7.6 Zo18/05

Alles/leerdoelen check, (resultaten,data) Draft opsturen

"The model should serve as an exploratory benchmark for assessing the added value of behavioral and policy features beyond traditional univariate approaches."

7.7 Za 17/05

Model testing

Model	RMSE	MAE	R ²	MAPE	Opmerking
Prophet	11522.58	9279.27	-4.6566	27.28%	Slecht op alle metrics
Holt-Winters	1427.03	1140.87	-4.8417	20.63%	Verrassend stabiel
SARIMAX	4776.29	4161.23	-1.5153	18.37%	Redelijk, maar traag
SARIMA	4589.61	3732.98	-2.1472	16.11%	Beste klassieke model
XGBoost	6109.53	5328.81	-4.4232	20.61%	Niet goed ondanks tuning
LightGBM	4285.06	3235.11	-1.5048	38.51%	Matig, hoge MAPE
LSTM	5262.84	4533.36	-4.9191	18.29%	Matige resultaten
TFT	8099.60	7017.87	-1.7950	20.87%	Niet indrukwekkend
GRU					Werkt niet

Model exploration

Model	Type & benadering	Exogene input	Interpretatie	Datavereisten	Typische prestaties & toepassingsgebied
SARIMA (Seasonal ARIMA)	Statistisch tijdreeksmodel (lineair; met seizoenscomponenten).	Nee (univariate; exogene alleen via SARIMAX variant).	Hoog – Parameters (AR, MA) relatief begrijpelijk; inzicht in trend/seizoen.	Vereist voldoende historische data (≥2 seizoenscycli); maandelijke frequentie mogelijk.	Sterk bij duidelijke seizoenspatronen en lineaire trends; goede baseline-prestaties voor stabiele reeksen.

SARIMA X (ARIMA met exo)	Statistisch tijdreeksmodel met exogene regressors.	Ja (lineaire invloed van exogene variabelen).	Hoog – vergelijkbaar met SARIMA; coef. van exogene geven effectschatting.	Zoals SARIMA, maar extra data voor alle exogene features; stabiele relaties vergen langere reeks.	Geschikt als bekende externe factoren belangrijke invloed hebben; behoudt SARIMA-prestaties bij lineaire relaties.
Holt-Winters (ETS)	Exponentiële gladstrijking (trend + seizoen; additive of multiplicative).	Nee (univariate).	Hoog – eenvoudige componenten (niveau, trend, seizoen).	Korte tot middellange reeksen volstaan (≥ 2 seizoenscycli); maand/kwartaal data.	Robuust voor eenvoudige patronen met geleidelijke trends; vaak vergelijkbaar of iets minder nauwkeurig dan ARIMA bij lineaire groei.
Prophet (Facebook)	Additief model (trend + seizoen + feestdagen; met Bayesian fitting).	Optioneel (feestdagen/events als dummy's of regressors).	Redelijk – biedt componenteninspectie (trend, seizoen, events).	Werkt goed met ontbreken de data en outliers; vereist historiek met meerdere jaren voor jaarseizoen.	Ideaal bij sterke seizoenen en bekende events (vakanties, beleid); gebruiksvriendelijk, maar presteert matig bij grillige patronen.
Random Forest	Machine learning beslissingsbomen-ensemble.	Ja (meerdere features/lagvariabelen mogelijk).	Middel – enige inzicht via feature importance; geen expliciete tijdscomponenten.	Veel data helpt (meerdere jaren, of hoge frequentie); vereist feature-engineering (lags,	Krachtig voor complexe, niet-lineaire relaties; robuust tegen overfit bij voldoende data; goede prestaties in diverse

					kalender).	domeinen (retail, energie).
XGBoost (Gradient Boosting)	Geavanceerd boomgebaseerd ML-model (boosting).	Ja (multivariate input mogelijk).	Middel – feature importance en SHAP values geven enige interpretatie.	Vereist voldoende data met relevante kenmerken ; snelle training zelfs met veel features.	Zeer hoge voorspelkracht bij goed afgestemde hyperparameters; vaak top-prestaties in forecasting-wedstrijden; efficiënt en schaalbaar.	
LightGBM	Gradient boosting machine (snelle variant).	Ja.	Middel – vergelijkbaar met XGBoost qua interpretatie.	Kan grote datasets aan; minder rekenintensief, dus bruikbaar voor hoge frequenties of veel series tegelijk.	Prestaties vergelijkbaar met XGBoost; praktisch voor industriële toepassingen met veel modellen (snelle iteratie, schaalbaar).	
LSTM (RNN variant)	Deep learning recurrent netwerk (onthoudt volgorde-info).	Ja (multivariate tijdreeks mogelijk).	Laag – “black box”; moeilijk te doorgronden, hoewel patroonherkenn ing intern plaatsvindt.	Vereist grote dataset of vele epochs training; profiteert van hoge frequentie of vele parallelle series; gevoelig voor overfitting bij <100 datapunte	Sterk in het leren van complexe sequentiële patronen (lange termijn afhankelijkheden); heeft bewezen zeer hoge nauwkeurigheid als genoeg data beschikbaar is.	

					n.	
	GRU (RNN variant)	Vereenvoudigde LSTM (minder parameters).	Ja.	Laag – vergelijkbaar met LSTM (black box).	Iets minder data-hongerig dan LSTM door eenvoud; snellere training.	Presteert vaak gelijkwaardig aan LSTM, soms beter op kleinere datasets, met kortere trainings- en rekentijd.
	TFT (Temporal Fusion Transformer)	Geavanceerd attentie-gebaseerd deep learning model.	Ja (ontworpen voor veel covariaten, incl. statische en bekende toekomstige).	Middel – complexe, maar <i>interpreteerbaar via attentie-visualisaties</i> (belang van features/tijdstippen).	Zeer veel data-aanbevolen (veel series of hoge freq); hoge rekeneisen en tuning-complexiteit.	State-of-the-art prestaties bij multivariate <i>multi-horizon</i> forecasts; combineert voordelen van klassieke en ML-modellen (accuratesse én inzicht), mits voldoende data en rekenkracht.

Model	R ² (gemiddeld)	Opmerkingen
SARIMA	+0.72	Werkt goed met alleen autoregressie
SARIMAX	-1.51	Slechter door zwakke exogene signalen
XGBoost	-8.15 tot -0.96	Faalt ondanks gridsearch, waarschijnlijk overfitting of slechte features

Modeltype	Doel	Geschikt?
SARIMA	Alleen historische verkoopdata gebruiken	baseline model

SARIMAX	Verkoop + externe indicatoren (zoals trends)	lineair, beperkt bij veel features
XGBoost	Voorspellen op basis van ALLE features	krachtig, geschikt voor dataset
LSTM/NN	Eventueel als bonus of vervolgonderzoek	complexer, veel tuning nodig

Alles/leerdoelen check, (resultaten,data)

Haha eigenlijk nog niks echt verbeterd, kijk ff wat grid search doet, en anders gewoon methode verder schrijven en verder gaan aan inleiding

7.8 16/05 70% Inleveren

Methode, probleemstelling inleiding

Probleem: r2 geeft aan dat MEAN BETER IS

Sarima results:

3 FOLD → 5 FOLD IETS BETERE RESULTATEN

Forecast Horizon	Average RMSE	Average MAE	Average MAPE (%)	Average R ²
3 months	2064.10	1918.53	10.08	0.4713
6 months	4589.61	3732.98	16.11	-2.1472
9 months	4646.68	3877.59	16.79	-1.8959
12 months	5314.93	4301.40	18.54	-1.8107

Hoewel de prestaties van het model voor korte termijn voorspellingen (3 maanden) redelijk zijn ($R^2 = 0.47$), blijkt uit de resultaten dat de voorspellende kracht aanzienlijk afneemt bij langere forecast horizons van 6 tot 9 maanden. Bij deze langere periodes is de R^2 zelfs negatief, wat aangeeft dat het model slechter presteert dan een eenvoudige voorspelling op basis van het gemiddelde.

Dit betekent echter niet dat het onderzoek is mislukt. De centrale onderzoeksvraag ("To what extent can macroeconomic indicators, media, and digital trends predict EV sales?") blijft geldig. De resultaten geven aan dat deze externe indicatoren een zekere voorspellende waarde hebben op korte termijn, maar minder geschikt zijn voor robuuste langetermijnvoorspellingen.

Deze bevinding onderstreept de complexiteit van het voorspellen van EV-verkoop, en laat zien dat factoren zoals seizoensinvloeden, beleidswijzigingen en externe marktontwikkelingen mogelijk een grotere rol spelen dan met de huidige set macro-economische en digitale indicatoren kan worden opgevangen.

Verder vormt het negatieve resultaat bij lange forecast horizons ook een relevante bijdrage: het toont aan waar de grenzen liggen van lineaire tijdreeksvoorspellingen met deze feature set. Dit biedt richting voor vervolgonderzoek, bijvoorbeeld naar het toevoegen van exogene variabelen, het inzetten van niet-lineaire modellen, of het verfijnen van de forecast horizon.

7.8.1.1 Vragen die in me op komen tijdens het schrijven:

- Check cbs, overweeg toch wel 2^e hands autos te doen, waarom niet?
- Check of je dingen op git op verberen kan zetten
- Hoe zit het met de Requirements waarop zijn ze opgesteld

7.8.1.1.1 Corrolatie keywords is gedaan op oude trainset!! Wijzigen naar vokedige set, of ?

7.8.1.1.2 Handmatig data van Bijtelling meenemen!

Verder gaan met requierments en dan methode/resultaten. Daarna weer terug naar existing work, AIDA helemaal weghalen heeft 0 relevantie

7.9 15/05

Check spelling, bronverwijzingen, consistentie, en formatteer alles volgens de eisen van je opleiding.

Voorbeeld van blok 1&2 project

Project 2:

- Alle A leerdoelen zijn op niveau voor
- B1 requirements zijn op niveau
- Dataset alleen onder, vanwege kleine set, ik kan dat benoemen

7.9.1.1 Indeling logboek

- Ai patterns, Level of automation
- Value proposition → stakeholder alignemnt
- Full moscow?
- Sketch → check dat dashboard A leerdloene allemaal voldoende in blok 2
- Keyword search methode
- B1 requirments zijn op v
- Eventueel bijlage met mailnaar ...
- Code snippet of corrolation keywords
-

7.9.1.2 Overzicht peer reviewed papers:

Source File Name	APA-Style Reference (Based on excerpt information)	Supporting Excerpts for Classification & Reference Info
A PREDICTION MODEL FOR AUTOMOBILE SALES IN TURKEY USING DEEP NEURAL networks.pdf	Kayapınar Kaya, S., & Yıldırım, Ö. (2020). A prediction model for automobile sales in Turkey using deep neural networks. <i>Journal of Industrial Engineering</i> , 31(1), 57-74.1	Format and references to academic journals indicate peer review. Journal name, volume, issue, and pages

		provided ¹ .
Advances in consumer electric vehicle adoption research A review and research agenda.pdf	Rezvani, Z., Jansson, J., & Bodin, J. (2015). Advances in consumer electric vehicle adoption research: A review and research agenda. <i>Transportation Research Part D: Transport and Environment</i> , 34, 122–136.2	Explicitly states it is a literature review in <i>Transportation Research Part D</i> 2..., a peer-reviewed journal.
Castellacci and Santoalha - 2025 - Does digitalisation affect the adoption of electric vehicles New regional-level evidence from Googl.pdf	Castellacci, F., & Santoalha, A. (2025). Does digitalisation affect the adoption of electric vehicles? New regional-level evidence from Google Trends. (Journal details not fully specified in excerpt).4...	Authors explicitly thank the journal editor and anonymous reviewers ⁴ , confirming peer review. Authors listed ⁵ .
Economic, Functional, and Social Factors Influencing Electric Vehicles' Adoption.pdf	(Authors not provided in excerpt). (2022). Economic, Functional, and Social Factors Influencing Electric Vehicles' Adoption. <i>Sustainability</i> , 14, 6283.6	Published in the journal <i>Sustainability</i> ⁶ . Authors thank anonymous reviewers ⁷ , confirming peer review.
Factors affecting adoption of electric vehicles in India.pdf	Chhikara, R., Gupta, S. K., & Sharma, C. (Year not provided in excerpt). Factors affecting adoption of electric vehicles in India. <i>Transportation Research Part D: Transport and Environment</i> . (Volume, issue, and pages not provided in excerpt).8...	Published in <i>Transportation Research Part D</i> 9, a known peer-reviewed journal. Authors provided ⁸ .
ForeXGBoost passenger car sales prediction based on XGBoost.pdf	Zhenchang, X., Xue, S., et al. (2020). ForeXGBoost: passenger car sales prediction based on XGBoost. <i>Distributed and Parallel Databases</i> . (Full author list, volume, issue, and pages not provided in excerpt). https://doi.org/10.1007/s10619-	Described as an "Article in Distributed and Parallel Databases" with DOI and citations listed ¹⁰ .

	020-07294-y10	Includes funding acknowledgements ¹¹ .
Forecasting electric vehicles sales with univariate and multivariate timeseries models the case of china.pdf	Zhang, Y., Zhong, M., Geng, N., & Jiang, Y. (2017). Forecasting electric vehicles sales with univariate and multivariate time series models: The case of China. <i>PLoS ONE</i> , 12(5), e0176729. https://doi.org/10.1371/journal.pone.0176729	Explicitly states publication in <i>PLoS ONE</i> , an open access journal with detailed publication dates and DOI ¹² Authors and contributions listed ¹⁴ .
Online Forecasting and Anomaly Detection Based on the ARIMA Model.pdf	Kozitsin, V., Katser, I., & Lakontsev, D. (2021). Online forecasting and anomaly detection based on the ARIMA model. <i>Applied Sciences</i> , 11(7), 3194. https://doi.org/10.3390/app11073194	Header indicates "applied sciences Article" with detailed publication information (journal, volume, issue, article number, DOI, dates, editor) ¹⁵ .
Profit_Prediction_Using_ARIMA_SARIMA_and_LSTM_Mode.pdf	Sirisha, U. M., Belavagi, M. C., & Attigeri, G. (Publication date not fully specified in excerpt). Profit prediction using ARIMA, SARIMA and LSTM models in time series forecasting: A comparison. (Publication name, volume, issue, and pages not fully specified in excerpt). https://doi.org/10.1109/ACCESS.2017 .DOI ¹⁶	Format includes DOI ¹⁶ , typical for published peer-reviewed articles, likely in an IEEE publication. Authors listed ¹⁶ .
Research Paper Michael Visser v4.0.pdf	Visser, M. (Date unknown). Research Paper Michael Visser v4.0. (Publication venue not specified in excerpt).	Titled "Research Paper" with an author name.

		Structured like an academic paper with figures and extensive references to peer-reviewed works ¹⁷ Likely intended for peer review/publication.
Sentiment Analysis and Google Trends Data for Predicting Car Sale.pdf	Wijnhoven, F., & Bloemen, O. (Year not provided in excerpt, likely 2017). Sentiment analysis and Google Trends data for predicting car sale. <i>Thirty Eighth International Conference on Information Systems</i> , 1-15.22	Authors thank anonymous ICIS reviewers, indicating it was reviewed for the International Conference on Information Systems ²² , a peer-reviewed conference.
The Showrooming Phenomenon It's More than Just About Price.pdf	(Authors and publication details not provided in excerpt). (Year not provided in excerpt). The Showrooming Phenomenon It's More than Just About Price. (Publication venue not specified in excerpt). ²³	Explicitly thanks the "Editor and reviewer" ²³ , confirming peer review for a journal or similar publication.
The influence of consumers technological and environmental considerations.pdf	B.D., & H.-G.H. (Full names not provided in excerpt). (2021). The influence of consumers technological and environmental considerations. <i>Sustainability</i> , 13(unknown article number), 12025.24...	Header indicates "FOR PEER REVIEW" ²⁶ Published in <i>Sustainability</i> with acceptance and publication dates ²⁴ . Authors' contributions

		listed ²⁸ .
Using Forum and Search Data for Sales Prediction of High-Involvement Projects.pdf	Geva, T., Oestreicher-Singer, G., Efron, N., & Shimshoni, Y. (2017). Using forum and search data for sales prediction of high-involvement projects. <i>MIS Quarterly</i> , 41(1), 65–82.29...	Identified as a "RESEARCH ARTICLE" in <i>MIS Quarterly</i> ³⁰ with full publication details ²⁹ . Authors thank editor, associate editor, and reviewers ³¹ , confirming peer review.
Using machine learning methods to predict electric vehicles penetration in the automotive market.pdf	(Authors not provided in excerpt). (2023). Using machine learning methods to predict electric vehicles penetration in the automotive market. (Publication venue not specified in excerpt).32...	Includes "Received" and "Accepted" dates ³² . Mentions "Open Access" license ³⁴ ... and "Springer Nature journal content" [135, specific to "Using machine learning methods to predict electric vehicles.pdf", but likely applies to both similar titles]. Structured as a published paper.
Using machine learning methods to predict electric vehicles.pdf	(Authors not provided in excerpt). (2023). Using machine learning methods to predict electric vehicles. (Publication venue not specified in excerpt).36...	Includes "Received" and "Accepted" dates ³⁶ . Mentions "Open Access" license ³⁵ and

		"Springer Nature journal content" ³⁷ . Structured as a published paper.
--	--	--

No peer:

Source File Name	APA-Style Reference (Based on excerpt information)	Supporting Excerpts for Classification & Reference Info
A. Google trends as complementary tool for new car sales forecasting A cross-country comparison along the customer journey,.pdf	(Author not provided in excerpt). (Year not provided in excerpt). <i>A. Google trends as complementary tool for new car sales forecasting: A cross-country comparison along the customer journey</i> . (Thesis type and Institution not provided in excerpt). ³⁸	Refers to the document as a "thesis" ³⁸ .
Google trends as a complementary tool for new car sales forecasting.pdf	(Author not provided in excerpt). (Year not provided in excerpt). <i>Google trends as a complementary tool for new car sales forecasting</i> . (Thesis type and Institution not provided in excerpt). ³⁹	Refers to the document as a "thesis" ³⁹ .
Rationale_anoniem.pdf	(Author and Date not provided in excerpt). <i>Rationale_anoniem.pdf</i> . (Document type not specified, appears to be a rationale or proposal). ⁴⁰	Refers to "This research" ⁴⁰ and appears to be a foundational document for a research project, not a finished publication. The file name also suggests it's a rationale ⁴⁰ .

7.9.1.3 Time series modellen:

Arima en Sarima gevonden

<https://www.datacamp.com/tutorial/arima> keuze voor modellen:

7.9.1.4 TODO vandaag:

To-Do List: Improving Introduction + Problem

- check if there are official documents supporting my approach.

A. Structure and Alignment with HvA Standards (e.g., Steur rationale)

1. Add a **"Purpose and Structure"** paragraph at the start of the Introduction to explain:

- o The rationale behind the research
- o What the reader can expect (e.g., method, data, analysis)

2. Simplify and streamline the **background**:

- o Start with a clear policy target (e.g., 100% EV new sales in 2030)
- o Follow with digital behavior as an opportunity

3. Clarify the **target audience** (NGOs, policymakers with limited budgets)

4. Add **transitional subheadings** (e.g., Background, Problem, Contribution, Research Design)

5. Avoid mixing **methodological claims** into the background — move to Method section

B. Content-Based Refinement

6. **Replace vague or general claims** with cited references

- o Example: "lagging indicators" → needs a supporting source

7. **Avoid focusing solely on Google Trends:**

- o Mention it as a case, not as the core idea
- o Generalize to "digital behavioral indicators"

8. **Remove/reduce AIDA framework:** only briefly mention it as a conceptual anchor, not a full model

9. Rephrase speculative or overstated claims (e.g., weak performance of sentiment → nuance this)

10. Address the **Google Trends keyword gap**:

- o Mention that brand-specific terms dominate existing research
- o Your approach uses more general terms drawn from policy sources

11. Discuss **policy variables** (e.g., bijtelling) clearly:

- o Cite RVO or Belastingdienst
- o Explain how these variables are constructed and lagged

12. Move detailed keyword engineering techniques (e.g., TF-IDF, YAKE) to methodology, not intro

C. Clarify and Strengthen the Problem Statement

13. Clearly define the **gap**:

- Short timeframes
- Brand-specific trends
- No fusion with macroeconomic variables

14. Specify **consequences of poor forecasting**:

- Over/underestimating infrastructure needs, misaligned subsidies

15. Link the problem **explicitly to your data scope**:

- Monthly national BEV data (2007–2025)

16. Use *"too limited, too brand-specific, too short-term"* as a structural problem framing

D. Methodological Anchoring

17. Avoid embedding model names (e.g., XGBoost, CNN) in the introduction

18. Instead, state that you'll compare interpretable and complex models

19. Clarify **why MAE** is used — and if interpretability is part of your focus

20. Define how you apply **lagging for time series features** (sales vs. trends)

21. Justify your **time split approach**:

- Explain why you use TimeSeriesSplit or KFold
- Why walk-forward validation is more appropriate for your case

E. Technical Fixes and Polish

22. Improve title: current version is vague

23. Ensure all references have DOI or working links

24. Improve citation quality: focus on stronger sources

25. Avoid repetition of similar points (e.g., Google Trends brand keywords)

- Methode verder uitwerken
 - Modelvergelijkingen
 - eerste resultaten
- Inleiding verbeteren, meer vergelijken met inhoud van Gogreen en opmaak rationale
- Data verbeteren, data van bijtelling citeren
- Time series split verantwoorden met sklearn
 - [KFold](#)
 - [Lagged features for time series forecasting](#)

7.10 14/05

Cross validation + lag https://scikit-learn.org/stable/modules/cross_validation.html#time-series-split

7.10.1.1 **Onderwerp:** Feedback op scriptievoorstel en richting

Samenvatting gesprek:

- **Feature correlatie en selectie (Leerdoel B):**
Marcio wees erop dat veel van mijn features waarschijnlijk onderling sterk correleren. Dit kan een uitdaging vormen voor feature selection methoden, omdat overlappende informatie het moeilijk maakt om individuele bijdrage van variabelen te bepalen. Hij raadde aan hier kritisch naar te kijken in relatie tot leerdoel B.
- **Modelkeuze (Leerdoel B):**
De keuze voor modellen zoals **CNN en XGBoost** was volgens Marcio nog onvoldoende onderbouwd. Hij stelde voor om krachtigere of recentere modellen te overwegen, en het modelkeuzeproces expliciet toe te lichten (waarom juist deze modellen, en niet bijvoorbeeld LSTM of transformers?).
- **Featurebeschrijving:**
Marcio gaf aan dat een duidelijke uitleg van de gebruikte features ontbrak in de draft. Ik heb afgesproken dit vandaag toe te voegen.
- **Data-splitsing / validatie:**
De huidige split in mijn model houdt nog geen rekening met de tijdsstructuur van de data. Marcio adviseerde een time-series split te gebruiken om te voorkomen dat het model toekomstige data leert van informatie in het verleden (data leakage).
- **Kwaliteit van bronnen (Leerdoel A):**
De literatuurkwaliteit moet omhoog. Veel van de huidige bronnen hebben een lage impact. Marcio benoemde **bron 8** als krachtig en adviseerde om die dieper te analyseren en te benutten.

Belangrijke bron:

- Gallagher & Muehlegger (2011): *"Giving green to get green: Incentives and consumer adoption of hybrid vehicle technology"*

7.10.1.2 **Vraag aan marcio;**

- Ik wil moscow methode voor requirements doen, waar zal ik dat op baseren?

- Vragen over gap op modellen
- Vragen voor tips keyboard search selectie/ evt auteur mailen
- Waarom noemen ze scriptie rationale?
- Roling avarage per keyword te printen
- Is it promessing?
- Difference between rationale and normal scritpie
- Evt top 4 per dataset doen, dus 4 maanden, 4 diesel, 4 benzine, 4 consumentenvertrouwen, keywords
- Check of je ook single comom mag

7.10.1.3

English Top 10 meest gecorreleerde zoektermen met EV-verkoop:

charging stations: 0.713

electric car: 0.705

plug in hybrid: 0.627

electric truck: 0.613

electric bus: 0.593


smart charging: 0.587

electric cars: 0.581

electric vehicles: 0.570

hybrid electric: 0.562

electric vehicle: 0.433



7.10.1.4 Top 10 meest gecorreleerde zoektermen met EV-verkoop:

thuis opladen: 0.793

elektrische auto: 0.788

hybride elektrisch: 0.781

elektrische bus_x: 0.758

elektrische bus_y: 0.758


elektrisch rijden: 0.706

laadpunten: 0.701

elektrische vrachtwagen: 0.665

laadstations: 0.662

laadpunt: 0.647



7.10.1.5 Used invoer google trends

01/01/2007

Google Trends URL

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=toegankelijke%20laders>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=toegankelijk%20laden>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=toegankelijke%20snelladers>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=alternatieve%20brandstoffen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=infrastructuur%20voor%20alternatieve%20brandstoffen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=batterij->

elektrisch%20voertuig
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=batterij-elektrische%20voertuigen>
[https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=batterij-wisselsystemen](https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=batterij-elektrische%20voertuigen%20en%20plug-in%20hybride%20elektrische%20voertuigen)
[https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=laadinfrastructuur](https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrische%20voertuigen%20op%20celbasis)
[https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=laadpunt](https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=laadnetwerk)
[https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=laadstations](https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=laadpunten)
[https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=uitrol%20van%20elektrische%20auto%E2%80%99s](https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=vraag%20naar%20elektrische%20voertuigen)
[https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrische%20bus](https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=uitrol%20van%20elektrische%20voertuigen)
[https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrische%20auto](https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrische%20bussen)
[https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=modellen%20van%20elektrische%20auto%E2%80%99s](https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=markt%20voor%20elektrische%20auto%E2%80%99s)
[https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=verkoop%20van%20elektrische%20auto%E2%80%99s](https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aankoopprijs%20van%20elektrische%20auto%E2%80%99s)
[https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrische%20auto%E2%80%99s](https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=voorraad%20van%20elektrische%20auto%E2%80%99s)
[https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrisch%20rijden](https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=subsidies%20voor%20elektrische%20auto%E2%80%99s)
[https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrische%20lichte%20bedrijfswagens](https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrische%20lichte%20bedrijfsvoertuigen)
[https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrische%20mobiliteit](https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrische%20lichte%20voertuigen)

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrische%20vrachtwagen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrische%20vrachtwagens>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrische%20tweewielers>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrisch%20voertuig>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=adoptie%20van%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=batterijen%20voor%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=batterij%20voor%20elektrisch%20voertuig>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=opladen%20van%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=laadinfrastructuur%20voor%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=uitrol%20van%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=wagenpark%20van%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=initiatief%20voor%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=landen%20binnen%20het%20initiatief%20voor%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=markt%20voor%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=markten%20voor%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=modellen%20van%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=voorzichten%20voor%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aankoop prijs%20van%20elektrisch%20voertuig>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=verkoop%20van%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=marktaandeel%20van%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aanbod%20van%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=laadapparatuur%20voor%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=uitrol%20van%20laadapparatuur%20voor%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=laadpunten%20van%20laadapparatuur%20voor%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=groei%20van%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aantallen%20elektrische%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrische%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=data%20over%20elektrische%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=initiatief%20voor%20elektrische%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=subsidies%20voor%20elektrische%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=voertuigen%20met%20uitstoot>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=financi%C3%ABle%20prikkel%20voor%20elektrische%20auto%E2%80%99s>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=financi%C3%ABle%20prikkel%20voor%20elektrische%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=waterstofcel-elektrische%20auto>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=waterstofcel-elektrisch%20voertuig>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=wereldwijde%20elektrische%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=wereldwijd%20wagenpark%20van%20elektrische%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=wereldwijde%20data%20over%20elektrische%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=thuis%20opladen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=hybride%20elektrisch>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=hybride%20elektrische%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=auto%27s%20met%20verbrandingsmotor>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=voertuig%20met%20verbrandingsmotor>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=voertuigen%20met%20verbrandingsmotor>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=laders%20voor%20lichte%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=verkoop%20van%20lichte%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=nieuwe%20energievoertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aantal%20elektrische%20auto%E2%80%99s>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aantal%20elektrische%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=plug-in%20hybride>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=plug-in%20hybride%20elektrisch%20voertuig>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=plug-in%20hybride%20elektrische%20voertuigen>

<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=priv%C3%A9%20laders>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=priv%C3%A9%20laden>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=publieke%20laders>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=publiek%20laden>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=publiek%20toegankelijke%20laders>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=publiek%20toegankelijke%20laadmogelijkheden>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aankoopstimulansen%20voor%20elektrische%20auto%E2%80%99s>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aankoopstimulansen%20voor%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aankoop%20van%20elektrische%20auto%E2%80%99s>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aankoop%20van%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aankoopprijs%20elektrische%20auto>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aankoopprijs%20van%20elektrisch%20voertuig>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aankoopsubsidies%20voor%20elektrische%20auto%E2%80%99s>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aankoopsubsidies%20voor%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=verkoopaandeel%20van%20elektrische%20auto%E2%80%99s>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=verkoopaandeel%20van%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aandeel%20elektrische%20auto%E2%80%99s>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=aandeel%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=slim%20laden>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=voorraad%20van%20elektrische%20auto%E2%80%99s>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=voorraad%20van%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=transitie%20naar%20elektrisch>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=acceptatie%20van%20elektrische%20auto%E2%80%99s>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=acceptatie%20van%20elektrische%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=opladen%20van%20voertuigen>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=elektrificatie%20van%20voertuigen>


<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=nul-emissie%20voertuig>
<https://trends.google.com/trends/explore?date=2007-01-01%202025-01-01&geo=NL&hl=nl&q=nul-emissie%20voertuigen>

7.10.2 Results new keywords:

Google Trends normaliseert data binnen de groep van ingevoerde zoektermen. Dit betekent:

- De zoekterm met de **hoogste piek in die groep** krijgt altijd een waarde van 100.
- Alle andere termen worden daaraan relatief geschaald.

corrolatie with Totaal ev verkoop =



7.11 13/05

Schrijf je **methodologie**-hoofdstuk af: geef uitleg over je model selectie (XGBoost/cnn), evaluatie (MAE), en validatiestrategie

7.11.1.1 Feedback marcio

Hello Dylan,

I looked at your report. It is progressing (+). Still, many points (some related to the scope) need to be addressed. Below are some comments I made while reading your paper.

(?) Title:

It is hard to grasp. The sentence ("Uncovering the Drivers of Car Sales") seems ambiguous. Also, "grouped feature importance" is just one of the techniques used, and it's common in the data preparation and training phases. Unless this technique is the only one used (reading it entirely, I don't think so), I would not highlight it. You still have time to refine your title, but this version is unclear.

(!) References:

Please include the DOI URL for each referenced paper. If a DOI is unavailable, add a direct link to view or download the resource (e.g., reference 1 is a government document). Some references are incomplete—for instance, source 5 lacks full citation details.

(-) Based on what is this sentence?

("However, these factors are typically derived from surveys or lagging indicators, limiting their real time predictive utility").

Strong claims like this must be backed by a reference, a peer-reviewed paper or book.

(-) Regarding the sentence:

("In this context, Google Trends offers a unique view into early stage consumer interest in EVS by capturing real-time search behaviour").

It can be valid, but why only Google Trends? Focusing exclusively on it may limit the generalisability of your research.

(-) You refer to the AIDA method and cite source four as a basis.

However, I couldn't find any reference to this method in the abstract. Please confirm. It also appears that the methodology was introduced early in the paper but not followed through in the rest of the text. Is AIDA relevant for your entire work?

(-) Regarding the sentence:

("This study proposes a complementary approach by integrating Google search volume and behavioural-economic indicators").

Avoid sticking your concept to a single data source. The idea should be broadly conceptualised, and as a pragmatic decision, it would be fine to adopt Google Trends as an example of an application.

(-) Problem Statement:

Regarding the sentence ("While recent research has explored the use of behavioural signals such as Google search trends to model EV interest, many approaches still rely on short time windows or narrow keyword sets, often limited to specific car models").

What is your source for this statement?

(-) The problem statement is too general.

It should be more closely aligned with the "A" learning outcomes. Consider clarifying:

- Who are the stakeholders interested in EV sales forecasting? What are the opportunities for good forecasting, and what are the impacts of "bad" forecasting?
- Why is it relevant?
- What is currently being done in the field?

Also, the limitations of such approaches should be discussed. EV adoption is a complex phenomenon influenced by social, political, and technical factors, so multiple variables are at play.

(-) Regarding the sentence:

("The weak performance of sentiment data in predicting sales led the authors to conclude that behavioural search signals may offer more actionable insights, though their influence appears limited for high involvement purchases like cars, possibly due to the overriding impact of external factors such as tax policies").

This conclusion seems premature, especially because you mentioned very low statistical significance. Please avoid strong causal statements in such cases.

(?) Regarding the sentence:

("While their study was adoption-focused and cross-sectional, it validated Google Trends as a real-time behavioural proxy.")

This sentence is unclear—please rephrase for clarity.

(!) Literature Review:

The quality of sources should be improved. Most cited papers have very low citation counts, except for article 8, which offers a good overview. Make better use of that source to reinforce your problem statement.

(!) Regarding the sentence:

("This underlines the importance of timing and visibility in financial incentives that provide immediate benefits or are simpler to access appear more effective in influencing consumer decisions towards EV adoption").

Please clarify this statement. What exactly do you mean, and how does it relate to your research?

(!) Regarding the statement:

("The authors stated that gasoline prices influence the total cost of vehicle ownership and are expected to be associated with consumer car purchase decisions"). Please explain better.

(?) "Their six-month sliding window and feature selection via information gain allowed the model to outperform traditional regressors in both speed and accuracy."

What do you mean by "traditional regressors"? Please specify.

(-) You mention subsidies.

How do you plan to use this information? It would require tracking government subsidy programs over specific timeframes. This should be very well explained in the methodology section

(?) Regarding the sentence:

("Behavioural indicators like Google Trends are often analysed in isolation, without normalisation correction across years, which impedes comparability over time").

What do you mean by "normalisation correction across years"? Normalised based on what? Please explain.

(?) Is explainability your focus?

You mention that few studies compare interpretable nonlinear methods (e.g., XGBoost) with deep learning (e.g., CNN or LSTM). It raises the question: Are you really addressing the trade-off between accuracy and interpretability? To which target audience?

(?) Why compare XGBoost and CNN?

Why specifically CNN? You also mention LSTM later, but more efficient models are available. You should work on the rationale for your choices.

(?) Existing Work and Gaps:

Keyword selection is an implementation detail. More important is *what kind of information* you want to capture from documents. That part belongs in the methodology section. We need to understand the data at hand better to choose between technique A or B.

(!) Fix repetition:

There are multiple mentions of the limitation related to reliance on specific car brands—please consolidate.

(!) The keyword search is too limited.

More advanced and effective methods exist for semantic and temporal signal extraction.

(!) Google Trends in the research question?

Avoid embedding specific data sources into the research question—make it broader.

(!) Research Question:

Consider a broader framing:

To what extent can macroeconomic indicators, media, and digital trends predict EV sales?

Then break this into sub-questions like:

- a) Which macroeconomic indicators influence EV sales?
- b) Which digital trends (e.g., media coverage, search interest) play a role?
- c) What would a predictive model look like using fused data from these sources?

(-) Requirements:

These need to be specific and measurable. For example, "Use interpretable and scalable models" is too vague. Interpretable for whom? Also, who is your target audience? It must be defined to tailor your requirements accordingly. Note that in the discussion section, you'll need to revisit them, so the more ambiguity, the harder it is to answer them.

Data:

There's no description of what Google Trends provides. Exploratory Data Analysis (EDA) is essential. What does your dataset look like? What are the distributions, completeness, and statistical properties?

TF-IDF and YAKE are mentioned too soon and are somewhat outdated. Better techniques exist today. Also, the macroeconomic and policy data descriptions are not yet present.

Methodology:

Please justify your model selection: Why XGBoost, CNN, LSTM (?)—and why not other alternatives? How you plan to combine macroeconomic, digital, and policy data is also unclear. Consider specifying:

- Which features and transformations?
- How do spatial/temporal relationships come into play?

Quantitative Analysis:

Why use MAE and not other regression metrics? Provide a rationale.

Qualitative Analysis:

Are you including one? For instance, will you reflect on why specific policy, social, or economic indicators correlate with EV sales?

7.11.1.2 Verslag begeleidingsgesprek met scriptiebegeleidster (Daphne)

Vandaag heb ik een gesprek gehad met mijn huiswerkbegeleidster over de voortgang van mijn scriptie. Hieronder een samenvatting van de belangrijkste besproken punten:

7.11.1.2.1 1. Keuze van EV-gerelateerde zoektermen

We begonnen met een discussie over welke zoekwoorden ik het best kan gebruiken in Google Trends. Daphne gaf aan dat het gebruik van algemene EV-gerelateerde termen (zoals “elektrische auto”, “EV subsidie”) een goede keuze is.

7.11.1.2.2 2. Focus van de scriptie

Daphne benadrukte dat de focus van mijn scriptie nu nog te veel ligt op de zoektermen zelf. Ze adviseerde om de nadruk meer te leggen op de samenstelling en bruikbaarheid van de datasets die ik gebruik. De datasetconstructie is namelijk waar ik het meeste tijd in heb gestoken.

7.11.1.2.3 3. Gebruik van NOS als bron

Hoewel ik eerder heb besloten geen sentimentanalyse te doen, gaf Daphne aan dat het toch goed is om de NOS-dataset te benoemen, juist om te onderbouwen waarom deze niet bruikbaar was. Het draagt bij aan het verhaal over welke datasets ik heb onderzocht en waarom sommige zijn afgefallen.

7.11.1.2.4 4. Doelgroep van het onderzoek

We hebben samen nagedacht over een geschikte doelgroep. De voorkeur ging uit naar overheden en NGO's die zich bezighouden met klimaatbeleid. Deze doelgroep heeft meer baat bij inzichten op basis van algemene zoektermen dan bijvoorbeeld autodealers, en beschikt vaak over een beperkt budget. Gratis databronnen zoals Google Trends en CBS zijn voor hen extra relevant.

7.11.1.2.5 5. Gebruik van het AIDA-model

In plaats van het AIDA-model uitgebreid te behandelen, stelde Daphne voor om kort te benoemen dat Google Trends een populaire methode is om gedrag of interesse rondom aankoopbeslissingen te analyseren.

7.11.1.2.6 6. Modelling en onderzoeksvraag

Ik vroeg hoe ik het beste mijn modelling kon aanpakken. Daphne stelde voor om meerdere modellen te proberen zonder daar een strikte hypothese aan te koppelen. De kernvraag is immers welke dataset het beste werkt binnen een model, niet welk model het beste presteert.

7.11.1.2.7 7. Keyword selectie en vertaling

Omdat mijn huidige lijst met keywords in het Engels is, wil ik deze vertalen naar het Nederlands. Hoewel Daphne aangaf dat ik gewoon de meest logische Nederlandse zoektermen kan gebruiken, wees ik erop dat dit eerder bij de sentimentanalyse niet goed uitpakte. Een alternatieve aanpak is om alle keywords op correlatie met verkoopdata te testen en op basis daarvan de top 5 te selecteren, maar dit vergt veel tijd.

7.11.1.2.8 8. Concrete verbeterpunten voor scriptierapport

- **Existing work en gap** samenvoegen tot één logisch geheel.
- **Subkopjes** toevoegen aan het onderdeel 'existing work' om de structuur te verbeteren.
- De **prestatiemaatstaf** die ik gebruik benoemen in dit deel.

7.11.1.2.9 9. Nieuwe formuleringen voor de onderzoeksvraag (suggesties)

- *What dataset provides the most accurate sales forecasting for electric vehicles in the Netherlands?*
- *What insights do available datasets provide for predicting EV sales in the Netherlands?*
- *Can the combination of Google Trends, fuel prices, and consumer confidence accurately predict EV sales in the Netherlands?*

7.11.1.2.10 10. Modelselectie en preprocessing

Ik moet nog beslissen welke modellen ik precies gebruik. Mogelijk kan ik werken met standaard hyperparameters. Daarna richt ik me weer op het preprocessen van de data, waaronder het toepassen van lagtime.

Wat betreft de bijtelling wilde ik die variabele één maand eerder trainen omdat de verkoop piekt vóór het ingaan van een nieuwe bijtellingsregeling. Maar dit blijkt niet mogelijk: toekomstige data gebruiken voor het trainen op het verleden is methodologisch onjuist, dus ik laat dit zoals het is.

Voor nu ligt de **focus op het toepassen van lagtime op de verkoopcijfers**. Eventueel onderzoek ik later ook of lagtime op Google Trends zinvol is. Omdat eerdere studies model-specifieke zoektermen gebruikten (zoals "Tesla Model 3"), was de lag daar logisch. Bij mijn bredere zoektermen (zoals "elektrisch rijden") is het minder duidelijk of een lag evenveel effect heeft.

Tot slot: ik kijk haar mail nog even na over dit onderwerp.

7.11.1.3 BIJTELLING GEVONDEN!



bpm_tarieven_bpm
0651z14fd.pdf

BPM is niet hetzelfde als bijtelling

7.11.1.4 Bijtelling % vinden:

Bijtelling zichtbaar op je salarisstroom

Vanaf 2007 'verhuisde' de bijtelling van inkomstenbelasting naar loonbelasting. Het resultaat daarvan was, dat de werkgever de bijtelling ging verrekenen met de salarisstroom. De rijder had dus elke maand direct inzicht in zijn bijtellingskosten. Je kunt je voorstellen dat de zakelijke rijder op een andere manier naar de leaseauto ging kijken.

Vanaf 2009 werd het algemene bijtellingstarief aangepast van 22% naar 25%. Ook werden er extra bijtellingscategorieën geïntroduceerd voor zuinigere auto's. Deze categorieën werden gebaseerd op de CO₂-uitstoot van een zakenauto. Ook werden de CO₂-grenzen elk jaar bijgesteld.

De belangrijkste wijziging bij de bijtellingscategorieën is de introductie in 2012 van het 0% bijtellingstarief voor [auto's zonder CO₂ uitstoot](#) (bijvoorbeeld elektrische en waterstofauto's). Dat jaar werd ook het bijtellingstarief voor [youngtimers](#) geïntroduceerd, namelijk 35% over de dagwaarde van 15 jaar oude auto's.

[https://www.vzr.nl/nieuws/details/de_geschiedenis_het_ontstaan_van_de_bijtelling#:~:text=De%20belangrijkste%20wijziging%20bij%20de,\(bijvoorbeeld%20elektrische%20en%20waterstofauto's\).](https://www.vzr.nl/nieuws/details/de_geschiedenis_het_ontstaan_van_de_bijtelling#:~:text=De%20belangrijkste%20wijziging%20bij%20de,(bijvoorbeeld%20elektrische%20en%20waterstofauto's).)

Bijtelling zichtbaar op je salarisstroom

Vanaf 2007 'verhuisde' de bijtelling van inkomstenbelasting naar loonbelasting. Het resultaat daarvan was, dat de werkgever de bijtelling ging verrekenen met de salarisstroom. De rijder had dus elke maand direct inzicht in zijn bijtellingskosten. Je kunt je voorstellen dat de zakelijke rijder op een andere manier naar de leaseauto ging kijken.

Vanaf 2009 werd het algemene bijtellingstarief aangepast van 22% naar 25%. Ook werden er extra bijtellingscategorieën geïntroduceerd voor zuinigere auto's. Deze categorieën werden gebaseerd op de CO₂-uitstoot van een zakenauto. Ook werden de CO₂-grenzen elk jaar bijgesteld.

De belangrijkste wijziging bij de bijtellingscategorieën is de introductie in 2012 van het 0% bijtellingstarief voor [auto's zonder CO₂ uitstoot](#) (bijvoorbeeld elektrische en waterstofauto's). Dat jaar werd ook het bijtellingstarief voor [youngtimers](#) geïntroduceerd, namelijk 35% over de dagwaarde van 15 jaar oude auto's.

[https://www.vzr.nl/nieuws/details/de_geschiedenis_het_ontstaan_van_de_bijtelling#:~:text=De%20belangrijkste%20wijziging%20bij%20de,\(bijvoorbeeld%20elektrische%20en%20waterstofauto's\).](https://www.vzr.nl/nieuws/details/de_geschiedenis_het_ontstaan_van_de_bijtelling#:~:text=De%20belangrijkste%20wijziging%20bij%20de,(bijvoorbeeld%20elektrische%20en%20waterstofauto's).)

Naar één bijtellingstarief

Vanaf 2017 is niet meer 25%, maar 22% het algemene bijtellingstarief geworden. Auto's zonder CO2-uitstoot genieten nog steeds van een bijtellingskorting, al wordt dit elk jaar wel zodanig aangepast, dat alle auto's vanaf 2026 onder het bijtellingstarief van 22% vallen.

Naar één bijtellingstarief

Vanaf 2017 is niet meer 25%, maar 22% het algemene bijtellingstarief geworden. Auto's zonder CO2-uitstoot genieten nog steeds van een bijtellingskorting, al wordt dit elk jaar wel zodanig aangepast, dat alle auto's vanaf 2026 onder het bijtellingstarief van 22% vallen.

7.11.1.5 Data prepossesing:

XGboost	F%	MAE	MAPA
Met zelfde gasprijzen mean,first last min max etc: En keywords: ev electrisch rijden, electrische auto, ev nederland Geen Bijtelling%	29.22	3477.37	
Alleen mean per maand gas	31.39	3618.48	
Met nieuwe keywords en bijtelling%	43.30	4202.57	23.34

Met zelfde gasprijzen mean,first last min max etc:

Gemiddelde absolute foutmarge (%): 29.22


Overall MAE op validatieset: 3477.37

Maakt minimaal verschil

Zonder:

Gemiddelde absolute foutmarge (%): 31.39

Overall MAE op validatieset: 3618.48



Met alleen mean per maand voor pomp en met een draft van bijtelling:

Cnn voor was Gemiddelde absolute foutmarge (%): 31.03

Mean Absolute Error (MAE): 3149.71

7.11.1.6 Feedback Daphne:

7.11.1.6.1 Background:

ik heb zelf wat twijfels erbij dat AIDA model te introduceren, zeker omdat het erop lijkt dat je dit een beetje last minute gevonden hebt. Het is inderdaad wel duidelijk dat Google Trends goed de 'Attention' kan weerspiegelen, maar er zijn zeker nog andere 'attention' aspecten die je in deze thesis niet meeneemt (bijv. social media posts/reacties over EVs)

Daarnaast neem je ook niet per se zo veel 'Desire' data mee, zoals andere papers dat doen (bijv. gegevens over 'environmental' concerns van mogelijke klanten, informatie over subsidies etc).

Vandaar dat ik niet vind dat het AIDA framework super sterk overeenkomt met jouw approach, en zou ik het daarom ook niet per se noemen

maybe good to mention how they obtained this data (and at some point later maybe justify why you couldn't obtain that kind of data)

7.11.1.6.2 Existing work:

I wouldn't really say that XGBoost is an interpretable model, maybe you can say that it's a faster to learn model compared to the others again, not really interpretable

7.11.1.6.3 Gap:

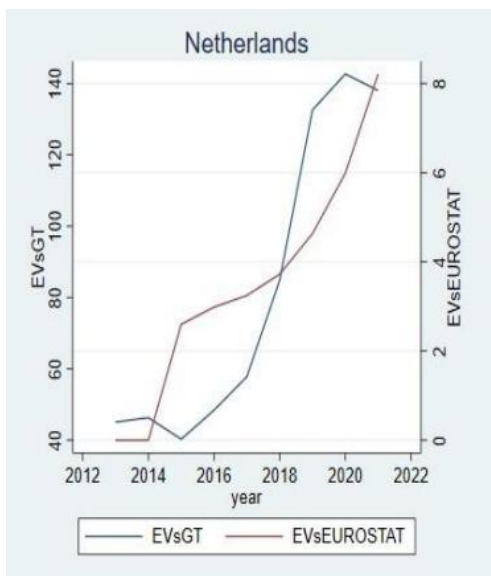
this whole section feels repetitive to the previous one, consider skipping

7.12 12/05

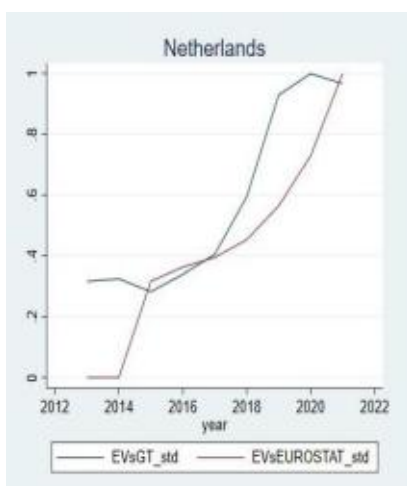
Werk me **dataverwerking en feature engineering** sectie uit met uitleg over o.a. Google Trends, brandstofprijzen, lags.

7.12.1 Oplossing keyword search?

Ik heb contact opgenomen met Fulvio Castellacci met het verzoek om de lijst met gebruikte zoekwoorden uit zijn onderzoek te delen. Hij heeft hierop positief gereageerd en de volledige lijst toegestuurd via de online appendix van het gepubliceerde artikel. In zijn toelichting gaf hij aan dat de samengestelde EV-indicator is berekend als het gemiddelde van de Google Trends-scores van alle opgenomen zoekwoorden (zie sectie 3.2 van het artikel). Deze lijst biedt waardevolle input voor mijn eigen keywordselectieproces. → vraag zijn die keywords georderdend op iets?



Figuur 1: Google Trends indicator of EVs adoption (left-axis) and Eurostat indicator



Figuur 2: Google Trends indicator of EVs adoption and Eurostat indicator on the share

7.12.1.1 Bron voor jaarlijkse bijtelling:

De onderstaande bron geeft een overzicht van bijtellingspercentages voor volledig elektrische auto's (0 gram CO₂-uitstoot) per jaar:

<https://100-salaris.nl/bijtellingspercentages-voor-privegebruik-auto-2011-2026/>

Hoewel de informatie overzichtelijk is weergegeven, is de betrouwbaarheid en herkomst van de data momenteel niet voldoende onderbouwd voor gebruik in mijn thesis. Ik ga onderzoeken of de gegevens aansluiten bij officiële bronnen (zoals de Belastingdienst) of dat ik een officiële bron kan gebruiken ter vervanging.

Jaar	Bijtellingspercentage	Max. verlaagde bijtelling tot cataloguswaarde
2019	4%	€50.000
2020	8%	€45.000
2021	12%	€40.000
2022	16%	€35.000
2023	16%	€30.000
2024	16%	€30.000
2025	17%	€30.000
2026	22%	Geen drempel – volledige cataloguswaarde

Let op: Bijtelling geldt voor een periode van 60 maanden vanaf de eerste tenaamstelling. Na deze periode zijn de op dat moment geldende percentages van toepassing.

Tot slot: bij het googelen van termen als “*Bijtelling privégebruik auto*” verschijnen in veel gevallen (ruim 20 keer geteld) cijfers afkomstig van de Belastingdienst zelf. Dit bevestigt dat deze officiële gegevens breed worden geciteerd, en biedt mogelijk aanknopingspunten voor het vinden van een directer te citeren primaire bron.



Tabel_bijtelling_201
1-2026.pdf

Damn zie nu ook <https://rijksoverheid.sitearchief.nl/#archive> kijken of ik hier iets kan vinden over bijtelling eerste indruk is dat het moeilijk is om te zoeken:

[het bijtellingstarief voor e-auto's wederom wordt verhoogd \(van 8 naar 12 procent\), kan er tegen het einde van het jaar weer een run ontstaan, zoals afgelopen december.](#)

<https://www.bovag.nl/nieuws/446114-nieuwe-personenautos-in-2019>

7.13 11/05

7.13.1.1 Vragen voor mezelf:

Als ik zo een focus leg op overheid en zero emissions, moet ik dan niet eigenlijk een doorberekening doen op 20250? → nee je zou in discussie kunnen zetten

Rond **literatuurstudie** af: samenvatting van eerdere papers, positionering van je eigen bijdrage.

Ochtend (15-16)

- **Literatuurstudie afronden:**

- Korte samenvatting per kernpaper (Wijnhoven, Afandizadeh, Zhang, Castellacci, enz.)
- Benoem verschil in scope, methoden, tijdsperiode
- Schrijf je bijdrage als afsluitende alinea van dit hoofdstuk

Middag (16:30-18)

- **Finaliseer methodologie:**
 - Leg ‘walk-forward’ nog 1x kort uit
 - Benoem waarom je MAE kiest
 - Noem kort waarom CNN erbij zit naast XGBoost
- **Check scope + ethische overwegingen** (kort)
 - Benoem bewust gebruik van publieke data
 - Zeg dat het model transparant en reproduceerbaar is

Eind van de dag (18:00-20:00)

- **Laatste spellingscheck (Grammarly / Overleaf)**
- PDF genereren via Overleaf
- **Stuur draft naar je docent met korte begeleidende e-mail**
- Benoem verschil in scope, methoden, tijdsperiode

7.13.1.2 Existing Work – Outline and Draft Starters

Samenvattingen Kernpaper:

7.13.1.3 Sentiment Analysis and Google Trends Data for Predicting Car Sales(Wijnhoven & Plant, n.d.)

In contrast to previous studies that primarily focus on short-term sales forecasting, model-specific interest, or sentiment-based indicators, this thesis offers a broader and more policy-relevant approach. While research such as Wijnhoven & Plant (2017) and Afandizadeh et al. (2023) focus on brand-level queries or deep neural networks applied to shorter periods, this study analyzes national-level EV sales in the Netherlands from 2007 to 2025. It integrates general behavioral indicators (e.g., Google Trends data on “elektrisch rijden” and “laadpaal”), macroeconomic signals (fuel prices, consumer confidence), and policy events (e.g., subsidy announcements, changes in bijtelling) into a unified forecasting framework. By applying nonlinear models like XGBoost and CNN, combined with walk-forward validation and rescaling of Google Trends data, this thesis adds methodological rigor and real-world applicability. It bridges a gap in the literature by aligning behavioral data with policy evaluation, offering valuable insights for forecasting electric vehicle market trends beyond brand-specific analysis.

Objective:

To compare the predictive power of **social media sentiment** and **Google Trends data** for **forecasting car sales** in the Netherlands, focusing on 11 car models over 52 months (2012–2016).

Key Concepts & Theoretical Basis:

- **AIDA Model:**
 - **Attention** → Social media mentions

- **Interest** → Google search behavior (Google Trends)
- **Desire** → Sentiment (positive/negative ratio, PNR)
- **Action** → Actual sales
- **Theory of Planned Behavior** and **Information Acceptance Model (IACM)** also underpin the assumed link between social information and purchase intention.

Methodology:

- **Data Sources:**
 - 500,000 social media posts via Coosto (Twitter, Facebook, etc.)
 - Google Trends data for search interest
 - Monthly car sales data from BOVAG (Netherlands)
- **Sentiment Measure:**
 - $PNR = \text{Positive posts} / \text{Negative posts}$
- **Analysis:**
 - Linear regressions and decision tree regression (M5P in WEKA)
 - Time lag testing (cross-correlation with up to 12-month delay)

Results:

- **Sentiment:**
 - Weak predictor of car sales; only significant for VW Golf, and even then with lag 0.
- **Google Trends:**
 - Moderate to strong predictor in multiple cases (avg. correlation ≈ 0.345 with ~ 6.7 months lag).
- **Total mentions:**
 - Strong predictor for some models (correlation ≈ 0.804 , $R^2 \approx 0.606$).
- **Prediction model:**
 - A decision tree using car model, mentions, and Trends score (with 4-month lag) achieved $R = 0.73$.

Conclusions:

- **PNR (sentiment)** was not a reliable predictor.
- **Search interest (Google Trends)** had higher and more consistent predictive power.
- **Modeling lags** is essential — peak search and mention activity precede sales by about **4–7 months**.
- **Policy effects** (e.g., tax changes) likely have stronger influence than sentiment.

Relevance to Your Thesis:

Supports your decision to use Google Trends over sentiment analysis, especially for high-involvement goods like EVs.

Highlights the importance of time lags, especially around **4–6 months** — aligning with your own walk-forward validation setup.

Validates keyword-based Trends selection for vehicle forecasting, although they used model-specific queries (e.g., “Volkswagen Passat”) rather than general EV terms — that’s a clear **point of distinction** for your study.

You extend this work by using nonlinear models (XGBoost, CNN), a broader range of macroeconomic and behavioral features, and a **longer time window (2007–2025)**.

7.13.1.4 *Does digitalisation affect the adoption of electric vehicles? New regional-level evidence from Google Trends data (Castellacci & Santoalha, 2025)*

Methodology:

- **Data source:** Google Trends (monthly search data)
- **EV adoption signal:** 116 keywords selected from 9 years of IEA EV Outlook reports (e.g., “electric vehicle,” “EV battery”).
- **Digitalisation indicators:** Keywords for five domains (smart manufacturing, smart cities, smart appliances, online communication, social media).
- **Composite scores:** Built by averaging normalized Trends scores (0–100) per region.
- **Validation:** Google Trends EV score was compared to Eurostat EV market share data in 12 countries and showed strong alignment.
- **Handling missing data:** Regions with <50% completeness were excluded.

Key Findings:

- Regions with higher digitalisation (measured via Trends) also showed **greater interest in EVs**.
- The Google Trends-based EV adoption indicator is shown to be **valid and consistent with actual adoption trends**.

Relevance to Your Thesis:

- Strong support for using **Google Trends as a behavioral proxy** for EV interest.
- Their **keyword selection method** (based on expert sources like IEA reports) gives you a defensible strategy for building your own search terms.
- You extend this work by:
 - Focusing on **forecasting actual EV sales** over time (not just interest or adoption).
 - Including **macroeconomic and policy variables**.

- Applying **machine learning models (XGBoost, CNN)** rather than regression alone.
- Working with **longer timeframes (2007–2025)** and monthly granularity.

7.13.1.5 *Using machine learning methods to predict electric vehicles penetration in the automotive market* (Afandizadeh et al., 2023)

Mooie zinnen:

Electric cars have been introduced as an alternative to gasoline and diesel cars to reduce greenhouse gas emissions, optimize fossil fuel use, and protect the environment. Predicting EV sales is momentous for stakeholders, including car manufacturers policy makers and **fuel suppliers**

According to environmental protection agency 27% van greenhouse gas emissions are from transportation sector → zelfde toevoegen voor NL

Objective of the Study

- Predict monthly EV sales and market share using advanced deep learning models.
- Identify the most influential factors on EV sales using hybrid AI models.

Existing work:

Numerous studies have applied machine learning (ML) techniques to forecast vehicle sales using time-series and economic data. A variety of models—ranging from regression-based methods to advanced neural networks—have been tested across different regions and data granularities.

Brühl et al. (2012) compared Multiple Linear Regression and Support Vector Machines (SVM) using economic indicators such as GDP, personal income, and petroleum charges, across yearly, quarterly, and monthly data. They found that SVM outperformed regression models in terms of MAE and MAPE, particularly on quarterly data due to better stability and interpretability.

Wang et al. implemented Adaptive Network-Based Fuzzy Inference Systems (ANFIS), Artificial Neural Networks (ANN), and ARIMA models to forecast sales using macroeconomic factors, vehicle and component prices, and exchange rates. ANFIS achieved the highest accuracy (R^2 and MSE), demonstrating the advantage of hybrid ML techniques.

Hülsmann et al. (2012) analyzed German and US sales data using both linear models (OLS, quantile regression) and nonlinear ones (SVM, decision trees, random forests, k-NN). Decision trees showed the best monthly performance in terms of MAPE, with interpretability being a key strength.

Kitapçı et al. examined macro-policy effects in Turkey using both regression and neural networks. Variables included tax incentives, loan rates, euro exchange rates, and advertisement spending. Neural networks outperformed regression models, and tax-related factors proved particularly influential.

Bas et al. explored EV adoption prediction using ride-sourcing behavior and sociodemographics. With classification algorithms and LIME for interpretability, they found that ride frequency, EV knowledge, and environmental awareness were key drivers of EV adoption.

Zhang et al. tested Singular Spectrum Analysis (SSA) and Vector Auto-Regression (VAR) on Chinese EV sales. VAR outperformed SSA due to its ability to integrate macroeconomic indicators (fuel prices, confidence indices) and behavioral data (Baidu searches).

Kaya and Yildirim developed a deep neural network to predict monthly vehicle sales in Turkey based on GDP, CPI, CCI, and exchange rate data. The DNN achieved high accuracy, highlighting the importance of economic indicators and time features.

Xia et al. introduced the ForeXGBoost model, applying XGBoost to a large-scale dataset with brand/model data. Through feature selection and optimized time-window extraction, their model significantly outperformed traditional regressors in both speed and accuracy.

Lastly, Saxena et al. evaluated deep learning methods like LSTM and ARIMA for green vehicle sales forecasting. LSTM delivered the lowest MAE and RMSE, reinforcing its suitability for time-series forecasting with non-linear dynamics.

Summary: Non-ML Approaches to Understanding Factors Influencing EV Sales

Several studies have explored factors that influence electric vehicle (EV) sales using alternative methods such as surveys, choice modeling, and behavioral analysis—particularly to support **policy development** by better understanding user preferences.

Survey-based studies:

- **Beggs et al.** and **Calfee et al.** used consumer surveys to estimate potential EV demand based on preferences for technical specifications (e.g., seat capacity, price, performance). They found that poor performance limits adoption but demand increases under improved tech or fuel scarcity scenarios.
- These approaches have limitations: they predict market share as reflected in the survey, not in real-world sales.

Social influence and consumer perception:

- **Mau et al.** introduced the concept of the “**neighbor effect**”, where awareness of local EV adoption increases personal likelihood to purchase.
- **Kinski et al.** found that **Google Trends search interest** correlates positively with car sales, offering a real-time behavioral signal of market interest.

Vehicle attributes and decision-making:

- **Balducci et al.** showed that fuel economy and emissions reduction are strong motivators for plug-in hybrid EVs, while high cost and low reliability deter buyers.
- **Hess et al.** used discrete choice models to show that purchase incentives, acceleration, range, and fuel availability positively influence purchase intent, while cost and maintenance negatively affect it.
- **Shafiei et al.** confirmed that combining tax incentives, lower EV prices, and high fuel prices significantly boosts EV market share.

Technology and energy cost trade-offs:

- **Bas et al.** demonstrated that new fuel-saving technologies (even in gasoline cars) are appealing to consumers, and that **EVs still struggle with cost-benefit perception**, despite environmental advantages.

Relevance to This Thesis

These studies identify **critical factors influencing EV adoption**, such as:

- Vehicle specs (range, acceleration, fuel cost)
- Policy instruments (subsidies, tax breaks)
- Public perception (neighbor effect, environmental concern)
- Behavioral signals (Google search interest)

While most studies use static methods (surveys, choice models), your thesis adds value by:

- Using **Google Trends** to quantify “interest” in the **AIDA model**
- Integrating **economic and behavioral indicators** in a dynamic, time-series forecasting model
- Focusing on **real-time prediction** instead of stated preference modeling
- Applying **walk-forward validation** with lags to simulate decision-relevant forecasts

This enables your research to bridge the gap between **policy design** and **behavioral response forecasting**—something traditional survey-based approaches cannot do dynamically.

Methodology & Data Summary – Afandizadeh et al. (2023)

Afandizadeh et al. developed a hybrid deep learning framework to predict electric vehicle (EV) sales in the U.S. market using data from **2014 to 2020**. The research compared three models:

1. **LSTM** – captures long-term dependencies in time series.
2. **ConvLSTM** – improves temporal correlation handling by using convolutional operations on sequences.
3. **Hybrid LSTM with 2D Attention and Residual Network** – introduces an attention mechanism to weigh feature importance across a 7-month window, and residual connections to preserve learned patterns from earlier layers.

The models were evaluated using rolling cross-validation and metrics like MAPE, NRSME, and R^2 . The **hybrid model outperformed** the other two, achieving an average MAPE of ~3.5% for EV share predictions.

Data Collection

- **Primary dataset:** Monthly sales data for 357 new car models from 2014–2020.
- **Web crawlers** were used to collect:
 - **Vehicle specifications** (e.g., MPG, engine power, price).

- **Sentiment scores** from car-related news articles (via VADER sentiment analysis).
 - **Google Trends** search scores for specific brand + model queries.
- **Macroeconomic data:** GDP, CPI, fuel prices, stock indices, loan interest rates.
- Input was structured using a **7-month sliding window**, and month-of-year dummy variables were used for seasonality.

Relevance and Gap Compared to Your Thesis

What's similar:

- Both studies use **machine learning for EV sales forecasting**.
- Both combine **behavioral signals (Google Trends)** with **macroeconomic indicators**.
- Both apply **lag structures** to model temporal effects.
- You also use **nonlinear models (e.g., XGBoost, CNN)** and aim for **walk-forward validation**.

What's different / your added value:

- You focus on **national-level EV sales**, not brand-level disaggregation.
- Your time range is longer: **2007–2025**, which may better capture **long-term policy effects** (e.g., bijtelling changes, subsidies).
- You explore **general behavioral intent** (e.g., search terms like “elektrisch rijden”) rather than only brand-model-specific queries. This may capture **early-stage public interest**, though it risks lower precision.
- You **exclude sentiment scores**, but highlight **policy signals** like subsidy announcements and aim to link sales spikes to them.
- Their dataset is **U.S.-based** and heavily dependent on scraped product specs and model-specific trends, whereas yours aims to integrate **Dutch government data and climate policy context**.

Key Findings

- The hybrid model outperforms LSTM and ConvLSTM (MAE ~3.5% on average).
- Top influential factors vary per car, but CPI, MPG, price, and Google search volume were often important.
- The model performed best in predicting EV *share* within each market segment.

Critical Notes

- Uses brand- and model-specific data and keywords (e.g., "Tesla Model S"), not general EV terms.
- Google Trends is applied per model, with 3 different search phrase formats.

- Sentiment from news is aggregated by vehicle model using VADER, not embedding-based matching.
- No focus on policy signals like *bijtelling* or Dutch tax structure.

Stick with XGBoost and CNN as your core methods, since they balance accuracy and interpretability

Optionally test a baseline LSTM with simple architecture to show you've considered temporal deep learning — then explain why it was less suitable in your context (e.g., interpretability, dataset size, training stability)

7.13.1.6 Google Trends as a Complementary Tool for New Car Sales Forecasting: A Cross-Country Comparison along the Customer Journey. (A. Google Trends as Complementary Tool for New Car Sales Forecasting A Cross-Country Comparison along the Customer Journey, n.d.)

Data sources:

- Monthly car sales data (from *Automobilwoche Data Centre*) for Germany and the U.S. for 24 car models over a 39-month period (2013–2016).
- Google Trends data was downloaded using **exact car model names** (e.g., “Audi Q7”) as keywords. Filters were applied for country, time window, and category (“Automotive & Vehicles”) to improve signal quality.

Preprocessing:

- The Google Trends index was **averaged from two extraction days** to reduce sampling noise.
- Noise from second-hand searches was *unsuccessfully* filtered out (attempts to exclude “used” or “second hand” via keyword modifiers failed due to Google’s minimum search volume threshold).

Lag analysis:

- A **cross-correlation function (CCF)** was applied to determine the optimal time lag between search interest and actual sales. The lags varied:
 - On average: 2.96 months (low-priced cars), 3.41 months (high-priced).
 - For Audi Q7: 6-month lag gave the highest explanatory power.
- After applying the lag, **R² improved significantly** (e.g., from ~22% to 68.5% for Audi Q7).

Modeling approach:

- **Linear regression models** were used, comparing:
 - Raw vs. lag-adjusted data.
 - U.S. vs. German market.
- Significance was tested with 95% confidence, and **prediction quality was assessed via R² and MAE**.

Reliability

Kinski explains that **reliability** refers to the *consistency* of measurement — whether the use of a particular method produces stable results across repetitions. He references Choi & Varian (2009), who advocate for publishing reproducible methods, and Baker & Fradkin (2013), who improved reliability by averaging data over four different weeks to reduce internet noise. Kinski applies a **Cronbach's alpha test** on 30 time series variables (car models), which yielded a value of **0.79** — above the accepted threshold of 0.70, thus confirming high internal consistency.

Validity

For **validity**, Kinski distinguishes between:

- **Face validity:** ensuring keywords seem logically related to what is being measured.
- **Content validity:** checking whether all relevant dimensions of the concept (e.g., car interest) are captured.
- **Criterion-related validity:** linking trends to actual outcomes (like sales).
He supports this by following **Stephens-Davidowitz & Varian's** (2014) guidelines on category selection (e.g., restricting to “Automobile and Vehicles”) and geographical filtering to avoid noise. He also highlights the importance of **keyword selection**, which Zhu et al. (2012) deemed essential for meaningful analysis.

Summary and Relevance to Your Thesis

Kinski's approach shows that **Google Trends can be reliable and valid** if:

- Keywords are carefully selected.
- Categories and countries are restricted to reduce noise.
- Data smoothing (averaging over multiple queries) is considered.
- Internal consistency is statistically tested.

For your thesis, this justifies your use of *Google Trends* if you transparently describe:

1. Your keyword selection process.
2. Your category and country filters.
3. Any averaging or rescaling method to account for weekly volatility.
4. Optional: perform a Cronbach's alpha test or similar reliability assessment.

What Kinski did:

- Used **brand- and model-specific keywords**, short time span (2013–2016), **basic linear regression**, and did not include macroeconomic factors or broader behavioral signals.

What you are doing differently:

- Focus on **general EV-related terms** (e.g., “laadpaal,” “elektrisch rijden”), not brand-specific.
- Longer time horizon (2007–2025), including **policy variables**, macroeconomic indicators (fuel prices, consumer confidence), and **walk-forward validation**.

- You use **nonlinear models** (e.g., XGBoost, CNN), offering a more flexible and modern approach to modeling.

7.13.1.7 Using forum and search data for sales prediction of high-involvement projects(Tel Aviv University et al., 2017)

Title: Using Forum and Search Data for Sales Prediction of High-Involvement Projects

Context: Predicting car sales using a combination of Google search trend data and forum data.

Main Research Questions

1. Can combining search trends and forum data improve car sales predictions?
2. Is search data sufficient to outperform social media (forum) data?
3. Does this vary between **premium** and **value** brands?

Methodology & Data

- **Industry:** U.S. automotive market.
- **Time period:** Monthly data from 2007–2010.
- **Brands:** 23 car brands, sales volume above 5,000/month.
- **Data sources:**
 - **Sales data:** Automotive News.
 - **Forum data:** Google's index of online discussion forums.
 - Includes **volume** and **sentiment** (dictionary-based).
 - **Search data:** Google Trends (brand-level keywords).
 - **Control variables:** Seasonality (sales lag 12), gasoline prices, consumer sentiment.

Models:

- Benchmark model (sales history, macro indicators).
- Forum-only, search-only, and combined models.
- Evaluated with Linear Regression and validated using **rolling window** forecasting (out-of-sample MAPE).

Key Findings

- **Combined model** (search + forum) outperforms all others in prediction accuracy.
- **Search-only** models perform similarly to forum-based models, despite being cheaper and less biased.
- **Value brands** benefit more from adding search trends than **premium brands**.

- Biases in forum data (manipulation, visibility, self-presentation) are partly mitigated by search data, which reflects private intent.

Relevance to Your Thesis

- Confirms that **Google Trends** is a powerful and *less biased* proxy for consumer interest—especially important since you dropped sentiment/news analysis.
- Reinforces that **search logs reflect latent intent**, aligning with your use of Trends for behavioral signal modeling in the Dutch EV market.
- Their use of **brand-level keywords** (not models) and normalization of Trends data parallels your approach.
- Your thesis extends this by including **policy signals**, longer timeframes (2007–2025), and **macroeconomic variables** like fuel price and consumer confidence.

Gap Your Thesis Covers

- While Geva et al. used **U.S. premium vs. value brand forecasting**, you:
 - Focus on **national EV-level sales** (not brand-specific).
 - Include **policy shifts** like subsidies and “bijtelling”.
 - Extend the **temporal window** to track long-term behavioral shifts and policy impact.
 - Compare **XGBoost and CNN**, offering nonlinear interpretability beyond linear regression

7.14 10/05

Schrijf een eerste ruwe versie van je **inleiding** met duidelijke probleemstelling, relevantie en onderzoeksvragen.

- hesisstructuur opgesteld en vertaald naar LaTeX (inclusief hoofdstukken voor Introduction, Methodology, Data, Models, etc.).
- Methodesectie herschreven met onderbouwing van modelkeuze (XGBoost vs. CNN) en evaluatiestrategie (walk-forward, MAE/MAPE).
- Keuze voor Google Trends boven NOS-nieuwssentiment onderbouwd aan de hand van feedback en reproduceerbaarheid.
- Lagstructuren onderzocht op basis van literatuur en toegepast op gedragssignalen (1–2 maanden) en beleidsreacties (0–1 maand).
- Titeloptyes en definitie van gedragsfactoren uitgewerkt.

Leeruitkomsten (gericht op afstudeereisen):

- **A1:** Probleem in context geplaatst en scope aangescherpt.
- **A2:** Oplossingsrichting via AI-methoden verder uitgewerkt.
- **A5:** Reflectie op geschiktheid van AI-modellen en waarom gedragssignalen relevant zijn.
- **C1:** Maatschappelijke impact besproken via beleidsmomenten.
- **D1:** Feedback uit eerdere sessies verwerkt in herpositionering van het onderzoek.

7.14.1.1 Vragen die ik niet kon beantwoorden tijdens het schrijven:

- Wie wordt target audience?
 - o als ik Policy makes doe, moet ik meer focussen op Klimaat en wss subsidie
 - Ook is het lastiger om model te vergelijken met hun model
 - o Voor autofabrikanten moet ik minder focussen op klimaat, misschien zelfs helemaal weg gaan

Wat zou goede tussenweg zijn?

De redenen voor elektrische auto

Weakness:

Veel studies gebruiken daadwerkelijke autotermen omdat mensen die opzoeken als ze auto kopen, ze zoeken geen specifieke modellen op:

Oplossing:

Acknowledging this trade-off:

“While search behavior around specific vehicle models may more directly reflect imminent purchasing intent, this thesis focuses on general EV-related terms to capture broader public interest and early-stage engagement with electric mobility.”

Framing your work as **market climate modeling**, not buyer modeling.

7.14.1.2 Target audience:

Rijksoverheid: dashboard mobiliteit personen en auto's

https://www.pbl.nl/modellen?f%5B0%5D=publication_topic%3A12

info over dashboard:

<https://dashboardklimaatbeleid.nl/content/overditdashboard>

info over modellen:

https://www.pbl.nl/modellen?f%5B0%5D=publication_topic%3A12

misschien toch wel gewoon car manufactures doen en zeggen dat zij uiteindelijk zelf hun eigen automerken kunnen toevoegen.

7.14.1.3 Skelet van mijn rapport: (nu nog van visser * A leerdoelen toevoegen)

1. Introduction

- a. Background
- b. Problem
- c. Existing work
- d. Gap
- e. Scope of the research

2. Requirements

- a. Functional requirements
- b. Ethical requirements

3. Dataset

- a. Social media platform
- b. Approach
- c. Dataset 1 – sentiment (X)
- d. Dataset 2 – factual or opinion (FEVER)
- e. Dataset 3 – stock price (Yahoo Finance)

4. Models

- a. Methodology
- b. **Dataset 1 (X) preprocessing**

- i. Distribution and splitting the data
 - ii. Duplicates and missing values
 - iii. Text cleaning
 - c. Model 1: Tweet sentiment classifier
 - d. **Dataset 2 (FEVER) preprocessing**
 - i. Removing duplicates
 - ii. Handling missing values
 - iii. Filtering labels
 - iv. Balancing the dataset
 - v. Label mapping for binary classification
 - vi. Shuffling the data
 - vii. Splitting the data
 - viii. Training and validation split
 - e. Model 2: Factual or opinion classifier
 - i. Null model
 - ii. Baseline Model
 - iii. Rule-based component
 - iv. Motivation for model selection
 - v. Evaluation Metrics
 - vi. Architecture

5. Hardware

- a. Qualitative analysis of FEVER dataset applicability to tweets

6. Results

a. Models

- i. Qualitative analysis of labeled fact / opinion

b. Putting it all together & exploring the Correlation

- i. Quantitative analysis of correlation
- ii. TSLA Stock Price vs. Sentiment
- iii. TSLA stock price vs. sentiment with 21-day moving average (MA)
- iv. TSLA stock price vs. sentiment with 21-day MA filtered on factual tweets

c. Validating comparability and compatibility

- i. Motivation
 - ii. Results
 - iii. Analysis of results
- d. **Conclusion**
- e. **Discussion**
 - i. Limitations
 - ii. Future Work

Dataset/bron gevonden over internettoegang en internet activiteiten in nederland:

7.14.1.4 *Internetgebruik en online activiteiten (CBS-tabel, 2024)*

(Centraal Bureau voor de Statistiek, 2024)

Datum ingevoerd: 10 mei 2025

Bron: Centraal Bureau voor de Statistiek (CBS), *Internet; toegang, gebruik en faciliteiten*

Omschrijving:

Vandaag heb ik de meest recente CBS-tabel over internetaankopen en internetgebruik (gepubliceerd op 3 september 2024) geraadpleegd. Deze tabel bevat definitieve cijfers vanaf 2020 en is uitgesplitst naar persoonskenmerken zoals geslacht, leeftijd, opleidingsniveau, inkomensgroep en stedelijkheid. De gegevens zijn relevant als context voor gedragsmatige indicatoren zoals zoek- en surfgedrag in relatie tot thema's als digitale koopintentie en publieke interesse in elektrische voertuigen.

De tabel omvat:

- Internettoegang thuis en frequentie van gebruik
- Activiteiten in de afgelopen 3 maanden, onderverdeeld in:
 - **Communicatie** (e-mail, sociale netwerken, WhatsApp)
 - **Informatie en vermaak** (nieuws, gezondheidsinformatie, streaming)
 - **Dienstverlening** (bankieren, verkopen, overheidsinformatie)

Deze informatie kan ondersteunend zijn bij het interpreteren van zoek trends (bijv. via Google Trends) en bij het afleiden van gedragsindicatoren in modellen die consumentengedrag of productinteresse voorspellen.

Belangrijk detail: Cijfers zijn afgerond op 1 decimaal en jaarlijks beschikbaar in november.

<https://opendata.cbs.nl/StatLine/#/CBS/nl/dataset/84888NED/table?ts=1746869151665>

7.15 09/05

Werk Daphne's feedback uit in je methodesectie en update de uitleg over lagstructuur + walk-forward validatie.

Na gesprek met Daphne nog gehad om geen pieken weg te halen, evt wel om MAE voor de piek te berekenen nos. Ook bespreken we het opdelen van

Voorbereiding overleg Daphne:

Unieke bijdrage t.o.v. bestaande literatuur:

Mijn onderzoek richt zich uitsluitend op elektrische auto's (EV's) binnen de Nederlandse markt, terwijl veel bestaande studies zoals die van Wijnhoven & Plant (Wijnhoven & Plant, 2017), (Afandizadeh et al., 2023) en (Sayedi, 2020) brede autosegmenten en landen vergelijken. In tegenstelling tot hun gebruik van lineaire modellen of regressies, zal ik nonlineaire modellen vergelijken zoals xgboost en cnn om met als doel de complexere patronen te herkennen. Ik gebruik een lange tijdsreeks van 2007–2025, wat afwijkt van veel studies die zich op kortere perioden richten (zoals 2014–2020 bij Afandizadeh et al. Of in de buurt van 2011–2015 bij Zhang).

Een belangrijk verschil is dat ik mij niet richt op individuele automerken of -modellen, zoals veel van de bovenstaande papers wel doen, maar werk met algemene gedragsindicatoren zoals zoekinteresse in "elektrisch rijden" of "laadpaal". Vanwege de brede scope in data voeg ik ook verklarende variabelen toe zoals brandstofprijzen, consumentenvertrouwen en economisch klimaat, die vaak ontbreken in bestaande studies. Deze variabelen sluiten aan bij verschillende fasen van het Attention, Interest, Desire, Action (AIDA)-model: zo weerspiegelen consumentenvertrouwen, Google Trends-zoekgedrag en het economisch klimaat vooral de interessefase ("Interest"), terwijl brandstofprijzen een directe invloed kunnen hebben op het verlangen naar elektrische voertuigen ("Desire")

Daarnaast wil ik een mogelijk probleem van Google Trends normalisatie (0–100 schaling) oplossen door de zoektermen over overlappende segmenten te herschalen, zodat tijdsvergelijking betrouwbaarder wordt.

Ik gebruik een walk-forward validatie methode met lags, zodat mijn voorspellingen alleen gebaseerd zijn op informatie die op dat moment bekend was.

Dit verhoogt de realisme en toepasbaarheid voor beleid. Ten slotte probeer ik de relatie tussen beleid (zoals bijtelling) en verkoop te koppelen aan pieken in de data, iets wat nauwelijks terugkomt in bestaande Google Trends-literatuur.

Tijdens meeting bragen gesteld over de piek momenten, en lagtime

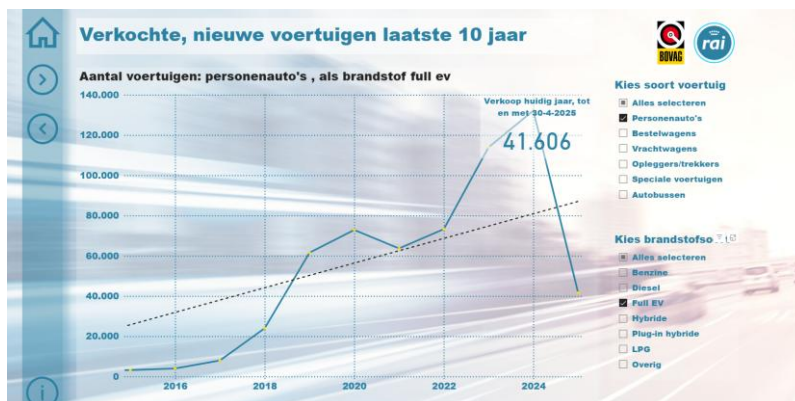
7.16 08/05

7.16.1 Literatuuronderzoek:

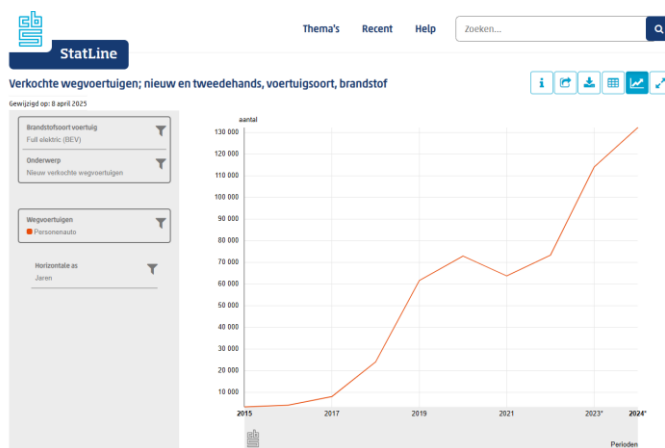
7.16.1.1 Vergelijking met Wijnhoven & Plant (2017) – Sentiment & Google Trends voor EV-voorspellingen

Brongegevens:

- **Onderzoek:** Wijnhoven & Plant (2017) – Sentiment Analysis and Google Trends Data for Predicting Car Sales
- **Databronnen gebruikt in artikel:** Google Trends per automodel, verkoopcijfers per model (via [BOVAG](#), link inmiddels 404).



- **Mijn bron:** Google Trends op algemene EV-gerelateerde zoektermen (zoals "elektrische auto"), verkoopcijfers van het [CBS](#) per maand (totaal aantal EV's)



Belangrijkste inzichten uit het artikel

- **Modellering:** zij gebruiken M5P decision trees met lineaire modellen in de knopen; ik gebruik XGBoost (gradient boosting) met walk-forward validatie.
- **Lag-analyse:** ze berekenen voor elk automodel de optimale tijdsvertraging (lag) met cross-correlatie (SPSS), tot maximaal 12 maanden.
- **Resultaten:** MAE varieerde per model, maar exacte gemiddelden zijn niet transparant vermeld. Wel werden bijv. correlaties > 0.5 als significant gepresenteerd.
- **Gebruik Google Trends:** per automodel; bijvoorbeeld "Volkswagen Passat" of "Ford Fiesta".

Aspect	Wijnhoven & Plant (2017)	Mijn benadering
Modeltype	M5P Decision Trees	XGBoost (met boosting op residuen)/ kan wijzigen naar CNN
Voorspellingseenheid	Per automodel (11)	Totaal aantal verkochte EV's (geaggregeerd)
Google Trends	Specifieke modellen als zoekterm	Algemene zoektermen ("elektrische auto", enz.)
Lag-analyse	Lag bepaald per model m.b.v. crosscorrelatie	(Nog) niet toegepast, dynamische walk-forward
Validatie	66% train / 33% test (klassieke split) 52 maanden	Walk-forward (tijdreeksgevoelig) (80/20) 219 maanden
Multicollineariteit	Getest via VIF (Variance Inflation Factor)	Niet toegepast, maar mogelijk relevant
Tools	Weka (GUI)	Python + scikit-learn, pandas, matplotlib

Suggesties voor uitbreiding

1. **Voer cross-correlatie uit tussen Google Trends en verkoop met lags van -12 tot +12 maanden.** Bekijk bij welke vertraging de correlatie het hoogst is.
2. **Bereken VIF voor je huidige featureset**, om te controleren op multicollineariteit. Dit kan met `statsmodels.stats.outliers_influence.variance_inflation_factor`.
3. **Overweeg om consumentenvertrouwen toe te voegen**
4. **Toets je model op nieuwe EV-subcategorieën** zoals plug-in hybrides of EV's per merk (indien data beschikbaar is).

7.16.1.2 **Doel:** Onderzoeken hoe Google Trends effectief ingezet kan worden bij het analyseren van consumentengedrag en het verbeteren van verkoopvoorspellingen van elektrische voertuigen (EV's).

1. Analyse van bestaande literatuur

- Bestudeer eerder onderzoek waarin Google Trends is gebruikt binnen de context van elektrische voertuigen of consumentengedrag.
- Let hierbij op de gebruikte zoektermen in deze studies. Voorbeelden zijn:
 - *Electric Vehicles*
 - *Alternative Fuel Vehicles*
 - *Plug-in Hybrid Electric Vehicles*
 - *Battery Electric Vehicles*
 - *Green Cars, Eco-cars, Cleaner Vehicles*
 - En gedragsgerelateerde termen zoals *acceptance*, *consumer adoption*, *attitude*, *intention*, en *behavior*
(Zie bijvoorbeeld: [ScienceDirect-artikel](#)).

2. Verrijking van zoektermen

- Gebruik synoniemen en alternatieve bewoordingen uit bronnen zoals het woordenboek of thesauri om de dekking van relevante zoekopdrachten te vergroten.
- Denk aan varianten in spelling, afkortingen, of volksmondtermen.

3. Relevante aanbevelingen en inzichten uit Google Trends

- Raadpleeg praktische toepassingen van zoekgedrag, zoals weergegeven op platforms als [Think with Google](#), om inzicht te krijgen in mobiele zoekpatronen rondom EV's.
- Overweeg hoe zoekvolumedata vertaald kunnen worden naar marketing- en verkoopstrategieën.

4. Stakeholderinput meenemen

- Verzamel input van relevante belanghebbenden, zoals EV-verkopers of marketingexperts, om realistische en praktijkgerichte zoektermen te identificeren.

5. Wetenschappelijke onderbouwing van voorspellingswaarde

- Analyseer studies die de voorspellende waarde van Google Trends-gegevens op productniveau hebben onderzocht, zoals:
 - Fritsch et al., "Can Google Trends Improve Sales Forecasts on a Product Level?" ([ScienceDirect](#))
 - Publicaties op IEEE Xplore ([IEEE artikel](#))
 - Medisch-psychologische studies over consumentengedrag via PubMed ([PubMed studie](#))

7.17 07/05 Onderzoekplan herzien

Na de het gesprek met Marcio, heb ik mijn onderzoeksplan herzien. De aparte validatieset is verwijderd en vervangen door cross-validation. Zoals verwacht had dit weinig invloed op de prestaties van het model, maar het maakt de methode methodologisch sterker en beter verdedigbaar.

Vervolgens heb ik mijn strategie voor artikel/selectie van sentimentbronnen geëvalueerd. Het werd duidelijk dat het sentiment uit NOS Nieuws geen consistente of voorspellende waarde bood. Ook de selectie van EV gerelateerde artikelen voldeed niet aan de kwaliteitseisen. Mogelijk heb ik te veel tijd besteed aan het proberen te verbeteren van deze aanpak.

Mijn eerste alternatief was overstappen naar Twitter-sentiment, maar dat zou vergelijkbare problemen opleveren (zoals het correct filteren van irrelevante data en het beoordelen van de kwaliteit van de sentimentanalyse). Daarnaast heb ik tijdens literatuur onderzoek van pva over het hoofd gezien dat sentiment analyse weinig voorspellende waarden hebben voor autoverkoop.


In plaats daarvan heb ik me verder verdiept in onderzoek van **Fons Wijnhoven**, waarin onder andere wordt geconcludeerd dat:

“Google Trends scores correlated better with car sales and, in many cases, significantly.”

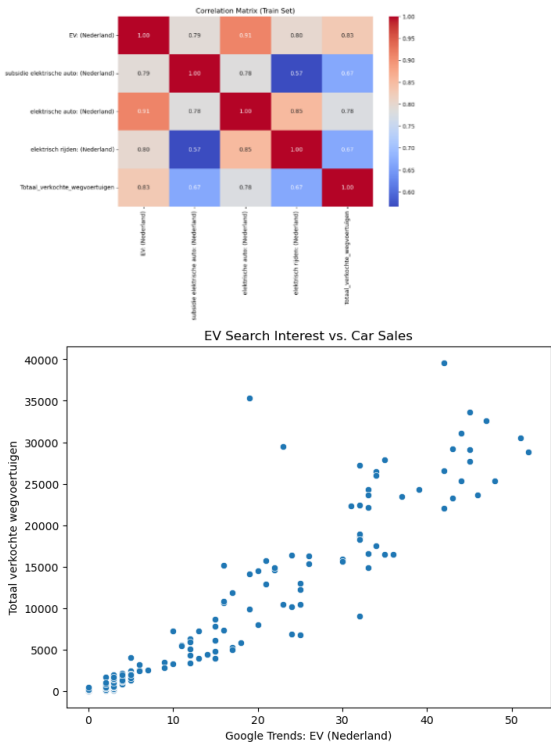
Deze bevinding gaf me het vertrouwen om voort te bouwen op zijn werk, met een specifieke focus op elektrische voertuigen (EV's) en een uitgebreidere dataset waar in het oorspronkelijke onderzoek 53 maanden werden gebruikt, maak ik nu gebruik van 216 maanden (2007–2025), in plaats van de 93 maanden uit mijn eerdere opzet met nieuwssentiment.

Ik voerde een verkennende analyse uit met algemene EV-gerelateerde zoektermen in Google Trends, waaronder:

- "EV"
- "subsidie elektrische auto"
- "elektrische auto"
- "elektrisch rijden"



Deze heb ik gekoppeld aan CBS-data over verkochte EV's. De correlatiematrix liet duidelijker verbanden zien.



Daarna heb ik een **XGBoost-model met cross-validation** toegepast om het voorspellen van EV-verkopen te testen. Zonder dat er al sprake was van vertraging (lag time) in de features, presteerde het model aanzienlijk beter:

Ook visueel sloot de voorspelde lijn beter aan bij de werkelijke cijfers, op enkele uitschieters na (die ik nog nader ga onderzoeken).

“Tot eind 2019 gold voor volledig elektrische auto's een bijtellingspercentage van 4% over de eerste €50.000 van de cataloguswaarde. Vanaf 1 januari 2020 werd dit percentage verhoogd naar 8%. Om te profiteren van het lagere tarief, besloten veel zakelijke rijders hun elektrische voertuigen nog in december 2019 op kenteken te zetten.” ([Business insider](#))


In 2020 werd de bijtelling voor elektrische auto's opnieuw verhoogd, ditmaal naar 12% vanaf 1 januari 2021. Wederom leidde dit tot een verkoopspiek in december 2020, aangezien zakelijke rijders probeerden te profiteren van het nog geldende lagere tarief. ([NOS](#))

“De grote stijging van het aantal BEV personenauto's in 2020 is voor een groot deel het gevolg van de grote verkoopaantallen in december 2020. Deze stijging in het wagenpark is vergelijkbaar met het stijgende patroon in 2019, die tevens grotendeels veroorzaakt is door de grote verkoopaantallen in december 2019.”


(Bron: RVO, Jaaranalyse 2020 – pagina 6)

“Zoals voorspeld in het jaaroverzicht 2019, wordt de BEV-verkooppiek in december 2019 gevolgd door een veel lagere verkoopomvang in de eerste maanden van 2020.”

(Bron: RVO, Jaaranalyse 2020 – pagina 12)



- **MAE (Google Trends): 3.661,21**



- **MAE (News Sentiment): 18.714,00**

Nog openstaande punten:

- **Selectiemethode voor zoektermen in Google Trends:**
Mogelijke strategie:
 - Clustering van algemene EV-termen
 - Aanvullen met termen uit eerdere literatuur
 - Synoniemen uit woordenboeken of thesauri
 - Google Trends-aanbevelingen

- Stakeholderinput, bijvoorbeeld van EV-verkopers
 - Doel: subjectieve keuzes onderbouwen met objectieve argumenten
- **Afstemming van afbakening en bijdrage:**
Controleren of de focus op Nederlandse EV-verkoop en een grotere dataset (2007–2025) inhoudelijk sterk genoeg is en voldoende wetenschappelijke waarde toevoegt.

Compared thesis with visser:

Leerdoel	Opmerkingen
A1. Probleem in context + belanghebbenden	De context (social media sentiment vs. markt) is sterk uitgewerkt, maar het perspectief van eindgebruikers of opdrachtgevers ontbreekt grotendeels.
A2. Verkenning oplossingsrichtingen + AI-ontwerp	Er wordt gewerkt met FinBERT, Random Forest, CNN en regelgebaseerde modellen. Alternatieven zijn onderbouwd.
A3. Designkwaliteit (gebruiksvriendelijk, waarde)	De afweging van modelkeuze wordt gedaan (bijv. FastText i.p.v. BERT), maar gebruiksvriendelijkheid of toegevoegde waarde voor stakeholders komt weinig terug.
A4. Prototype testen in context	Er is geen concrete gebruikerstest of toepassing van het prototype in een realistische setting beschreven.
A5. Is AI geschikt? Technisch, maatschappelijk, ethisch	In de ethieksectie en discussie worden privacy, bias en toepasbaarheid besproken.
C1. Evalueren maatschappelijke impact, dialoog vakgenoten	Er is reflectie op impact (bijv. bots, TSM vs. TSLA), maar geen interactie met vakgenoten of interviews.
D1. Feedback verwerken en ontwikkeling tonen	Niet zichtbaar in het document zelf; mogelijk elders (Logboek, feedbackmomenten) wel aanwezig.

7.17.1 Meeting met Marcio

7.17.2 Belangrijkste feedbackpunten

De thesis voldoet momenteel niet aan de eisen voor de 70%-beoordeling. Drie hoofdproblemen:

- Scope is te breed
- Richting van het onderzoek is niet scherp genoeg
- Probleemstelling mist focus

Bespreking leeruitkomsten A (met input van labbegeleider Kees)

A1: . Je doet onderzoek om het probleem in context in kaart te brengen, herformuleert het vraagstuk, weegt en toetst de belangen van de opdrachtgever, eindgebruiker en andere belanghebbenden. → **Verwacht in rapport. Focus op één doelgroep: verkopers of gemeenteambtenaren.**

A2: . Je verkent en analyseert de oplossingsrichtingen voor een vraagstuk en ontwerpt een AI-oplossing volgens een gangbare ontwerpmethodiek. → **Moet duidelijk uitgewerkt zijn in de thesis.**

A3. Je beschrijft de kwaliteit van het ontwerp door te verwijzen naar design patterns en te kijken naar aspecten als haalbaarheid, gebruiksvriendelijkheid en de toegevoegde waarde die de oplossing kan bieden aan stakeholders.

& A4. Je ontwikkelt een prototype en test deze in de context waarin de oplossing gebruikt gaat worden. → **Prototype blijft beperkt; benoem dit expliciet als buiten scope in een discussieparagraaf. Voeg eventueel een schets toe van hoe het prototype eruit zou kunnen zien.**

A5: 5. Je onderbouwt voor de opdrachtgever of AI wel of niet geschikt is voor een gegeven vraagstuk, gelet op technische, maatschappelijk en ethische aspecten. → **Onderbouwen waarom AI gebruikt wordt. Waarom geen standaard statistiek?**

C1: Maatschappelijke impact & dialoog vakgenoten → Complex onderdeel. Gebruik eventueel hypothetisch scenario.

Analyse deelonderwerpen

1. NOS-artikelselectie (EV-gerelateerd):

- Keyword search is zwak: Niet reproduceerbaar, onduidelijke motivatie voor woordkeuze. Geen literatuurbasis.
- Query prompt is subjectief: Gebaseerd op eigen inzicht, niet onderbouwd.
- Verbeteropties: Artikelen selecteren via scatter plot met hoge semantische overeenkomst.
 - Vraag: Waarop is de scatter plot gebaseerd als query ook subjectief is?

2. XGBoost-voorspelling:

- Model presteert redelijk in mei/juni, maar faalt in juli/februari.
- Belangrijke fout: gebruik van unieke tijdsindex → aanpassen naar maandnummer (01–12).
- Februari heeft structureel lage verkoop. Interpolatie consumentenvertrouwen is acceptabel. Overweeg cross-validatie i.v.m. kleine dataset.

Algemene problemen in het onderzoek

- Hypothese lijkt weerlegd: zwakke correlatie tussen NOS-nieuws en EV-verkoop.
- Belangrijkste zwakke punten: probleem is te breed, dataset te klein, keyword selection werkt niet goed.
- Mogelijke interessante variabelen: advertenties, laadpalen – moeilijk te verkrijgen.

Actiepunten voor deze week

- Probeer Twitter-dataset gericht op EV's.
- Verwijder tijdsvariabele en vervang door maandnummer (01–12).
- Run opnieuw met alleen NOS-data.
- Bereid nieuwe meeting volgende week voor met resultaten.

Toekomstige ideeën en 'thinking out loud'

- Handmatige subsidiedata toevoegen (gemiddelde per jaar?).
- EV-verkoop uitbreiden tot 2007.
- Combineer sentiment + Google Trends specifiek voor EV's.
- Oudere studie toont zwakke sentimentvoorspelling, maar sterke volume-effecten.
- EV-markt is veranderd → nieuwe studie kan relevant zijn.
- Vergelijk eventueel met niet-EV auto's.

7.18 06/05

Logboeknotitie – Reflectie op voortgang en expertfeedback)

1. Bespreking met Prof. dr. C.A.G.M. van Montfort

Tijdens de Thesis Supervision Call heb ik samen met prof. dr. C.A.G.M. van Montfort de voorspellingen van mijn XGBoost-model besproken. Opvallend hierbij was dat de voorspellingen systematisch onder de daadwerkelijke verkoopcijfers lagen, ondanks dat het model de trendbewegingen (pieken en dalen) redelijk accuraat volgt. Prof. Van Montfort suggereerde dat een verticale verschuiving van de voorspellingslijn al tot betere overlap met de werkelijke waarden zou leiden. Dit wijst mogelijk op een structurele bias in het model.

Daarnaast stelde ik voor om seizoensinvloeden te normaliseren. Prof. Van Montfort ontraadde dit in de huidige fase van het onderzoek. Wel wees hij op het ontbreken van tijdsvariabelen in het model, wat potentieel waardevolle verklarende kracht mist. Hiervoor gaf hij twee mogelijke benaderingen:

- **Tijd uitsluiten** en corrigeren voor langetermijntrends (complex en bewerkelijk).
- **Tijd meenemen als verklarende variabele**, bijvoorbeeld via:
 - een continue variabele zoals "aantal maanden sinds start";
 - dummyvariabelen per jaar (waarbij 1 jaar als referentie dient om multicollineariteit te vermijden).

Ook stelde hij dat het groeperen van jaren (bijv. "vroeg", "midden", "recent") overwogen kan worden indien er weinig verandering tussen individuele jaren is.

Verder bespraken we de mogelijkheid om een random train/test-split te overwegen i.p.v. een tijdsgebaseerde split, afhankelijk van het onderzoeksdoel.

Tot slot uitte ik mijn zorg over leerdoel A (ontwerp), omdat ik geen externe opdrachtgever heb. Prof. Van Montfort bevestigde dat dit geen probleem is en verwees naar de bestaande projectbeschrijving van M. Visser [1] als voldoende onderbouwing.

Samenvatting referentie [1]:

Visser onderzocht hoe social media sentiment van invloed kan zijn op beursfluctuaties. In zijn aanpak combineerde hij sentimentanalyse met tijdreeksen en experimenteerde hij met featureselectie. Zijn methodiek diende als inspiratiebron voor mijn LOFO-analyse.

2. Verbeteringen in de code en aanpak (met dr. Daphne)

Later die dag heb ik mijn code en aanpak besproken met dr. Daphne. Daarin kwamen we een aantal punten tegen:

- **Herziening embedding- en keywordfiltering:**
Ik heb eerst opnieuw een keywordfilter toegepast op NOS-artikelen, waarna ik Jina V3 embeddings heb berekend en similarityscores heb geanalyseerd. De histogram van similarityscores liet zien dat de meeste artikelen tussen 0.15 en 0.35 scoren. Artikelen met lage scores bleken inderdaad nauwelijks over elektrische voertuigen te gaan.

- **Afweging dekking vs. kwaliteit:**

Ik koos ervoor om een similaritydrempel van ≥ 0.29 te hanteren. Dit garandeerde voldoende artikeldekking per maand zonder relevante data te missen.

- **Sentimentanalyse herzien:**

RobBERT v2 gaf bijna uitsluitend hoge scores (0.9), dus ik heb alternatieven getest (TextBlob, Vader, etc.). TextBlob leverde het meest gevarieerde en interpreteerbare resultaat op. Deze sentimentscore heb ik vervolgens per maand geaggregeerd.

- **Feature engineering en modelverbetering:**

- Sentimentscore én tijdsindex zijn toegevoegd aan de dataset.
- Opmerking van Daphne: de lag-feature was initieel niet correct toegepast op het model. Dit heb ik hersteld door Totaal_verkochte_wegvoertuigen_lag1 correct als input mee te geven aan XGBoost.

3. Modelverbetering en evaluatie

Na deze verbeteringen is de MAE van het model significant gedaald tot **4662.99**. Ik heb vervolgens een Leave-One-Feature-Out (LOFO) analyse uitgevoerd op basis van walk-forward validatie. De resultaten tonen het belang van de tijds- en nieuwsfeatures:

Weggelaten featuregroep	MAE (walk-forward)	Gem. foutmarge (%)
Voorgaande verkoop (lag1)	3778.9	15.6%
Economisch sentiment	3804.6	15.4%
Brandstofprijzen	4365.7	17.8%
Nieuwsartikelen (sentiment)	5222.0	21.6%
Tijdsindex	5404.8	22.2%

Dit bevestigt dat zowel tijd, economisch sentiment als lagged verkoopcijfers sterke verklarende waarde hebben. Het uitsluiten van de tijdsindex resulteert in de hoogste MAE, wat aansluit bij het advies van Prof. Van Montfort.

7.18.1.1 Tabel met MAE van verschillende verkoop voorspellingen

Techniek / Model	Dataset / Context	MAE Resultaat	Opmerkingen
DGA-based NGBM (1,1) (Pei en Li, 2019)	Voorspelling EV-verkoop	< 300 voertuigen3	
Multiple Regression (Bitencourt et al., 2021)	Voorspelling EV-verkoop	Gerapporteerd	Specifiek resultaat niet gegeven, wel dat MAE is gebruikt voor evaluatie.
NGMB and PSO (Ding et al., 2021)	Voorspelling EV-verkoop	10071.274	

Sequence to Sequence (Yi et al., 2022)	Voorspelling EV-verkoop	4.71194	
OFDGPM (Liu vd., 2022)	Voorspelling EV-verkoop		Specifiek resultaat niet gegeven, wel dat MAE is gebruikt voor evaluatie.
BPNN, RNN, en LSTM (Ding et al., 2023)	Voorspelling EV-verkoop	159.475	Gebruikten online reviews, sentimentanalyse, en historische verkoopdata6.
Bi-LSTM, ISOMAP, LLE, en PCA (Liu et al., 2023)	Voorspelling EV-verkoop		Specifiek resultaat niet gegeven, wel dat MAE is gebruikt voor evaluatie.
Neural Networks, Bayesian linear regression, LightGBM (Yeh en Wang, 2023)	Voorspelling EV-verkoop		Specifiek resultaat niet gegeven, wel dat MAE is gebruikt voor evaluatie.
ARIMA, XGBoost, Random Forest, en LSTM (Kumar et al., 2024)	Voorspelling EV-verkoop (India, twee- en driewielers)		Specifiek resultaat niet gegeven, wel dat MAE is gebruikt voor evaluatie.
ARIMA en LSTM (Ning et al., 2024)	Voorspelling NEV (New Energy Vehicle) verkoop (China)		Gebruikten data tussen 2018 en 20238. Specifiek resultaat niet gegeven.
EVs-PredNet (Voorgesteld Model)	Voorspelling Vraag EV - BEV (Battery Electric Vehicle)	3.67059	LSTM- en CNN-gebaseerd model10....
EVs-PredNet (Voorgesteld Model)	Voorspelling Vraag EV - HEV (Hybrid Electric Vehicle)	4.13589	
EVs-PredNet (Voorgesteld Model)	Voorspelling Vraag EV - PHEV (Plug-in Hybrid Electric Vehicle)	1.38019	Laagste MAE voor specifieke EV-categorie9.
EVs-PredNet (Voorgesteld Model)	Voorspelling Vraag EV - ALL (Alle elektrische voertuigen samen)	2.05509...	Gebruikt Adam optimizer13. Hoogste R-Squared voor deze categorie9.
Decision Tree (DT)	Voorspelling Vraag EV - ALL (Traditionele ML-methode ter vergelijking)	2.942512	Vergeleken met EVs-PredNet12....

Linear Regression (LR)	Voorspelling Vraag EV - ALL (Traditionele ML-methode ter vergelijking)	2.521512	Meest succesvol van de ML-methoden voor ALL, BEV, HEV2.
Lasso-LR	Voorspelling Vraag EV - ALL (Traditionele ML-methode ter vergelijking)	2.800312	Vergeleken met EVs-PredNet12.
ElasticNet-LR	Voorspelling Vraag EV - ALL (Traditionele ML-methode ter vergelijking)	2.773712	Vergeleken met EVs-PredNet12.
Ridge-LR	Voorspelling Vraag EV - ALL (Traditionele ML-methode ter vergelijking)	2.611612	Vergeleken met EVs-PredNet12.
K-Nearest Neighbors (KNN)	Voorspelling Vraag EV - ALL (Traditionele ML-methode ter vergelijking)	2.850712	Vergeleken met EVs-PredNet12.
Support Vector Machines (SVM)	Voorspelling Vraag EV - ALL (Traditionele ML-methode ter vergelijking)	4.455712	Slechtste prestatie onder traditionele ML-methoden2.
AdaBoost Regression (ABR)	Voorspelling Vraag EV - ALL (Traditionele ML-methode ter vergelijking)	2.655912	Presteerde beter voor PHEV dan andere ML-methoden2.
Decision Tree regression (M5P classifier)	Voorspelling Autoverkoop Nederland (m.b.v. sentiment & Google Trends)	141.452615	Sentiment had weinig voorspellende kracht15.
Random Forest	Voorspelling Autoverkoop China - Benchmark Dataset	142.3116	Gebruikt Baidu Index, benzineprijs, CCI17.
Random Forest	Voorspelling Autoverkoop China - Benchmark + Autohome Dataset	35.3616	Inclusief Autohome data (views, reviews, scores, etc.)17.
Random Forest	Voorspelling Autoverkoop China -	122.8816	Inclusief Weibo data (mentions, sentiment

	Benchmark + Weibo Dataset		counts)17.
Random Forest	Voorspelling Autoverkoop China - Combined Dataset	45.0216	Combinatie van Benchmark, Autohome en Weibo data17.
XGBoost	Voorspelling Autoverkoop China - Benchmark Dataset	151.3516	Gebruikt Baidu Index, benzineprijs, CCI17.
XGBoost	Voorspelling Autoverkoop China - Benchmark + Autohome Dataset	37.8616	Beste prestatie in deze studie 16. Autohome data verbeterde nauwkeurigheid significant18.
XGBoost	Voorspelling Autoverkoop China - Benchmark + Weibo Dataset	125.5516	Inclusief Weibo data17.
XGBoost	Voorspelling Autoverkoop China - Combined Dataset	44.3416	Combinatie van Benchmark, Autohome en Weibo data17.
SVR	Voorspelling Autoverkoop China - Benchmark Dataset	239.9816	Gebruikt Baidu Index, benzineprijs, CCI17.
SVR	Voorspelling Autoverkoop China - Benchmark + Autohome Dataset	119.7316	Inclusief Autohome data17.
SVR	Voorspelling Autoverkoop China - Benchmark + Weibo Dataset	220.7816	Inclusief Weibo data17.
SVR	Voorspelling Autoverkoop China - Combined Dataset	103.4016	Combinatie van Benchmark, Autohome en Weibo data17.

7.18.2 Gesprek met labbegeleider Kees

Tijdens de Thesis Supervision Call hebben prof. dr. C.A.G.M. van Montfort en ik samen naar de voorspelde lijn van het model gekeken. Opvallend was dat de voorspellingen structureel lager liggen dan de daadwerkelijke verkoopcijfers, hoewel het model de pieken en dalen redelijk goed volgt. Prof. Van Montfort gaf aan dat, indien de voorspelde lijn verticaal zou worden verschoven, deze beter zou overlappen met de werkelijke waarden. Dit duidt mogelijk op een systematische fout of bias in het model.

Daarnaast heb ik het idee besproken om seizoensgebonden fluctuaties te normaliseren. Prof. Van Montfort was het hier niet mee eens en vond dit geen geschikte aanpak in het huidige stadium van het onderzoek.

Een belangrijk punt dat hij naar voren bracht, is dat ik tot nu toe de factor *tijd* niet als verklarende variabele heb meegenomen. Hij stelde hiervoor twee mogelijke benaderingen voor:

1. **Tijd uitsluiten:** de tijdscomponent volledig buiten beschouwing laten en in plaats daarvan de verkoopcijfers corrigeren voor langetermijntrends. Deze aanpak zou echter veel werk en ingrepen in de dataset vereisen.
2. **Tijd meenemen als verklarende variabele:**
 - o Via een continue variabele, zoals het aantal maanden sinds de start van de reeks.
 - o Of via **dummyvariabelen per jaar**. Dit houdt in dat per jaar een binaire variabele (0 of 1) wordt toegevoegd. Bij een dataset met 10 jaren zijn dan 9 dummyvariabelen nodig om multicollineariteit te vermijden (referentiecategorie).

Aangezien ik twee jaren gebruik voor validatie en test, zou ik in principe ook voor die jaren afzonderlijke dummy's moeten toevoegen. Prof. Van Montfort merkte op dat er in de eerste jaren mogelijk weinig verandering zat in de verkoopcijfers, waardoor de bijbehorende dummyvariabelen weinig onderscheidend vermogen hebben. Een alternatief is het groeperen van jaren in drie bredere categorieën, zoals vroege jaren, middenperiode en recente jaren.

Verder adviseerde hij om te overwegen om in plaats van een tijdsgebaseerde splitsing, juist een *random split* toe te passen voor het trainen en testen van het model, afhankelijk van het onderzoeksdoel.

Ten slotte heb ik mijn zorgen geuit over het behalen van leerdoel A (ontwerp), aangezien ik geen externe opdrachtgever heb. Prof. Van Montfort gaf aan dat dit in de beoordeling buiten beschouwing wordt gelaten wanneer een opdrachtgever niet van toepassing is. Het volstaat om dit kort te benoemen in het verslag. De eerder opgestelde projectbeschrijving door M. Visser [1] is in mijn geval voldoende. Ik zal dit morgen nog verifiëren met Marcio.

Tot slot werd benadrukt dat ik de gebruikte variabelen goed moet kunnen uitleggen. Door het toevoegen van tijds-dummy's zou ik mogelijk het aantal aggregaties van andere variabelen kunnen reduceren. Zo neem ik nu bijvoorbeeld meerdere aggregaties van brandstofprijzen mee (zoals minimum, maximum, gemiddelde, etc.), maar dat maakt de interpretatie lastig. Door dit terug te brengen tot één enkele aggregatie, zoals het maandgemiddelde, wordt het model eenvoudiger uitlegbaar.

Referentie

[1] M. Visser, *Analyzing the Influence of Social Media Sentiment on Stock Market Fluctuations: A Comprehensive Study*

7.19 05/05

Activiteit: Verkenning subsidieregelingen

Omschrijving:

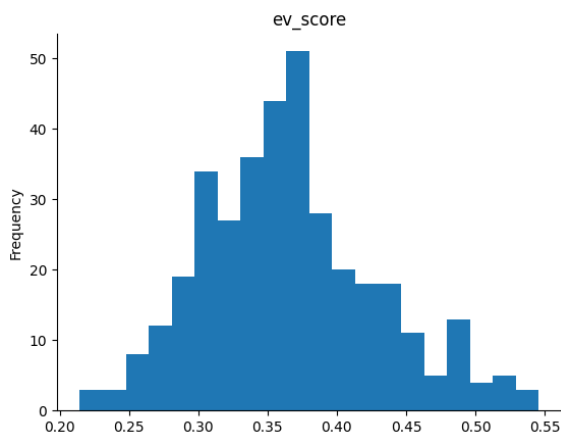
Vandaag onderzocht of maandelijkse data over SEPP-subsidies (Subsidie Elektrische Personenauto's Particulieren) beschikbaar zijn om als verklarende variabele toe te voegen aan het voorspellingsmodel voor EV-verkoop. Uit documentanalyse (Tussentijdse Evaluatie SEPP) blijkt dat de regeling pas in juli 2020 van start is gegaan en dat beschikbare cijfers voornamelijk op jaarbasis worden gerapporteerd. Maandelijkse cijfers zijn niet publiek beschikbaar, maar zouden mogelijk opgevraagd kunnen worden via de RVO. Alternatief overwogen om maandelijkse EV-registraties van het CBS te gebruiken als proxy voor subsidiegebruik, eventueel gecombineerd met jaarlijkse subsidiebedragen en lag-structuren.

7.19.1 Verkenning en filtering van nieuwsartikelen m.b.v. keywords en embedding

Vandaag heb ik nieuwsartikelen van NOS.nl gefilterd op basis van zowel **trefwoorden** als **semantische embedding scores**. Voor de trefwoordenfilter heb ik een uitgebreide lijst van meer dan 50 EV-gerelateerde termen gebruikt, waaronder "*elektrische auto*", "*laadpaal*", "*Tesla*", "*subsidie*", en "*verduurzaming vervoer*". Deze trefwoorden zijn bedoeld om zo veel mogelijk relevante artikelen rondom elektrische voertuigen (EV's) te selecteren:

```
ev_keywords = ["elektrische auto", "laadpaal", "Tesla", ..., "verduurzaming vervoer"]
```

Na het toepassen van deze filter heb ik aanvullend **embedding-gebaseerde filtering** toegepast (via Jina Embeddings + cosine similarity). Dit gaf mij een `ev_score` die aangeeft hoe sterk een artikel inhoudelijk lijkt op een EV-referentieartikel. De scores bleken normaal verdeeld, zoals zichtbaar in onderstaande histogram.




Wat viel op:

- Artikelen met de hoogste ev_score zijn allemaal inhoudelijk relevant (bijv. over subsidies, nieuwe EV-modellen, beleid).
- De artikelen met de laagste scores zijn totaal niet EV-gerelateerd. Enkele voorbeelden zijn:
 - Horeca rechtszaak tijdens corona
 - Vissersmoorden voor de kust van Suriname
 - Discussies over kerkdiensten en coronabeleid

Deze **negatieve voorbeelden** bevatten geen enkele relevante term uit de keyword-lijst. Dit bevestigt dat de embedding-filter effectief is, maar ook dat een minimum ev_score nodig is om off-topic artikelen uit te sluiten.

Clustering van artikelen (UMAP)



Op basis van de embeddings heb ik een **clusterwolk** (UMAP) geplot. Hierin zijn semantisch vergelijkbare artikelen bij elkaar gegroepeerd. Artikelen met hoge EV-similarity zijn geconcentreerd in bepaalde regio's van de plot. Dit suggereert dat een drempelwaarde (bijv. $ev_score > 0.35$) zou kunnen helpen om enkel relevante EV-artikelen te selecteren voor sentimentanalyse of tijdreeksvoorspelling.


Sentimentanalyse

Voor sentimentanalyse heb ik het RobBERT v2-model gebruikt via:

```
pipe = pipeline("text-classification", model="DTAI-KULeuven/robbert-v2-dutch-sentiment")
```

Dit model retourneert slechts 3 klassen (NEG, NEU, POS), en pogingen om dit naar een 5-puntsschaal te mappen leverden uitsluitend neutrale labels op. Daarom heb ik het originele 3-klassensysteem behouden, aangezien dit ook het best presterende model is volgens [de DBRD dataset benchmark](#).

De sentimentanalyse is succesvol uitgevoerd op de volledige dataset in Google Colab (i.v.m. performance). Per maand is de gemiddelde sentimentscore berekend en opgeslagen in een CSV-bestand (`average_sentiment_per_month.csv`) dat later gebruikt wordt voor XGBoost time-series analyse.



Observaties:

- De gemiddelde sentimentsscores per maand vertonen **beperkte variatie** (meestal tussen 0.91–0.96), wat de voorspellende kracht mogelijk onderdrukt.
- De correlatie tussen nieuws-sentiment en autoverkoop is dan ook **verwaarloosbaar** ($r = 0.04$).
- Daarentegen tonen andere variabelen sterke correlaties:
 - **Consumentenvertrouwen**: -0.76
 - **Economisch klimaat**: -0.78
 - **Brandstofprijzen (benzine/diesel)**: +0.65–0.67

Aanbevelingen:

- **Verbeter de filtering van nieuws**: Gebruik alleen artikelen met een hoge `ev_score` (bijv. > 0.35) en controleer op aanwezigheid van relevante keywords.
- **Voeg lag-variabelen toe**: Indicatoren zoals vertrouwen, brandstofprijs en sentiment kunnen pas na enkele maanden effect hebben op aankoopbeslissingen. Voeg vertragingen toe ($t-1$, $t-2$, etc.).
- **Vergelijk met een baseline**: Train ook een model zonder sentimentvariabele om de **toegevoegde waarde van nieuws** te evalueren.
- **Toekomstige filtering**: Overweeg het combineren van keyword-, embedding- én named entity filters (zoals merken of technologieën) om ruis verder te minimaliseren.

7.19.1.1 Modelontwikkeling & Evaluatie (XGBoost, RNN en LOFO-analyse)


Vandaag heb ik gewerkt aan de time series voorspelling van voertuigverkoop met XGBoost en RNN-modellen. Hiervoor heb ik een train-, validation- en testset opgezet, waarbij de laatste twee jaar (2023–2024) als validation- en testperiode zijn gebruikt. De validatieset zonder nieuwsinput werd als baseline gemeten:

- **XGBoost baseline (zonder nieuws): MAE = 7276.32 voertuigen**
- **RNN baseline (zonder nieuws): MAE = 8145.07 voertuigen**

De MAE (Mean Absolute Error) is gekozen als hoofdmaatstaf, conform de aanbevelingen uit het boek van François Chollet, *Deep Learning with Python*, 2nd Edition (ISBN: 9781617296864).


Vervolgens is de nieuwssentimentscore (afkomstig van het RobBERT-model) toegevoegd aan de feature set:

- **XGBoost mét nieuws: MAE = 6784.66**
- **RNN mét nieuws: MAE = 8114.22**



Dit suggereert een lichte verbetering door het toevoegen van de sentimentfeature in het geval van XGBoost.


De validatie-uitvoer liet zien dat het model moeite heeft met piekmaanden: met name juni, augustus en oktober worden structureel onderschat, terwijl december wordt overschat. Dit wijst mogelijk op seizoensinvloeden of exogene factoren die nog niet goed zijn opgenomen in het model. Zie de heatmap en lijnplots voor een visuele ondersteuning van de foutverdeling over de maanden.



LOFO-analyse (Leave One Feature-group Out)

Om de bijdrage van verschillende featuregroepen te evalueren, is een LOFO-analyse uitgevoerd. Per experiment is één categorie weggelaten, waarna opnieuw is getraind en geëvalueerd:

- **Zonder nieuws** → MAE: 7276.32
- **Zonder brandstofprijzen** → MAE: 7057.66
- **Zonder economische variabelen (vertrouwen/klimaat/koopbereidheid)** → MAE: 6795.25
- **Zonder historische verkoopdata** → MAE: 6784.66




Uit deze resultaten blijkt:

- Voorgaande verkoop is de meest voorspellende featuregroep.

- Economische variabelen zijn belangrijk, maar minder cruciaal dan historische verkoop.
- Nieuws heeft de minste impact; het verwijderen ervan verhoogt de MAE nauwelijks.

Correlatie en modeloverwegingen



De correlatiematrix bevestigt dit beeld:

- Brandstofprijzen correleren positief met verkoop ($r \approx 0.65$ – 0.67).
- Consumentenvertrouwen, economisch klimaat en koopbereidheid hebben een sterke negatieve correlatie ($r \approx -0.65$ tot -0.78).
- De nieuwssentimentscore heeft nauwelijks correlatie met voertuigverkoop ($r \approx 0.04$).

Dit duidt erop dat het nieuws (zoals gemeten met RobBERT) in de huidige vorm weinig informatie toevoegt. De oorzaak lijkt te liggen bij een beperkte variatie in sentiment scores, een mismatch tussen het type nieuws en consumentengedrag, en het ontbreken van een vertragingseffect (lag).

7.19.2 Aanbevelingen voor verdere verbetering van het model en de sentimentanalyse

Modeloptimalisatie

1. Voeg lag-variabelen toe

Introduceer vertraging (lag t-1, t-2) voor brandstofprijzen, consumentenvertrouwen en sentiment, om vertraagde effecten op verkoop te modelleren.

2. **Overweeg seizoenscomponenten expliciet te modelleren**

Voeg maand-dummy's of Fourier-features toe om seizoenspatronen te vangen (zoals pieken in zomer en december).

3. **Gebruik cross-validation met tijdseriestructuur**

Bijvoorbeeld TimeSeriesSplit voor robuustere prestatie-evaluatie.

Verbetering van sentimentinput

4. **Herfilter het nieuws op inhoudelijke relevantie**

Filter alleen op artikelen met daadwerkelijke economische, auto- of EV-gerelateerde inhoud — laat algemene nieuwsartikelen met lage similariteit weg.

5. **Gebruik EV-similarity scores in plaats van alleen keywords**

Experimenteer met een drempelwaarde op de ev_score (bijv. > 0.35) om irrelevante artikelen uit te sluiten.

6. **Kies voor een sentimentmodel met meerdere klassen**

RobBERT geeft vooral neutrale scores terug bij meer dan 3 klassen. Overweeg alternatieve modellen of fine-tuning op een domeinspecifieke dataset.

7. **Voer maandelijkse media-intensiteit mee als feature**

Tel het aantal EV-gerelateerde artikelen per maand als extra input, los van de sentimentwaarde.

Evaluatie & interpretatie

8. **Blijf een baseline zonder sentiment meenemen in evaluaties**

Zo kan per iteratie worden getoetst of sentiment daadwerkelijk waarde toevoegt.

9. **Analyseer foutmarges per maand**

Gebruik heatmaps en plots om systematische over- of onderschattingen te lokaliseren en gericht bij te sturen.

10. **Gebruik SHAP of feature importance-analyse**

Visualiseer welke features het meeste bijdragen aan voorspelling

7.19.2.1.1 Draft to do

Aan de xgboost kant heb ik een train test val set gemaakt, vanwege time series val en test laatste 2 jaar gedaan. Valset zonder nos is

MAE voor valset: 7276.32

Uiteindelijk gekozen als mea als maatstaaf omdat dit wordt aanbevolen uit het boek van cholet (citering toevoegen) ISBN: 9781617296864


Daarna ook gekeken naar rnn omdat dit wordt aanbevolen, verbaasend lager resultaat

RNN MAE voor valset: 8145.07

Vervolgens nos dataset toegevoegd, bovenste 2 uitkomsten kunnen gezien worden als baseline zonder nos.


Met nos zijn de uitkomsten het volgende MAE voor valset: 6784.66 en voor rnn
RNN MAE voor valset: 8114.22

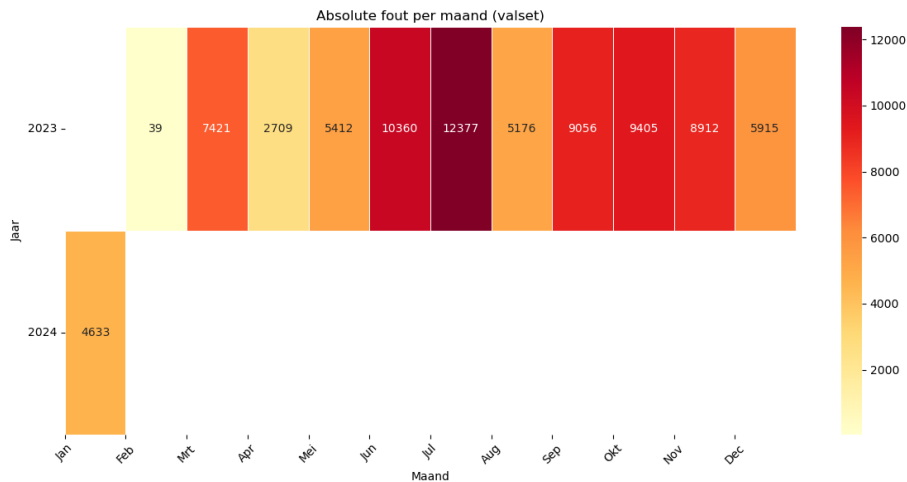
Correlatie is trouwens het volgende:



Het XGBoost-model is geëvalueerd op de validatieset (12 maanden). De gemiddelde absolute fout (MAE) bedraagt 7276 voertuigen. In de eerste maanden liggen de voorspellingen relatief dicht bij de werkelijke waarden (foutmarges rond de 3–15%), maar in het midden van het jaar loopt de foutmarge op tot ruim 40%. Het model onderschat structureel de verkoop tijdens piekmaanden, met name in juni, augustus en oktober. Enkel in december is sprake van overschatting. Deze resultaten wijzen op mogelijke seizoensinvloeden die het model momenteel niet goed opvangt.

Afbeldingen toene xgboost:





Daaran LofO leave one out toegeveogd, uitkomst was het volgende:

LOFO - Zonder: Nieuws

Gebruikte features (13): ['Consumentenvertrouwen', 'Economisch klimaat', 'Koopbereidheid', 'BenzineEuro95_1_first', 'BenzineEuro95_1_last', 'BenzineEuro95_1_min', 'BenzineEuro95_1_max', 'BenzineEuro95_1_mean', 'Diesel_2_first', 'Diesel_2_last', 'Diesel_2_min', 'Diesel_2_max', 'Diesel_2_mean']

MAE: 7276.32, Gemiddelde foutmarge: 29.88%

LOFO - Zonder: Brandstofprijzen

Gebruikte features (4): ['Consumentenvertrouwen', 'Economisch klimaat', 'Koopbereidheid', 'Average Sentiment Score']

MAE: 7057.66, Gemiddelde foutmarge: 29.25%

LOFO - Zonder: Economisch

Gebruikte features (11): ['BenzineEuro95_1_first', 'BenzineEuro95_1_last', 'BenzineEuro95_1_min', 'BenzineEuro95_1_max', 'BenzineEuro95_1_mean', 'Diesel_2_first', 'Diesel_2_last', 'Diesel_2_min', 'Diesel_2_max', 'Diesel_2_mean', 'Average Sentiment Score']


MAE: 6795.25, Gemiddelde foutmarge: 28.55%

LOFO - Zonder: Voorgaande_verkoop

Gebruikte features (14): ['Consumentenvertrouwen', 'Economisch klimaat', 'Koopbereidheid', 'BenzineEuro95_1_first', 'BenzineEuro95_1_last', 'BenzineEuro95_1_min',

'BenzineEuro95_1_max', 'BenzineEuro95_1_mean', 'Diesel_2_first', 'Diesel_2_last',
'Diesel_2_min', 'Diesel_2_max', 'Diesel_2_mean', 'Average Sentiment Score']

MAE: 6784.66, Gemiddelde foutmarge: 27.73%




Voor het voorspellen van autoverkoop zijn historische verkoopdata (voorgaande verkoop) de belangrijkste informatiebron, gevolgd door economische sentimenten. Brandstofprijzen dragen het minst bij aan modelnauwkeurigheid.

Vandaag Nos artikelen zowel gefilterd op keywords als embedding ik hebenorm veel keywords gebruikt en fdaana embedding gedana: ev_keywords = [

"elektrische auto", "elektrische voertuigen", "elektrisch rijden", "stekkerauto", "emissievrij",
"zero emission", "elektrisch vervoer", "battery electric vehicle", " BEV ", " EV", "EV-markt",
"laadpaal", "laadinfrastructuur", "laadstation", "snelladen", "laadtijd",
"laadnetwerk", "opladen", "elektriciteitsnet", "netcongestie",
"batterij", "accu", "actieradius", "solid state batterij", "energieopslag", "accutechnologie",
"Tesla", " BYD ", "Volkswagen ID", "Renault Zoe", "Hyundai Ioniq", "Kia EV",
"Nissan Leaf", "Polestar", "BMW i", "Ford Mustang Mach-E", "Audi e-tron",
"subsidie elektrische auto", "aanschafsubsidie", "bijtelling",
"fiscale stimulering", "milieu-investeringsaftrek", "overheidsbeleid", "klimaatmaatregelen",
"duurzame mobiliteit", "klimaatbeleid", "CO2-uitstoot", "groene transitie",
"verduurzaming vervoer", "energietransitie", "schoner verkeer",
"tweedehands elektrische auto", "EV import", "EV export", "restwaarde EV",
"autoverkoop EV", "EV occasion", "elektrisch leasen", "Subsidieregeling Elektrische
Personenauto's Particulieren"
]

Daarna embedding kunnen uitvoeren op collab, resultaat was het volgende zie afbeelding ev scores



Ook heb ik hiermee artikelen kunnen sorteren op similarity, paar artikelen met meeste en was ook benieuwd naar het minste similarity:
Top 10 Articles with the Lowest Similarity Scores:

Article 1821 similarity: -0.0576

Title: Horeca-ondernemer voor de rechter: 'Thuis meer risico op besmetting'

Description: In een kort geding eisen zeker 68 horecaondernemers onmiddellijke heropening van de horeca. De rechter doet vanmiddag uitspraak.

Content (snippet): Horeca-ondernemer voor de rechter: 'Thuis meer risico op besmetting' De rechtbank in Den Haag doet vanmiddag om 16.00 uur uitspraak in het door meerdere horecaondernemers aangespannen kort geding. De ...

URL: <https://nos.nl/artikel/2353064-horeca-ondernemer-voor-de-rechter-thuis-meer-risico-op-besmetting>

Article 915 similarity: -0.0287

Title: Na bloedbad op boot bij Suriname opnieuw visser gedood

Description: Vrijdagnacht zijn ook een aantal boten overvallen. Slechts vier van de twintig bemanningsleden overleefden het.

Content (snippet): Na bloedbad op boot bij Suriname opnieuw visser gedood Op de Atlantische oceaan is vannacht opnieuw een vissersboot overvallen voor de kust van Suriname. Daarbij is in ieder geval de kapitein om het l...

URL: <https://nos.nl/artikel/2230202-na-bloedbad-op-boot-bij-suriname-opnieuw-visser-gedood>

Article 1955 similarity: -0.0215

Title: Viroloog Koopmans: kerk op Urk speelt 'Russische roulette'

Description: De kerk wil de coronamaatregelen negeren en daarmee tegemoet komen aan de wens van gelovigen om weer ter kerke te kunnen gaan.

Content (snippet): Viroloog Koopmans: kerk op Urk speelt 'Russische roulette' Viroloog en OMT-lid Marion Koopmans vindt dat de Gereformeerde Gemeente Sionkerk op Urk "Russische roulette" speelt, door de coronamaatregelen...

URL: <https://nos.nl/artikel/2373944-viroloog-koopmans-kerk-op-urk-speelt-russische-roulette>

Article 910 similarity: -0.0195

Title: Woede en ongeloof over trage zoektocht na zeerovers-tragedie Suriname

Description: Het duurde meer dan een etmaal voordat er een schip van de kustwacht uitvoer om zestien vermiste vissers te zoeken.

Content (snippet): Woede en ongeloof over trage zoektocht na zeerovers-tragedie Suriname Kavita Tarnattie (28) staat op de steiger en staart uitdrukingsloos over het snelstromende bruine water van de Surinamerivier. Gi...

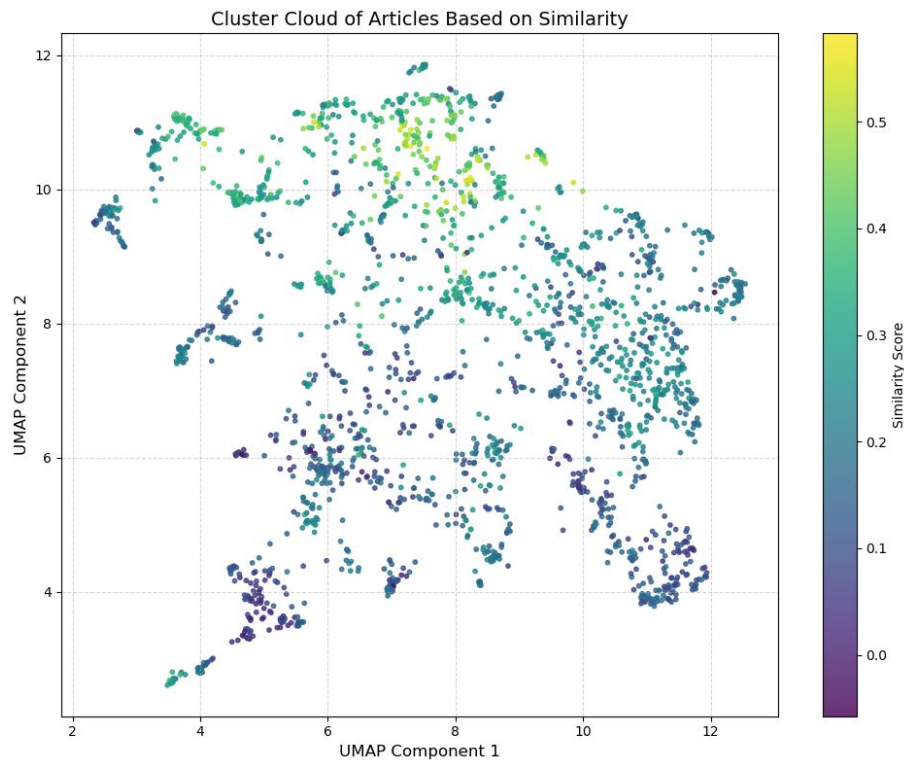
URL: <https://nos.nl/artikel/2230099-woede-en-ongeloof-over-trage-zoektocht-na-zeerovers-tragedie-suriname>

De top 10 lowest bevatten niet eens de keywords, daar moet nog naar gekeken worden.

De 10 avg en 10 hoogste similarity zijn wel allemaal artikelen die gaan over ev

Vervolgens wilde ik sentiment analyse uitvoeren, maar kreeg steeds het probleem dat ik maar 25 artikelen terug kreeg, ik heb dus data die ik heb aangemaakt naar keyword search gebruikt, dit werkte uiteindelijk wel, maar heb dus niet gedaan met de ev similarity.

Wel een cluster gemaakt




hier viel en volgende mee op...

Daarna sentiment analyse opgezet met `pipe = pipeline("text-classification", model="DTAI-KULeuven/robert-v2-dutch-sentiment")`


Enige nadeel is dat het niet werkte om meerdere classes toe te voegen wilde 5 toevoegen maar kreeg toen alleen neutraal, dus heb het op de og 3 gelaten

Want <https://huggingface.co/datasets/benjaminvdb/dbrd> blijkt het best te presteren (voeg toe op welk punt en schrijf ok over andere). Die sentiement heb ik gedraaid op de collab met volgende uitkomst

:



Vervolgens heb ik gemiddelde sentiment per maand getoont en in een dataset gezet:



7.20 2/05

Eind van de dag todo list afgaan om te checken of alles erin staat

Onderzoeken hoe ik de artikelen op een andere manier kan selecteren, embedding is te heftig, anders

Model selectie ltoelichten

Voor stakeholders:

Onderzoeken wat current work is dus hoe autofabrikanten verkoop van auto;s nu predicten:

<https://www.indeed.com/career-advice/career-development/formula-for-sales-forecast>

EVT gewoon een dashboardaken voor de prediction:

<https://www.figma.com/community/file/1238189616000926360>

lees intereassant info over <https://medium.com/data-science/text-embeddings-comprehensive-guide-afd97fce8fb5> embedding

7.20.1 Idee generatie: waarde propositie:

7.20.1.1 Hoe je de afstudeeronderdelen toepast op jouw scriptie:

7.20.1.1.1 Prototype

7.20.1.1.2 Idee & Waardepropositie

Wat is het nut van mijn systeem?

- Mijn model biedt inzicht in hoe publieke berichtgeving invloed kan hebben op koopgedrag in de EV-markt.
- Stakeholders: beleidsmakers, autobedrijven, duurzaamheidsexperts → zij kunnen hiermee sneller reageren op publieke opinie.

7.20.1.1.3 Flow Diagram & AI Breakdown

Laat zien hoe mijn systeem werkt in stappen.

- Maak een **flowchart** met blokken zoals:
 1. Data-inname (NOS + RDW data)
 2. Preprocessing (tokenisatie, cleanen)
 3. Sentimentanalyse (RobBERT v2 → score)
 4. Aggregatie over tijd
 5. Voorspellingsmodel (XGBoost)
 6. Evaluatie (RMSE, MAE)
- Leg uit *waarom* ik voor deze AI-technieken hebt gekozen

7.20.1.1.4 Gebruikersonderzoek / Empathy Map

Ik maak geen app voor gebruikers, maar toch kun ik 'gebruikers' definiëren als **besluitvormers** of **analisten**.

- Interview 1 of 2 experts uit de branche (denk aan mensen bij de gemeente, duurzaamheid, mobiliteit of marktanalyse).
- Vraag hen:
 - *Zou dit soort voorspellingstool jou helpen?*
 - *Wat voor output zou nuttig zijn?*
 - *Wat voor vertrouwen moet je hebben in zo'n model om het te gebruiken?*
- Dit is jouw "gebruikersonderzoek".

7.21 01/05 To do list

Skelet schrijven

In elk project (blok 1, blok 2 en afstuderen) wordt een rapport opgeleverd ter ondersteuning van je

Product. De belangrijkste onderbouwde keuzes en resultaten zijn daarin terug te lezen. Het rapport heeft een traditionele vorm van een thesis en/of artikel van max. 10 blz. (IEEE-double column). Om een indicatie te geven bevat het rapport de volgende onderdelen. In overleg met je Docentbegeleider/lab-begeleider

Kun je daar iets van af wijken.

- Samenvatting
- Introductie
 - Context, Probleem, Bestaand werk, Gat, Voorstel
- Achtergrond
 - Basiskennis (literatuur)
 - State of the art (literatuur)
 - Stakeholder-analyse
- Requirements
 - Product (inclusief gebruikersinterface)
 - Model
- Prototype
 - Idee generatie en value proposition
 - Flow diagrams en AI breakdown
 - Gebruikersonderzoek (empathy map bijvoorbeeld)
 - (Paper) Prototype
- Model
 - Methodologie (dataset, architecture, ...)
 - Resultaten (performance en andere kwaliteitsmaten)
 - Conclusie
- Discussie
 - Implicaties, Future work, Aanbevelingen
 - Terugkomen op requirements
- Bronnenlijst (overweeg het gebruik van een referentiemanager)

Meeste hiervan kan meegenomen worden uit project van blok 2 en 3 kijk daar dus naar

Focus voornamelijk op leerdoel A,

Todo list voor morgen (zet leerdoelen naast de benodigdheden)

- Leg duidelijk uit waarom je gekozen hebt voor specifieke methoden en modellen
- Licht toe waarom bepaalde tools of drempelwaarden (thresholds) zijn gebruikt
- Onderzoek micro-economische factoren die correleren met autoverkoop (binnen 2 weken)
- Gebruik topic modeling en named entity recognition om relevante artikelen te selecteren (binnen 2 weken)
- Presenteer eerste resultaten (binnen 3 weken)
- Focus op de uitleg van je methode en de behaalde resultaten (binnen 3 weken)
- Gebruik Jina Embeddings v3 in plaats van RobBERT voor betere semantische zoekresultaten en sentimentanalyse
- Bereken cosine similarity tussen artikel-embeddings
- Kies een drempelwaarde voor clustering (bijvoorbeeld 0.99 of 0.98)
- Cluster artikelen op basis van cosine similarity
- Identificeer het grootste cluster dat relevant is voor je onderwerp
- Label clusters automatisch
- Gebruik de gelabelde clusters om een classifier te bouwen

7.22 30/04: (Leave one out toepassen, Nos Sentiment maken met keyword search, evt train/test split maken)

7.22.1.1 Leave one out:

Kaggle:

<http://kaggle.com/code/felipefonte99/leave-one-out>

The notebook provides a detailed account of the process, including input, output, and logs. The project involves using Python to process a train file, create a testing set, and develop an LGB model. The notebook has been released under the Apache 2.0 open source license and has been viewed 5,605 times.

LANL Earthquake Prediction

The LANL Earthquake Prediction competition is a research prediction challenge hosted by Los Alamos National Laboratory. The goal is to predict the time remaining before laboratory earthquakes occur from real-time seismic data. The competition uses a dataset from an experiment on rock in a double direct shear geometry subjected to bi-axial loading, which mimics the cycle of loading and failure on tectonic faults. The winner will receive a prize of \$20,000.

<http://kaggle.com/c/LANL-Earthquake-Prediction>

Verlag voortgangsoverleg huiswerkbegeleider

Tijdens het overleg is besproken dat er een aantal vervolgstappen nodig zijn voor de analyse en rapportage. Er moet een scatterplot gemaakt worden van het consumentenvertrouwen ten opzichte van autoverkoop, en aanvullende informatie over consumentenvertrouwen worden verzameld. Daarnaast moet de lagtime worden onderzocht, zowel in de train data als specifiek voor benzineprijzen en consumentenvertrouwen. Het is nog onduidelijk of eerst per feature gekeken moet worden of dat de lagtime als eerste moet worden berekend – dit dient nog te worden uitgezocht. Verder moet worden gecontroleerd of de lagtime correct wordt berekend en of de foutmarges realistisch zijn (met name bij voorgaande verkoopdata lijkt de foutmarge verdacht laag).

Ook is geopperd om alternatieve modellen te overwegen, zoals RNN, die mogelijk goed kunnen presteren.

Tot slot is afgesproken dat er morgenochtend gestart wordt met het schrijven van de tekst. Daarna volgt verdere programmering, preprocessing en training van de data. Daarnaast wordt begonnen met een eerste opzet van het onderzoeksrapport, inclusief inleiding, onderzoeksvraag en eventueel al uitgevoerde experimenten.

7.23 28/04 (Dataset gemerged, code naar stefan gestuurd)

Data nog een keer proberen te mergen, is gelukt, maar De data van het consumentenvertrouwen werd tot 2017 maandelijks bijgehouden, maar sinds 2017 is dit per kwartaal. Om toch een consistente maandelijks dataset te hebben, heb ik lineaire interpolatie toegepast. Hiermee worden de ontbrekende maanden tussen de kwartaalmetingen ingevuld op basis van het gemiddelde tussen de voorgaande en volgende bekende waarden.

7.23.1.1 Notebook XGBOost car sales:

nog doen:

- Uitleggen waarom ik de prestatie maten gebruik (mae foutmarge)
- Verschillende lag time's verantwoorden
- Cars sales anonimiseren
- Scatterplot maken van consumenten vertrouwen & autoverkoop
- Extra info opdoen over consumenten vertrouwen
- Lagtime (checken door traindata goed te zetten)
- Ook lagtimeberekenen voor benzine/consumenten vertrouwen
- Eerst per feature dan lag time of andersom? ← checken
- Check of lagtime juist wordt berekend
- Check foutmarge (met voorgaande verkoop verdacht lage foutmarge)
- Eventueel ook andere modellen gebruiken (rnn werkt wss ook goed) → daar nog naar kijken.
-


Plan voor tekst opschrijven:

Morgen in de ochtend start met schrijven, daarna verder gaan met programmeren

Andere contributie was om het preprocessen en trainen van data

Alvast skelet versie onderzoeksrapport schrijven (met inleiding/onderzoeksvraag en evt uitgevoerde experimenten.)

Correlatiema
trix gemaakt

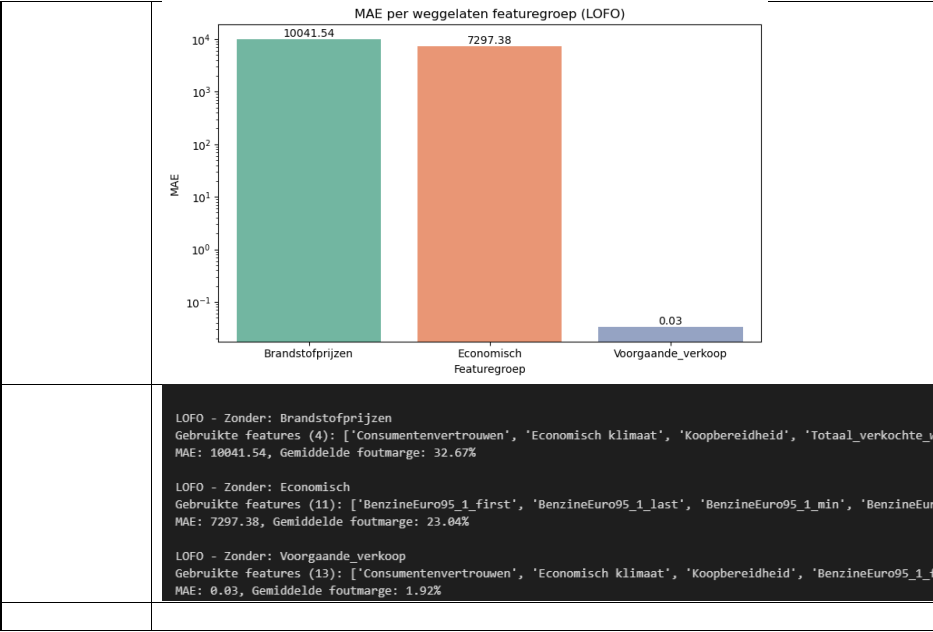


Benzine- en dieselprijzen een sterke positieve correlatie (rond 0.73-0.75) hebben met het aantal verkochte elektrische voertuigen.

Consumentenvertrouwen en economisch klimaat hebben een negatieve correlatie (rond -0.74 tot -0.77) met autoverkoop.

Dit suggereert dat stijgende brandstofprijzen samengaan met meer elektrische

	autoverkoop, terwijl een dalend consumentenvertrouwen mogelijk leidt tot hogere verkopen, mogelijk door stimuleringsmaatregelen.
supervised time series	<div><div><p>Werkelijke vs Voorspelde Autoverkoop (Laatste 12 maanden)</p></div><div><p>Maand 1: Werkelijk=22060.0, Voorspeld=24068.6, Fout=2008.6, Foutmarge=9.10%</p><p>Maand 2: Werkelijk=29193.0, Voorspeld=21791.1, Fout=7401.9, Foutmarge=25.36%</p><p>Maand 3: Werkelijk=25326.0, Voorspeld=27414.6, Fout=2088.6, Foutmarge=8.25%</p><p>Maand 4: Werkelijk=26607.0, Voorspeld=23810.2, Fout=2796.8, Foutmarge=10.51%</p><p>Maand 5: Werkelijk=27731.0, Voorspeld=24069.4, Fout=3661.6, Foutmarge=13.20%</p><p>Maand 6: Werkelijk=25370.0, Voorspeld=23942.2, Fout=1427.8, Foutmarge=5.63%</p><p>Maand 7: Werkelijk=23683.0, Voorspeld=26062.0, Fout=2379.0, Foutmarge=10.05%</p><p>Maand 8: Werkelijk=28820.0, Voorspeld=23167.1, Fout=5652.9, Foutmarge=19.61%</p><p>Maand 9: Werkelijk=30491.0, Voorspeld=26553.2, Fout=3937.8, Foutmarge=12.91%</p><p>Maand 10: Werkelijk=32623.0, Voorspeld=28185.0, Fout=4438.0, Foutmarge=13.60%</p><p>Maand 11: Werkelijk=39594.0, Voorspeld=29159.3, Fout=10434.7, Foutmarge=26.35%</p><p>Maand 12: Werkelijk=33680.0, Voorspeld=35184.1, Fout=1504.1, Foutmarge=4.47%</p><p>MAE: 3977.64</p></div></div> <p>maandelijkse data om in een supervised time series-formaat met sliding window (6 lags), traint een XGBoost-model met walk-forward validatie, en berekent de foutmarge en MAE voor de laatste 12 maanden.</p>
Lofo toegepast	<p>Ik heb per featuregroep getest hoeveel de modelprestatie daalt als deze groep wordt weggelaten.</p> <p>Resultaat: brandstofprijzen zijn het meest bepalend voor de nauwkeurigheid van het model (hoogste MAE bij weglaten), gevolgd door economische indicatoren. De groep "voorgaande verkoop" lijkt nauwelijks invloed te hebben, maar dit is misleidend doordat lag-variabelen van verkoopdata waarschijnlijk nog in het model zaten. Dit wordt in de volgende iteratie gecorrigeerd.</p> <p>Train/val/test splits:</p> <p>De tijdreeksdata (maandelijks 2015–2025) is gesplitst in:</p> <ul style="list-style-type: none">• Trainset: alles tot en met begin 2022• Validatieset: 10 maanden (2022-03 t/m 2022-12)• Testset: laatste 12 maanden (2023 t/m 2024)



(bron toevoegen)

27/04

ToDo:

- Datasets opnieuw inladen
- `<iframe src="https://www.kaggle.com/embed/johnboulard/exploration-public-nos-dataset-feb-2025?cellIds=1&kernelSessionId=234413029" height="300" style="margin: 0 auto; width: 100%; max-width: 950px;" frameborder="0" scrolling="auto" title="EXPLORATION public NOS dataset - feb 2025"></iframe>`
- <https://www.kaggle.com/code/johnboulard/exploration-public-nos-dataset-feb-2025?cellIds=1&kernelSessionId=234413029>

- **Meeting Kees:**

Onderwerpen:

1. Nieuwsartikelen lastig te filteren:

- De dataset met nieuwsberichten bleek te groot om effectief te filteren.
- Daarnaast was het sentiment in de berichten te neutraal voor goede analyses.

2. Tweets geprobeerd:

- Gekeken naar een dataset met tweets en sentiment (al gedaan in ander onderzoek).
- Niet verder uitgewerkt in dit gesprek.

3. Plan B – Keyword search:

- Idee: artikelen handmatig selecteren na keyword search.
- Kees vond dit een goed plan, maar Marcio was er minder enthousiast over.

4. Algemene voortgang scriptie:

- Scriptie loopt goed! (problemen horen erbij)
- Kees adviseert om zo veel mogelijk vast te houden aan het oorspronkelijke plan.

5. Modelkeuze (advies van Daphne):

- Blijven bij regressiemodel (dus geen overstap naar time-series).
- Dit is handiger en past bij het oorspronkelijke plan.

6. Technische hulp – Embeddings:

- Overwogen om Stefan (vader van vriendin, werkt bij Microsoft) te benaderen voor hulp bij het uitvoeren van de embedding code.

? **Data opschonen:**

- **Herlaad alle data** (om mogelijke duplicaten of fouten eruit te halen).

? **Sentiment-analyse:**

- Bepaal of je doorgaat met de **tweets** of verdergaat met **keyword search + handmatige selectie** van artikelen.

? **Modelkeuze bevestigen:**

- Houd vast aan het **regressiemodel** (zoals Daphne adviseerde).

? **Stefan appen:**

- Vraag of hij kan helpen met het **draaien van de embedding code**.

? **Terug naar time-series overweging:**

- Check of je eventueel een **time-series analyse** kunt doen ná opschoning, **indien relevant** (of alleen regressie blijft).

7.24 21/04

7.24.1 TO Do list:

1. Test Jina Embedding model (0.1 sample)

- Laad een 10% sample ($\text{frac}=0.1$) van de NOS-dataset.
- Genereer **embeddings** met Jina Embedding v3.
- Bereken de **gemiddelde embedding per maand** (of week).
- Koppel het aan de maanden van autoverkoop (zonder echte cijfers nog).

2. Correlatie-analyse (zonder verkoopcijfers!)

- Gebruik een **dummyreeks van autoverkoop-indicatoren** (bv. "hoge", "lage" verkoopperiodes) op basis van publieke bronnen of seizoenspatronen.
- Bereken de **Pearson-correlatiecoëfficiënt** tussen sentiment (gemiddelde embedding score of topic score) en deze indicatoren.
- Documenteer dit als **proof-of-concept** voor correlatie zonder gevoelige data.

3. Literatuuronderzoek

- Zoek papers/artikelen over:
 - Economisch of consumentenvertrouwen vs. koopgedrag
 - Sentimentanalyse in econometrie of autosector
 - Voorbeeld: "Media sentiment and economic indicators"
- Noteer min. 3 bronnen (APA) voor je verslag.

Zoektermen in Google Scholar:

- "consumer sentiment economic behavior"
- "media sentiment car sales"
- "text analysis economic indicators"

4. Autoverkoopdata herbekijken

- Vraag de docent of je **geaggregeerde of geanonimiseerde cijfers** mag gebruiken (bijv. per maand, zonder exacte getallen).
- Alternatief: Zoek een **open dataset** van autoverkopen (bijv. via CBS of European Automobile Manufacturers Association).

5. Voorbereiding op gesprek

- Print of open notities: wat is je onderzoeksvraag, wat wil je testen, waar loop je tegenaan?
- Leg uit hoe je omgaat met beperkingen van data (proxygebruik, indirecte analyse).
- Formuleer concrete vragen aan je docent:

- “Mag ik de verkoopdata benaderen via proxies?”
- “Is het oké als ik sentiment meet op maandniveau?”
- “Welke semantische analyse zou waardevol zijn volgens u?”

7.24.1.1 Idea: Adding CBS Consumer Sentiment Indicators as Complementary Features

Currently, the model relies on sentiment extracted from NOS news articles (2015–2025) to predict economic behavior. While this news sentiment captures real-time media tone and public discourse, it may not fully reflect how consumers themselves perceive their financial situation or the broader economy.

To complement the media-driven approach, I am considering integrating **official consumer sentiment indicators from Statistics Netherlands (CBS)**. These include:

- *Consumer Confidence* (Consumentenvertrouwen_1)
- *Willingness to Buy* (Koopbereidheid_3)
- *Economic Climate* (EconomischKlimaat_2)

These indicators are based on monthly surveys of Dutch consumers and offer a **structured and aggregated view of consumer expectations**. By including them in the model, I aim to:

- Capture behavioral trends that may not be directly visible in media sentiment,
- Compare the explanatory power of **public opinion vs. media tone**, and
- Test whether combining both sources reduces prediction error (e.g., RMSE, MAE).

This hybrid approach could potentially enhance model robustness by blending **bottom-up signals (public sentiment)** with **top-down signals (news sentiment)**.

In de oorspronkelijke versie van dit project werden EV-gerelateerde artikelen geïdentificeerd op basis van een vaste lijst met zoekwoorden, zoals “*elektrische auto*”, “*Tesla*” of “*laadpaal*”. Hoewel deze methode snel en simpel toepasbaar is, heeft het een aantal duidelijke beperkingen. De detectie is oppervlakkig, mist context, en herkent geen synoniemen of inhoud die semantisch verwant is aan het onderwerp, maar niet letterlijk de zoekwoorden bevat.

Om dit te verbeteren, is gekozen voor een geavanceerdere aanpak waarbij gebruik wordt gemaakt van de semantische kracht van de Jina Embeddings v3 encoder. In plaats van puur op trefwoorden te zoeken, wordt een representatieve zoekzin zoals:

"Dit artikel gaat over elektrische voertuigen of duurzaamheid in mobiliteit"

omgezet in een embedding (vectorrepresentatie). Deze zoekembedding wordt vervolgens vergeleken met de embeddings van alle artikelen met behulp van cosine similarity. Artikelen die qua betekenis dicht bij de zoekzin liggen, krijgen

Post meeting:

Making “simple regression model”

8 Meeting Marcio 17/04

Project Focus: Microeconomic Factors in Car Sales

Timeline & Planning

- Next 2 weeks:
 - Research **microeconomic factors** that correlate with **car sales**.
 - Use **topic modeling** and **named entity recognition** for **article selection**.
- Within 3 weeks:
 - Present **first results**.
 - Focus on **methodology** and **results**.

Article Search & Classification

Tools & Techniques

- **Embeddings:** Try **Jina Embeddings v3** instead of RobBERT for better **semantic search** and **sentiment analysis**.
- **Clustering Approach:**
 - Calculate **cosine similarity** between article embeddings.
 - Determine a **threshold** (e.g., 0.99 / 0.98) for inclusion in clusters.
 - **Cluster** articles based on similarity.
 - Identify the **largest cluster** related to your subject.
 - **Automatically label** clusters → generate a **classifier** based on them.

Methodological Considerations

Selection Criteria

- **Need a clear method** for article selection (justify the process).
- Use **topic modeling** and **NER** to filter relevant content.

Metrics

- For current car sales data:
 - Calculate **RMSE** and **MSE** to assess model performance.

Quality Expectations

- Define **how the system should perform** (precision, recall, interpretability).
- Must explain **historical events** that match **graphical patterns** in the data.

Data Handling

Met opmerkingen [DH1]: Hier dus nog mee wachten met Stefan
(denk trouwens dat ik evt met collab al een heel eind kan komen)

- Watch out for **data leakage**:
 - **Don't show raw car sales data** during model training/validation.
 - Ensure the model can't "cheat" by seeing target data in features.

Communication & Next Steps

- Let **Marcio** know if we can schedule **weekly check-ins**.
- Emphasize that the project involves:
 - The **right steps** (experimentation, methodology).
 - But also needs to make **logical and practical sense** overall.
- Be sure to **clearly justify**:
 - The **methods and models** used.
 - Why **certain tools/thresholds** were chosen.

8.1.1.1 Original notes:

<https://huggingface.co/jinaai/jina-embeddings-v3> use jina for article search and couple

what would be threshold by for example cosine 99/98

create cluster of articles

find big cluster that similar to subject

and then label them (automatic) → print classifier based on that.

Research micro economic factor sin buying cars

` → UPcoming 2 weeks find factors that corralate with car sales.

Limited time → that's why

Clear method of the selection of articles →

Quality → how it should perform

Using topic modelling for article selection, named entity

Explain hystorical events based on the graph

DATA leakage → car sales (niet laten zien!)

→ Gaat lasting worden om model reasoning

UPcoming 2 weeks find factors that corralate with car sales.

First now → what is rmse mse (regression van data dat ik nu heb)

Focus on methology and results

Within 3 weeks results

Let marcio know if we can sit in weekly bases

Consumenten vertrouwen

TO/DO

1. Sentimentanalyse

- Keyword search verbeteren → nu semantic search
- Keuze voor RobBERT onderbouwen → kappa score
- Literatuur over sentiment in nieuwsartikelen zoeken
- Twee modellen vergelijken met Kappa-score

2. CBS-data

- CBS-datasets documenteren (auto's, brandstofprijzen)

3. Lag time analyse

- Effect van 1-2 maanden vertraging in auto sales onderzoeken

4. Time series

- Eerste versie van time series analyse opzetten
- Nog geen parameter tuning uitvoeren

8.2 Update last feedback moment:

Moet ik nog doen

Ben er mee bezig

Is af

Algemeen / Overkoepelend

- Maak duidelijk dat **correlatie geen causaliteit** betekent, en benoem mogelijke externe factoren.
- Voeg reflectie toe over het feit dat autokoopbeslissingen **niet direct reageren op nieuws**, in tegenstelling tot bijvoorbeeld aandelen.
- Overweeg de **toevoeging van andere databronnen** naast NOS (bv. Rijksoverheid, autobladen, economische nieuwssites).
- Verfijn de methode van **artikelselectie**: overweeg geavanceerdere technieken zoals **topic modelling** of **sentence embeddings** in plaats van alleen keyword search.
- Voeg een stap toe waarin je **verschillende sentimentmodellen en forecastingmodellen vergelijkt** (minstens drie), inclusief voor- en nadelen.

Introductie

- Voeg **betrouwbare bronvermelding** toe aan claims over nieuwsimpact op consumentenvertrouwen en EV-aankopen.
- Leg uit **waarom je NOS hebt gekozen** als bron, en niet meerdere of andere media.
- Begin niet meteen met het noemen van **XGBoost of RobBERT v2**. Contextualiseer eerst het probleem.
- Noem in het kort bestaand onderzoek en **leg uit hoe jouw werk hierop voortbouwt**.

Probleemstelling en Onderzoeksdoel

- Maak de **doelstellingen abstracter**: formuleer ze op hoger niveau, zoals "onderzoeken welk sentimentmodel geschikt is".
- Verplaats de keuze voor modellen (RobBERT v2, XGBoost) naar de **methodesectie**.
- Maak de hoofdonderzoeksvraag concreter: specificeer wat je bedoelt met "voertuigverkoop" (aantallen? omzet?).
- Verwijder specifieke **evaluatiemetrics zoals RMSE** uit de vraagstelling, zodat je die later kunt motiveren.

Onderzoeksvragen

- **Verminder het aantal subvragen.**
- Orden de subvragen logischer:
 1. Wat is sentimentanalyse? Welke categorieën zijn relevant?
 2. Wat zijn state-of-the-art methodes voor tijdreeksvoorspelling?
 3. Hoe is sentiment eerder ingezet in voorspellingen?
 4. Hoe effectief is het om sentiment toe te voegen aan voorspellingsmodellen?

Literatuurstudie

- Voeg een formele definitie van sentiment toe en bespreek relevante categorieën (optimisme, pessimisme, woede, etc.).
- Voeg een overzicht toe van literatuur over tijdreeksvoorspelling, niet alleen XGBoost.
- **Onderbouw de claim dat de meeste studies gericht zijn op de VS en China met bronnen, en geef aan hoe jouw onderzoek hierin iets nieuws toevoegt.**

Methodologie

- Leg uit waarom je RobBERT v2 gebruikt en overweeg of fine-tuning nodig is.
- Leg uit waarom je XGBoost kiest en niet alternatieven zoals LSTM, ARIMA, etc. → MET KAPPA
- Voeg een validatie-set toe aan je train/test split.
- Specificeer welke evaluatiemetrics je gebruikt en waarom.

Reflectie en Discussie

- Sta stil bij het feit dat andere, niet-gemeten variabelen mogelijk verklarender zijn.
- Reflecteer op het beperkte bereik van je data en modelkeuze.
- Overweeg om ook verkoopdata van fossiele auto's mee te nemen voor vergelijking. → ben nu bezig met nieuwe data exploratie CBS

8.3 15/04:

Auto verkoop CBS:




Figure 1Verkochte voertuigen




Figure 2 Brandstofprijzen




Figure 3 1&2 samen

Horizontaal tabel gemaakt:

Jaar Maand	BenzineEuro95_1_first	BenzineEuro95_1_last	BenzineEuro95_1_min	BenzineEuro95_1_max	BenzineEuro95_1_mean	Diesel_2_first	Diesel_2_last	Diesel_2_min	Diesel_2_max	Diesel_2_mean	TotaalVerkochtWegvoertuigen_1	NieuwVerkochtWegvoertuigen_2	TweedehandsVerkochtWegvoertuigen_3
2015-01	1.501	1.46	1.458	1.503	14.730.645.161.290.300	1.207	1.19	1.184	1.208	11.940.645.161.290.300	320045	57337	262708
2015-02	1.461	1.557	1.461	1.557	15.201.428.571.428.500	1.192	1.291	1.192	1.291	12.539.642.857.142.800	273654	40170	233484
2015-03	1.559	1.601	1.559	1.603	15.861.612.903.225.800	1.291	1.277	1.276	1.294	12.866.129.032.258.000	291533	36261	255272
2015-04	1.599	1.646	1.592	1.647	16.144.666.666.666.600	1.275	1.312	1.261	1.312	12.833.666.666.666.600	278536	33416	245120
2015-05	1.645	1.639	1.634	1.648	16.408.064.516.129.000	1.31	1.306	1.306	1.313	13.097.096.774.193.500	274390	34819	239571
2015-06	1.638	1.653	1.638	1.668	16.549.333.333.333.300	1.304	1.295	1.293	1.31	13.014.000.000.000.000	307521	46094	261427

		pump (elec as well)					news		sentiment				target values	
Month	# cars sold (CBS)	start	end	max	min	avg	count	highly neg	mildly neg	neutral	mildly pos	highly positive	# cars upcoming month	# cars upcoming 2 months
Apr/24	500	1	1,5	1,7	0,8	1,3	30	2	1	10	15	2		

8.4 14/04:

Meeting with Marcio on 03/04

Key points discussed:

- Improve filtering based on keywords
- Define a target variable for multiple days
- Include electricity data in the analysis

Goal for today:

- Conduct data exploration
- Improve keyword research
- Perform a bit more literature review

		pump (elec as well)						news		sentiment					target values		
Month	# cars sold (CBS)	start	end	max	min	avg		count		highly neg	mildly neg	neutral	mildly pos	highly positive	# cars upcoming month	# cars upcoming 2 months	
April24	500	1	1,5	1,7	0,8	1,3		36		2	1	19	15	2			

8.5 03/04

8.5.1.1.1 Thesis Supervisor Meeting Agenda

8.5.1.1.2 1. Collected More Data

Update:

- Found better data sources from CBS:
- Lease pricing per quarter: Operational lease – Personenauto's
- Vehicle sales (filtered by new + passenger cars): Verkochte voertuigen
- Fuel prices (per day): Pompprijzen

Why this is better than RDW:

- Easier to filter for passenger cars
- Contains monthly frequency
- More accurate sales information

Question:

Are these CBS datasets sufficient and appropriate for a robust forecasting model, or should I consider additional sources (e.g., economic indicators, subsidies)?

8.5.1.2 Revised Research Question and Subquestions (Data-Driven)

Main Research Question:

How can news sentiment and macroeconomic indicators be used to forecast electric vehicle sales in the Netherlands?

Suggested Subquestions:

1. Which types of data have been used in literature to forecast EV or car sales (e.g., economic, sentiment, policy)?
2. What macroeconomic data sources are available in the Dutch context to inform car sales forecasting?
3. How can sentiment data (e.g., from news or social media) be extracted and quantified in a meaningful way?
4. How do different combinations of data sources affect the accuracy of car sales forecasting models?
5. Which forecasting model performs best given the chosen data sources (e.g., XGBoost, LSTM, Prophet)?

8.5.1.3 3. Data and Model Evaluation Strategy

Example Data Types and Their Evaluation Potential:

Data Type	Source	Signal Type	Expected Impact
Vehicle sales history	CBS	Quantitative, monthly	Baseline
Fuel prices	CBS	Quantitative, daily	Price sensitivity
Lease prices	CBS	Quantitative, quarterly	Affordability impact
Sentiment (NOS)	Media	Qualitative → score	Public mood
Economic news (FD)	Media	Qualitative → score	Policy influence

8.5.1.4 4. Questions for Supervisor

- What types of macroeconomic indicators are typically most useful in mobility forecasting?
- Would you recommend adding government policy variables (e.g., subsidy schedules)?
- How can I better justify the inclusion of sentiment as a signal for forecasting?
- Do you suggest beginning with a baseline (e.g. sales + fuel prices) and then gradually adding features like sentiment?
- Would it be reasonable to test different feature combinations across multiple models (e.g., XGBoost vs. LSTM) as part of the comparison?

Questions from me:

- how does the logbook look like
 - In what way can I incorporate my A learning goals? By making a dashboard?
 - Goal for upcoming weeks, incorporate feedback, finding better way sentiment analysis/keywords
 - Not sure if gap is still sufficient.
 - Research the (biggest) factors in the car market. (any tips?)
 - Possibility to move our meetings to Thursday

8.6 29/03

Doel:

Data uitbreiden:

Zelf gevonden op CBS:

https://opendata.cbs.nl/statline/portal.html?_la=nl&_catalog=CBS&tableId=85784NED&_theme=434

prijzontwikkeling per kwartaal van diensten van autoleasebedrijven, namelijk operationele lease van personenauto's, bestelauto's en privéauto's (private lease)

Verkochte autos: **Verkochte wegvoertuigen; nieuw en tweedehands, voertuigsoort, brandstof**

beter dan RDW want: het is sws verkochte autos, filteren op nieuw en op personen autos en het is

per maand

<https://opendata.cbs.nl/statline/#/CBS/nl/dataset/85898NED/table?ts=1743271461148>

pompprijzen:

Pompprijzen motorbrandstoffen; brandstofsoort, per dag

https://opendata.cbs.nl/statline/portal.html?_la=nl&_catalog=CBS&tableId=80416ned&_theme=434

8.7 26/03

Why RoBERT v2 and not others?

Why XGBoost and not others?

Why only NOS?

What if you could not find any correlation

Perhaps because other unseen variables were not present in your correlation analysis

Perhaps the decision-making process when buying a car is not as instant as buying a stock.

Feedback thesis

(-) Introduction: Some strong sentences lack reputable citations. For example: "News coverage can impact public perception, potentially affecting consumer confidence and EV purchase decisions" - Based on which evidence?

(-) Introduction: It escalated too quickly to assign NOS as the sole media source. It is too early to converge. More specifically, why NOS and not other sources?

(-) Introduction: It escalated too quickly to specific ML models such as XGBoost. Again, it is too early to define the architecture and metrics. The introduction is more about contextualising, developing the problem statement, and developing research questions and project objectives.

(-) Introduction: The last paragraph mentions that the research extends prior research but does not clarify these works. Please ensure you, at this point, highlight at least some contributions in the field. Then, in a more extensive way, in the literature review section.

(-) Problem statement and research goal: **Escalated too quickly to models such as RobBERT v2.** Please review the objectives to make them more high-level. One of the objectives could be evaluating which sentiment model (pretrained or fine-tuned) would suit the problem better.

(-) Research question: Which variable you are referring to? What is the number of vehicles sold or their value (currency)? Please be more specific here. Also, specific metrics such as RMSE should be removed. It will give you more freedom to choose the most suitable metric in the methodology and substantiate your choice.

(-) **Reduce the number of subquestions and create a natural ordering form them: e.g. a sub-question dedicated to sentiment analysis and how it works, and state-of-the-art (literature), a sub-question dedicated to forecasting using time series (literature), a sub-question dedicated to**

exploring the usage of sentiment in forecasting (methodology), a sub-question dedicated to measuring the effectiveness of adding the sentiment in forecasting (results)

(-) Literature: I missed a contextualisation and a formal definition of sentiment, its categories, and what it means. More specifically, which sentiments, such as pessimism, optimism, anger, etc., are relevant to the problem of EV sales forecasting?

(-) Literature: There should be a review on forecasting using time series. Currently, the research plan is strongly focused on XGBoost.

(-) Literature: It says that "most sentiment-based forecasting models have focused on China and the US, leaving the Netherlands adoption patterns largely underexplored." Where are these references? These works can be very interesting, and many ideas could be extended to the Dutch market.

(-) Methodology:

(-) keyword-based search to identify electric car subjects is too fragile. I prefer using a bit more sophisticated techniques such as topic modelling or embeddings for similarity search.

(-) The choice of sentiment model was not substantiated. Why Robbert V2? Is it fine-tuning necessary?

(-) The choice of XGBoost was not substantiated.

(-) Fundamental error: you should reserve portions for validation, not only train/test.

(-) There are many metrics, but which will be used to make decisions?

Final observations:

In general, finding correlations between news and sales seems interesting. At the same time, this phenomenon can be much more complex and involve variables that are not within your scope. Thus, correlation does not mean causality. Also, there is only a single type of source (NOS) and no others, e.g. government communications, specialised magazines on cars, economy news describing issues with fossil fuels or discussing the price of energy, etc. Also, consider using data about fossil fuel cars and analysing if there is a trend concerning the increase or decrease in sales.

The way articles are selected seems too fragile, based on keywords. It appears that the market of electric cars is more complex and depends on other factors such as the price of electricity, subsidies from the government, exceptions or reductions of tax for the adoption of electric cars, and global economic tensions (e.g. Trump, Musk and the repulsion to buy Tesla cars and so on)

A step should also be added to evaluate the most suitable sentiment analysis and forecasting model. You should select at least three alternatives and systematically compare their pros and cons.

8.8 13/03

Todlist

PVA:

Planning maken.

1. Data Selectie & Verwerking

- Bepalen welke NOS-data wordt gebruikt:
 - Sentimentanalyse op alle artikelen?
 - Alleen artikelen over EV's?
 - EV-gerelateerde thema's meenemen (klimaatverandering, duurzaamheid, belangrijke personen zoals Elon Musk)?
- Checken hoeveel artikelen er zijn over EV's en of dat voldoende is.
- Keuze onderbouwen en opnemen in het PvA.

8.8.1 12/03 feedback daphne op concept

To-Do List voor het PvA en Projectplan

1. Data Selectie & Verwerking

- Bepalen welke NOS-data wordt gebruikt:
 - Sentimentanalyse op alle artikelen?
 - Alleen artikelen over EV's?
 - EV-gerelateerde thema's meenemen (klimaatverandering, duurzaamheid, belangrijke personen zoals Elon Musk)?
- Checken hoeveel artikelen er zijn over EV's en of dat voldoende is.
- Keuze onderbouwen en opnemen in het PvA.

2. Planning Verduidelijken

- Detailleren wat wordt bedoeld met "70%-versie van project":
 - Wat valt hieronder? (bijv. data preprocessing, model bouwen, experimenten, resultaten analyseren, etc.)
- Specifieker maken wat elke fase inhoudt.
- Toevoegen aan het PvA.

3. Bespreking Voorbereiden

- Overzicht maken van de vragen die nog openstaan.
- Eventuele andere knelpunten opschrijven om morgen te bespreken.

Kinski toevoegn bron

Gap schrijven

Bronnen ff goed doorlezen

Volgende keer

- Leg uit wat je gaat doen in 'Jip-en-Janneketaal'
- Lever conceptversie van Onderzoeksplan in
 - Vraagstelling
 - Literatuur
 - Methodiek



9 Jip en janneke taal:

Onderzoeksplan – Impact van Online Sentiment op de Verkoop van Elektrische Auto's

Inleiding

Elektrische auto's worden steeds populairder. Veel mensen vinden ze goed voor het milieu, maar er zijn ook zorgen, zoals de actieradius en laadinfrastructuur. Dit onderzoek gaat over hoe mensen online praten over elektrische auto's en of dit invloed heeft op de verkoopcijfers.

Probleembeschrijving & Vraagstelling

Op sociale media en autowebsites geven mensen hun mening over elektrische auto's. Soms zijn ze positief, soms negatief. Maar heeft dat invloed op de verkoop?

Hoofdvraag:

Hoe beïnvloedt online sentiment de verkoop van elektrische auto's en kan dit helpen bij betere verkoopvoorspellingen?

Deelvragen:

1. Wat zeggen mensen online/op twitter over elektrische auto's?
2. Is er een verband tussen positieve of negatieve meningen en verkoopcijfers?
3. Welke andere factoren (zoals prijs en subsidies) spelen een rol?
4. Kan sentimentanalyse helpen om verkoopcijfers beter te voorspellen?

Literatuuronderzoek

Eerdere onderzoeken laten zien dat online sentimenten kunnen helpen bij het voorspellen van trends in verschillende markten.

- **Chen (2024)** ontdekte dat autobeoordelingen op Autohome de verkoopvoorspelling met **54%** verbeterden.
- **Kinski (2016)** vond dat zoekopdrachten op **Google Trends** tot **68,5% nauwkeurigheid** leiden bij autoverkoopvoorspellingen.
- **Liu et al. (2024)** lieten zien dat de aanwezigheid van **laadstations** een grote rol speelt in de aankoopbeslissing van elektrische auto's.
- **Sharma et al. (2024)** toonden aan dat sentimentanalyse met AI-modellen (zoals BERT) effectief is voor het begrijpen van consumentengedrag.

Methodiek (Hoe gaan we dit onderzoeken?)

1. Data verzamelen

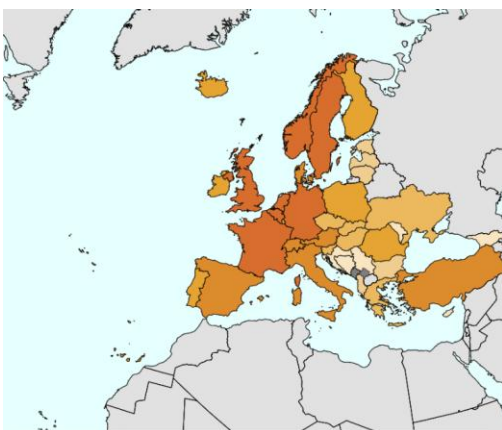
- **Verkoopcijfers van EV's** → Gegevens van RDW
- **Online meningen** → Twitter, Reddit, Autohome (reviews en social media)
- **Zoekgedrag** → Google Trends-data

2. Data analyseren

- Sentimentanalyse uitvoeren met AI-tools om te zien of berichten positief of negatief zijn.
- Correlatie berekenen tussen sentiment en verkoopcijfers (bijv. met Spearman/Pearson).
- Testen of het toevoegen van sentimentgegevens aan verkoopvoorspellingsmodellen (zoals XGBoost) de nauwkeurigheid verbetert.

3. Conclusies trekken

- Heeft online sentiment invloed op de verkoop?
- Kunnen we hiermee betere verkoopvoorspellingen maken?
- Wat betekent dit voor fabrikanten en beleidsmakers?



Nieuw plan afstuderen:

Sentiment analyse op de verkoop van ev

Electric field door

Impactanalyse van sentiment op EV-verkoop

Doel:

1. Onderzoeken in hoeverre online sentimenten over elektrische voertuigen correleren met verkoopcijfers en marktdynamiek.
2. How socialmedia sentiment can improve sales forecasting

Data:

Car sales → RDW

Autohome (carreview data)

- **Waarom?** Dit kan helpen om te begrijpen of positieve of negatieve publieke percepties invloed hebben op de markt.
- **Methode:** Vergelijk sentimentdata (bijv. sociale media, nieuwsartikelen) met verkoopstatistieken en bepaal correlaties.
- **Mogelijke conclusie:** Sentiment kan een rol spelen bij marktacceptatie, maar andere factoren (zoals prijzen en infrastructuur) zijn dominanter.

Titel	Doel	Gebruikte Data	Resultaten
Forecasting China's Car Sales	Verbeteren van autoverkoopvoorspellingen in China door multivariate analyse en sociale media data.	Historische verkoopcijfers, macro-economische indicatoren, gebruikersreviews, Weibo-sociale media data.	Gebruikersreviews verbeterden de nauwkeurigheid van voorspellingen met 54,42%; sociale media data zorgden voor een verbetering van 10,58%.
Google Trends as Complementary Tool for New Car Sales	Gebruik van Google Trends-gegevens om voorspellingen van nieuwe autoverkoop in verschillende landen te verbeteren.	Google-zoekopdrachten, autoverkoopgegevens, cross-country vergelijking.	Google zoekdata correleren sterk met autoverkoop; het toevoegen van een tijdsvertraging verbeterde de nauwkeurigheid van voorspellingen.
Electric Cars: Perception and Knowledge	Begrijpen van publieke perceptie en kennis over elektrische voertuigen.	Enquêtegegevens over publieke perceptie en kennis van EV's.	Publieke perceptie wordt beïnvloed door actieradius, laadinfrastructuur en kosten; kennisgebrek beperkt adoptie.
Evaluating the Market for EV Using TAM	Onderzoek naar de adoptie van elektrische voertuigen met het Technology Acceptance Model (TAM).	Enquête met 695 respondenten over consumentenhouding ten opzichte van EV's.	Consumentenattitudes en waargenomen bruikbaarheid zijn de belangrijkste drijfveren voor EV-adoptie.
The Impact of Consumer Sentiment on Sales of New Energy Vehicles	Onderzoeken van de impact van consumentensentiment op de verkoop van nieuwe energievoertuigen met tekstuele analyse.	Provinciale paneldata (2017-2022), machine learning-gebaseerde tekstuele analyse.	Consumentensentiment correleert positief met NEV-verkoop; infrastructuur voor opladen vermindert actieradiusangst.
Electric Vehicle Sentiment Analysis Using Large Language Models	Toepassen van grote taalmodellen (LLMs) op sentimentanalyse van EV-merken.	YouTube-commentaren op Lucid Motors en Tesla, sentimentclassificatie met BERT, RoBERTa, XLNet.	RoBERTa behaalde de hoogste sentimentclassificatie nauwkeurigheid met een F1-score van 92%.
Employing Sentimental Analysis to Prove Correlation Between Social Media and Stock Market	Onderzoeken van de correlatie tussen sociale media-sentiment en EV-marktprestaties.	Tweets, nieuwsartikelen, EV-aandelenprijzen, EV-marktaandelen, luchtkwaliteitsgegevens.	Positief sentiment op sociale media correleert sterk met EV-aandelenprijzen en marktprestaties.
Exploring the Sentiment Analysis of Electric Vehicles Social Media	Gebruik van functieselectiemethoden om sentimentanalyse van EV-gerelateerde sociale media-data te verbeteren.	Sociale mediaberichten, functieselectie voor sentimentclassificatie verbetering.	Functieselectiemethoden verbeterden de sentimentclassificatie, wat leidde tot betere inzichten in de EV-markt.

9.1 Feedback Dinsdag 25 februari:

1. Relatie tussen sentiment en beursindex verduidelijken

- Zorg voor een **duidelijke koppeling** tussen sentimentanalyse (bijvoorbeeld via Twitter of nieuws) en de AEX-index.
- In eerder onderzoek werd een vergelijkbare studie (Visser, n.d.) gedaan met **Tesla en Twitter**, waarbij sentiment invloed had op het aandeel van de eigenaar. Overweeg een soortgelijke aanpak voor AEX-bedrijven.

2. Data-uitdagingen

- **Niet alle datasets zijn recent:** Sommige historische data zijn mogelijk beperkt beschikbaar of moeilijk te verkrijgen.
- **Scraping kan illegaal zijn:** Check de juridische en ethische implicaties van webscraping voor nieuwsartikelen en sociale media.
- **Marketing-gebruik van scraping:** Sommige platforms beperken scraping om misbruik te voorkomen, dus overweeg alternatieve methodes zoals API's.

3. Onderzoek Centre Market AI en alternatieven

- Zoek informatie over **Centre Market AI**, dat mogelijk tools of methodes biedt voor het verwerken van marktinformatie via AI.
- Kijk naar bestaande oplossingen voor **webscraping** en API-gebaseerde dataverzameling.

4. Mogelijke uitbreiding: AI-model voor nieuwsverwerking

- Onderzoek of een **Large Language Model (LLM)** nieuwsartikelen kan verwerken en betekenisvolle indicaties kan genereren.
- Overweeg of je een **applicatie kunt bouwen** die historische nieuwsdata analyseert om patronen te ontdekken en te voorspellen.

5. Toekomstige richting

- **Duidelijker doel formuleren:** Zorg ervoor dat jouw onderzoek een heldere focus heeft, bijvoorbeeld:
 - "Kan sentimentanalyse van Nederlandse nieuwsartikelen helpen bij het voorspellen van de AEX?"
- **Praktische toepassing:** Ontwikkel een tool of app die historische data analyseert en betekenisvolle inzichten biedt.
- Onderzoek hoe sentimentgegevens **de invloed van nieuws op aandelenkoersen** beter zichtbaar kunnen maken.

Op basis van de bovenstaande punten ga ik:

Literatuur van Micheal visser (Visser, n.d.) doornemen, en kijken wat hij gebruikt heeft voor model, data collectie. 1 aandeel vinden en daar in specialiseren.

Onderzoek

Doel:

Het doel van de paper is om te onderzoeken hoe social media sentiment, met een onderscheid tussen sentiment polarity en het type content (feit of mening), invloed heeft op aandelenprijsbewegingen Van tesla en Validatie op Taiwan Semiconductor Manufacturing Company (TSM).

Probleem:

Social media posts reflecteerd aandelen sentiment, ligt de uitdaging bij het verdelen van posts die wel relevant zijn voor prijs veranderingen en post die gewoon ruis zijn. Daarnaast is door de komst van jongeren generatie op hun financieel landschap een grotere social gedreven inverserings klimaat. In het verleden hebben trends en hypes implicaties gehad op aandelen (game stock).

Om deze reden is het noodzakelijk om socialmedia sentiment te gebruiken om de impact op de financiële markt te voorspellen.

Huidige tool (opzoeken welke) falen en sentiment analysis focussen zich normaal gesproken op service level emotional tone. Probleem hierbij is dat niet alle posts de zelfde impact hebben.

Existing work

Feat en greed index:

Gebaseert op crypto markt index is ontworpen om de emotie te meten. Bij grote angs (excessive fear) gaan de prijzen zakken en extreme hebzucht (extreme greed) kan lijden tot prijs stijgingen.

Er wordt een cijfer gegeven 0-100 (extreme greed) and komt tot stand uit:

- **Volatiliteit:** De mate van prijsfluctuaties.
- **Marktmomentum/volume:** Het handelsvolume en de marktdynamiek.
- **Sociale media:** Het sentiment van sociale mediaplatforms, voornamelijk X (voorheen Twitter).
- **Enquêtes:** De resultaten van beleggerssentiment-enquêtes.
- **Bitcoin-dominantie:** Het marktaandeel van Bitcoin ten opzichte van de totale cryptomarkt.
- **Google-trends:** Zoek trends en trefwoorden gerelateerd aan cryptocurrency.

De scope van dit onderzoek richt zich enkel op sentiment → Zou interessant zijn voor mijn onderzoek om andere aspecten mee te nemen.

Thomas reuters market psych indices: analyse sentiment across various media sources (news articles, social media, and financial report)

Voor mijn onderzoek kan ik het zelfde argument gebruiken, over dat bestaande tools niet transparant zijn()

Gap:

Huidige sentiment analyse ligt de focus enkel op general sentiment (positief, neutraal, negatief) zonder dat er onderscheid wordt gemaakt op type informatie.

Bestaande modellen nemen de impact van berichten niet mee

Doel! Vergroten van de nauwkeurigheid van aandelen voorspellingen gehaald uit sentiment van social media.

Rc: Hoe kan sentimentanalyse, waarbij zowel meningen als feitelijke inhoud worden meegenomen, worden gebruikt om veranderingen in prijstrends van een specifiek aandeel te voorspellen?

Dataset:

Twitter is gebruikt vanwege groot gebruik van investerrders, korte berichten,

3 datasets zijn gecombineerd naar 1 grote

combi bestaande uit:

1. [kaggle](#) bestaande uit:
 - a. twitter
 - b. Yahoo finance → voor mijn onderzoek kan ik evt invester.com gebruiken
2. Fever
 - a. Support claim verification composes 185000 claims

Modellen:

1. Pretrained model gemaakt voor sentiment analyse
2. Zelf gemaakt model om te checken of tweet opinie was of feitelijk.

Methode:

1. Bekijken dataset
2. Preprosesseren
 - a. Data splitten
 - b. Distributie bekijken → som van linked tweets berekenen voor elke ticker (42% was voor tesla
 - c. Duplicaten verwijderen, Missende waardes identificeren → beide waren er niet
 - d. Train/validatie/test set maken
3. Sentiment classification toepassen op dataset 1 (twitter)

- a. Stap 1 Links verwijderen (verwijzen vaak naar foto/ external context daarom niet meegenomen)
 - b. Alle tekst naar lowercase (zodat alle woorden als het zelfde worden gezien)
 - c. Mentions weghalen “@tesla ” wordt gezien als tesla
 - d. User name is gewisseld voor place holde
 - e. Can’t wordt can not
 - f.
4. Fever gebruikt om feiten te splitsen van meningen
 5. Integreren dataset 3 (yahoo finance) in dataset 1
 6. Emojis worden wel mee genomen

Methode:

De studie analyseert de relatie tussen **social media sentiment** en **aandelenprijsbewegingen** met een hybride aanpak:

1. Data verzamelen:

- o Tweets over aandelen (voornamelijk **TSLA** en TSM) uit een Kaggle-dataset.
- o Historische aandelenprijzen van Yahoo Finance.
- o FEVER-dataset voor feit/opinie-classificatie.

2. Sentimentanalyse:

- o **FinBERT-model** bepaalt de **sentiment polarity** (positief, negatief, neutraal) van tweets.
- o Een op **FEVER** getraind model classificeert tweets als **feit** of **mening**.

3. Data-integratie & visualisatie:

- o Sentimentscores per dag worden berekend en gekoppeld aan de aandelenprijs.
- o Een **21-daags Moving Average** wordt toegepast om ruis te verminderen.
- o Correlaties tussen sentiment en aandelenprijs worden geanalyseerd, zowel met als zonder filtering van meningen.

4. Validatie:

- o De methode wordt getest op TSLA en vervolgens op TSM om de generaliseerbaarheid te beoordelen.

Met opmerkingen [DH2]: In de dataset had TSLA het grootste aandeel (46.3% van de tweets, ±37k tweets). TSM had de op één na meeste tweets (13.6%, ±11k tweets), waardoor het een logische tweede keuze was.

Doel:

Financieel vraagstuk oplossen

Met zelfgemaakt algoritme

Aantonen waarom mijn aanpak zinnig is, wat voegt het toe, presteert het beter?

- Onderwerp:
 - **Stockmarket (AEX) For casting**

Wat is het probleem?

Europese/nederlandse indices zoals AEX zijn onvoldoende onderzocht op dl technieken.

Vraagstelling

"Hoe kan ik de **dagelijkse sluitingsprijs** van de AEX voorspellen met een "**hogere nauwkeurigheid**" dan bestaande modellen?"

Welke modellen zijn er gebruikt, wat is de nauwkeurigheid?

Modellen

Data collection:

1. Stock market Forecasting utilizing News Sentiment Data:(Oriol, n.d.)

a. Gap

- i. The gap identified for this thesis was the lack of comprehensive comparative studies specifically addressing how news sentiment data can enhance stock market forecasting models. Although previous literature has extensively studied the use of newspaper sentiment in stock market predictions, this thesis does not aim at introducing entirely new concepts but rather at performing an in-depth comparative analysis of existing models.
- ii. Specifically, the thesis addresses whether incorporating news sentiment data into predictive models significantly improves the accuracy of predicting stock price movements (both next-day returns and directional classification). The research gap lies in systematically comparing models trained solely on financial data versus models trained with both financial and news sentiment data, thereby providing clearer insights into the practical value and limitations of sentiment analysis for stock forecasting

b. Data collection:

- i. The study narrows its scope by selecting a subset of seven representative stocks from the S&P 500, facilitating targeted and manageable analysis.
- ii. The chosen timeframe (January 1, 2019, to December 31, 2020) strategically aligns with the COVID-19 pandemic's onset, emphasizing the challenge of predicting market behavior during highly volatile periods.
- iii. Models use training data up to March 1, 2020, testing performance afterward, highlighting the difficulties traditional financial indicators face under crisis conditions.
- iv. The forecasting horizon is deliberately restricted to one day ahead, enabling concise, immediate performance evaluation.
- v. Selected stocks represent diverse market sectors and volatility levels, balancing financial visibility in news coverage with market representativeness

c. Future work

- i. Utilization of alternative sentiment sources (social media or analyst reports)
- ii. Incorporating microeconomic indicators

<https://hasdata.com/blog/web-scraping-google-news>

Met opmerkingen [DH3]: Interessant! Want social media was al gedaan vlgm

Onderzoek	Gebruikte Methodes	Modellen	Gaps / Beperkingen	Bron van data	Verwijzing naar onderzoek
Towards Autonomous Investment Analysts	Multi-agent systemen, technische analyse, fundamentele analyse	Adaptieve multi-agent architectuur	Moeilijkheden met menselijke aspecten zoals intuïtie en gezond verstand	Niet specifiek vermeld, algemeen financieel en marktdata	Castro & Junior (2023) [9]
Stock Market Forecasting Using Machine Learning	Tijdreeksanalyse (ARIMA), sentimentanalyse, lineaire regressie, machine learning	ARIMA-modellen, ordinale data regressie, sentimentanalyse-modellen	Beperkt door lineariteit van modellen en beperkte integratie van niet-financiële gegevens	S&P 500 index historische data	Hirulkar et al. (2017) [10]
Enhancing Stock Market Forecasting Through Microservice System	Microservices architectuur, sentimentanalyse, technische analyse, machine learning (LSTM)	Microservices geïntegreerd met LSTM, RSI, MACD indicatoren	Complexiteit van integratie van meerdere microservices en real-time dataverwerkingsuitdagingen	Saudi Aramco en financiële rapporten, sentimentdata	Algarni (2025) [11]
Enhanced Stock Market Forecasting Using Dandelion Optimization-driven 3D-CNN-GRU	Wavelet transformatie, Dandelion Optimization Algorithm (DOA), 3D-CNN-GRU, Blood Coagulation Algorithm (BCA)	Hybride model: 3D-CNN gecombineerd met GRU, optimalisatie via DOA en BCA	Dataset beperkt tot Nifty 50 index; verdere validatie nodig op bredere datasets en verschillende marktscenario's	Nifty 50 index data met technische indicatoren	Jagadesh et al. (2024) [12]

Onderzoek	Methode	Nulmodel	Resultaat	Features	Train/Test Set
Towards Autonomous Investment Analysts	Multi-agent systemen, technische en fundamentele analyse	Geen expliciet nulmodel vermeld	Efficiënte analyse en gepersonaliseerde investeringsadviezen	Technische indicatoren, economische fundamenteen, risicovoorkeuren beleggers	Niet specifiek vermeld
Stock Market Forecasting Using Machine Learning	ARIMA tijdreeksmodellen, sentimentanalyse, regressiemodellen	Eenvoudige historische gemiddelden	Effectieve voorspellingen van S&P 500 prijsbewegingen	Historische prijsgegevens, financiële ratio's, ordinale trends	Niet expliciet vermeld, waarschijnlijk historische splitsing
Enhancing Stock Market Forecasting Through Microservice System	Microservices met LSTM, sentimentanalyse, technische indicatoren	Standaard monolithisch voorspellingsmodel	Sterke voorspelling (LSTM) met MAE 0.26, MSE 0.18	Technische indicatoren (RSI, MACD), sentiment uit financiële rapporten	Niet expliciet vermeld, waarschijnlijk historische splitsing
Enhanced Stock Market Forecasting Using Dandelion Optimization-driven 3D-CNN-GRU	Wavelet transformatie, 3D-CNN-GRU hybride model, DOA en BCA optimalisatie	Niet expliciet vermeld, mogelijk standaard CNN of GRU modellen	Uitzonderlijke nauwkeurigheid (99,14%) met hybride 3D-CNN-GRU	Technische indicatoren (momentum, trend, volatiliteit), geoptimaliseerde features via DOA	Nifty 50 index historische data, splitsing niet specifiek vermeld

